# Introducción a la Computación 2017

## 25 de junio de 2017

# Índice

Sistemas de Numeración	10
Un sistema diferente	10
Preguntas	10
Sistema posicional	11
Calculando cada posición	11
Base de un sistema de numeración	11
Número y numeral	11
Indicando la base	12
Sistema decimal	12
Sistema binario	12
Trucos para conversión rápida	13
Sistema hexadecimal	14
Una expresión general	14
Conversión de base	15
Conversión de base 10 a otras bases	15
Conversión de otras bases a base 10	16
Preguntas	16
Conversión entre bases arbitrarias	16
Equivalencias entre sistemas	17
Conversión entre sistemas binario y hexadecimal	18
Conversión entre sistemas binario y octal	18

Unidades de Información	18
Información	18
Bit	19
El viaje de un bit	20
Byte	20
Representando datos con bytes	21
Sistema Internacional	21
Sistema de Prefijos Binarios	22
Representación de la Información	23
Representación de datos numéricos	23
Clasificación de los números	24
Datos enteros	25
Datos fraccionarios	25
Rango de representación	25
Representación sin signo $SS(k)$	26
Rango de representación de $SS(k)$	26
Representación con signo	27
Sistema de Signo-magnitud SM(k)	28
Rango de representación de $SM(k)$	28
Limitaciones de Signo-Magnitud	29
Sistema de Complemento a 2	29
Operación de Complemento a 2	29
Representación en Complemento a 2	30
Conversión de C2 a base 10	30
RR de C2 con $k$ bits	31
Comparando rangos de representación	31
Aritmética en C2	32
Overflow o desbordamiento en C2	32
Extensión de signo en C2	33
Notación en exceso o <i>bias</i>	34

	Conversión entre exceso y decimal	35
	Representación de fraccionarios	36
	Racionales	36
	Aproximación racional a los irracionales	36
	Coma o punto decimal	36
	Fraccionario en base 2 a decimal	37
	Decimal fraccionario a base 2	38
	Representación de punto fijo	38
	Decimal a $PF(n,k)$	39
	Truncamiento	40
	$PF(n,k) \text{ a decimal } \dots $	40
	Preguntas	41
	Notación Científica	42
	Normalización	43
	Normalización en base 2	43
	Representación en Punto Flotante	43
	Conversión de decimal a punto flotante	44
	Ejemplo de Punto Flotante	45
	Expresión de punto flotante en hexadecimal	45
	Conversión de punto flotante a decimal	45
	Error de truncamiento	47
	Casos especiales en punto flotante	47
D-		48
ĸe	presentación de Texto y multimedia	-
	Codificación de texto	48
	Códigos de caracteres	48
	Tabla de códigos ASCII	49
	Textos y documentos	50
	Archivos de hipertexto	50
	Imagen digital	51
	Color	52

Profundidad de color	 52
Formato de imagen	 52
Un formato de imagen	 53
Reconstruyendo una imagen	 54
Compresión de datos	 54
Compresión sin pérdida	 55
Compresión con pérdida	 55
Reducción de color	 56
Algoritmos de compresión sin pérdida	 57
Run Length Encoding o RLE	 57
Códigos de Huffmann o de longitud variable	 58
Compresión de imágenes con RLE	 59
Compresión con pérdida y pérdida de información	 59
Arquitectura y Organización de Computadoras	60
Componentes de una computadora simple	
Memoria	
CPU	
Arquitectura de Von Neumann	
Máquina de programa almacenado	
CPU y Memoria	
Buses	
Modelo Computacional Binario Elemental	
Esquema del MCBE	
Memoria del MCBE	
Registros del MCBE	
CPU del MCBE	
Formato de instrucciones del MCBE	
Conjunto de instrucciones del MCBE	
Ciclo de instrucción	
Programación del MCBE	 68

	Traza de ejecución	69
	Ayuda	69
	Preguntas	70
ΕI	Software	70
	Lenguajes de bajo nivel	70
	Lenguaje de máquina o código máquina	70
	Lenguaje ensamblador	71
	Mnemónicos	71
	Rótulos	71
	Rótulos en instrucciones de salto	72
	Rótulos predefinidos	73
	Traductores	73
	Ensambladores	73
	Ensamblador x86	73
	Ensamblador ARM	74
	Ensamblador PowerPC	75
	Lenguajes de programación	76
	Lenguajes de bajo nivel	76
	Lenguajes de alto nivel	76
	Niveles de lenguajes	76
	Paradigmas de programación	76
	Paradigma imperativo o procedural	77
	Paradigma lógico o declarativo	77
	Paradigma funcional	78
	Orientación a objetos	78
	Compiladores e intérpretes	78
	Velocidad de ejecución	79
	Portabilidad	79
	Ciclo de compilación	79
	Terminología	79
	Fases del ciclo de compilación	80
	Entornos de desarrollo o IDE	80

istemas de Cómputo	81
Evolución de los sistemas de cómputo	81
Antecedentes históricos	81
La Tabuladora de Hollerith	82
Primera generación	82
El tubo de vacío	83
Memorias de núcleos	83
ENIAC	84
Clementina	84
Segunda generación	85
Semiconductores	85
El transistor	85
Minicomputadoras	86
Tercera generación	86
Circuitos integrados	86
Microprocesador	87
Cuarta generación	88
Microprocesador Intel I7	89
Tiempos de acceso a los datos	90
stemas Operativos	91
Del hardware al software	91
Evolución del software de base	91
Open Shop	91
Sistemas Batch	92
Sistemas Multiprogramados	92
Sistemas de Tiempo Compartido	92
Computación personal	92
Preguntas	93
Componentes del SO	93
Sistemas empotrados o embebidos	93

Aplicaciones
Kernel
Recursos
Procesos
Llamadas al sistema o system calls
Modo dual de operación
Llamadas al sistema
Ejecución de aplicaciones
Una cronología de los SO
Servicios del SO
Ejecución de procesos
Creación de procesos
Estados de los procesos
Scheduler o planificador
Ciclo de estados
Ciclo de estados en un sistema multiprogramado
Ciclo de estados en un sistema de tiempo compartido 100
Comparando multiprogramación y time sharing
Preguntas
Concurrencia y paralelismo
Monitorización de procesos
Comando top
Comandos de procesos
Gestión de archivos
Archivos
Sistema de archivos
Metadatos
Directorios
Varios significados
Árbol de directorios
Nombres de archivo y referencias

Elementos del sistema de archivos
Particiones
Bloques
Inodos
Superblock
Inodos
Metadatos
Bloques de disco
Directorios
Links o nombres de archivo
Búsqueda de un archivo en el filesystem
Gestión de memoria
Mapa de memoria
Espacios de direcciones
Espacio de direcciones físicas
Espacio de direcciones lógicas
Traducción de direcciones
Unidad de gestión de memoria o MMU
Asignación de memoria contigua
Fragmentación externa
Segmentación
Paginación
Fragmentación interna
Tabla de páginas
Paginación por demanda
Memoria virtual
Reemplazo de páginas

Redes de computadoras	120
Modelo de Internet	. 121
Switches	. 121
Routers	. 122
Interfaces	. 123
Medios y enlaces	. 123
Velocidades de transmisión y de propagación	. 124
Tiempo de transferencia de un mensaje	. 125
Entidades de red	. 127
Eventos de red	. 127
Protocolos	. 127
Modelo cliente-servidor	. 128
Modelo peer-to-peer	. 128
Autómatas	. 128
Autómata del cliente	. 129
Autómata del servidor	. 129
Protocolos de parada y espera	. 130
Direcciones de red	. 131
Paquetes IP	. 131
Ruteo o encaminamiento	. 132
Tabla de reenvío o de ruteo	. 132
Subredes	. 132
Prefijo de subred	. 133
Dirección de subred y máscara de subred	. 133
Cálculo de la dirección de subred	. 134
Ruta por defecto o ruta default	. 135
Rutas más específicas y máscaras más largas	. 136
Algoritmo de reenvío	. 136
Servicio de Nombres de Dominio (DNS)	. 137
Jerarquía de nombres de dominio	. 137
Resolución de nombres	. 138

Administración	de redes															139
Comando	ping															139
Comando	tracerout	te														140

## Sistemas de Numeración

En este primer tema de la unidad veremos las propiedades de los sistemas de numeración más importantes para el estudio de la arquitectura de computadoras, en especial los sistemas **binario y hexadecimal**.

## Un sistema diferente

Todos conocemos el método tradicional de contar con los dedos. Como tenemos cinco dedos en cada mano, podemos contar hasta diez. Pero también podemos utilizar un método diferente del tradicional, que resulta ser muy interesante.

- Con este método, al llegar a 5 con la mano derecha, representamos el 6 sólo con un dedo de la izquierda. Los dedos de la mano derecha vuelven a 0, y seguimos contando con la derecha.
- Cada vez que se agotan los dedos de la mano derecha levantamos un nuevo dedo de la izquierda, y la derecha vuelve a 0.
- Cada dedo en alto de la mano izquierda significa que se agotó la secuencia de la mano derecha una vez.

## **Preguntas**

- ¿Hasta qué número se puede representar en este sistema, sólo con dos manos?
- Si agregamos una tercera mano, de un amigo, ¿hasta qué número llegamos?
- ¿Y cómo se representa el 36? ¿Y el 37?
- Y con cuatro manos, ¿hasta qué número llegamos?
- Y, si el número no se puede representar con dos manos, ¿cómo es el procedimiento para saber qué dedos levantar?

Notemos que este método tiene mayor capacidad que el tradicional, ya que podemos contar hasta diez y todavía nos queda mucho por contar con los dedos de ambas manos.

## Sistema posicional

Notemos además que esta ventaja se debe a que el método asigna valores diferentes a ambas manos. La derecha vale la cantidad de dedos que muestre, pero la izquierda vale seis por su cantidad de dedos. Esto se abrevia diciendo que se trata de un sistema de numeración posicional.

Al tratarse de un sistema posicional, podemos representar números relativamente grandes con pocos dígitos. En este sistema, disponemos únicamente de **6 dígitos (0, 1, 2, 3, 4, 5)** porque ésos son los que podemos representar con cada mano, es decir, **en cada posición**. Pero los números representables solamente dependen de cuántas manos (o, mejor dicho, de cuántas **posiciones**) podamos utilizar.

#### Calculando cada posición

En este sistema, dado un número no negativo que se pueda representar con dos manos, podemos saber qué dedos levantar en cada mano haciendo una sencilla cuenta de división entera (sin decimales): dividimos el número por 6 y tomamos el cociente y el resto. El cociente es el número de la izquierda, y el resto, el de la derecha.

Tomemos por ejemplo el número 15. Al dividir 15 por 6, el cociente es 2 y el resto es 3. En este sistema, escribimos el 15 como dos dedos en la izquierda, y tres dedos en la derecha, lo que podemos abreviar como (2,3) o directamente 23 (que se pronuncia dos tres porque no quiere decir veintitrés, sino quince, sólo que escrito en este sistema). Como el dígito 2 de la izquierda vale por 6, si hacemos la operación de sumar  $2 \times 6 + 3$  obtenemos, efectivamente, 15.

## Base de un sistema de numeración

La **base** de un sistema es la cantidad de dígitos de que dispone, o sea que el sistema decimal habitual es de base 10, mientras que el de los deditos es de base 6.

#### Número y numeral

Notemos que un mismo número puede escribirse de muchas maneras: en prácticamente cualquier base que se nos ocurra, sin necesidad de contar con los dedos; y que la forma habitual, en base 10, no es más importante o mejor que las otras (salvo, claro, que ya estamos acostumbrados a ella). Otras culturas han desarrollado otros sistemas de numeración y escriben los números de otra manera.

Esto muestra que hay una **diferencia entre número y numeral**, diferencia que es algo difícil de ver debido a la costumbre de identificar a los números con su representación en decimal.

- El **numeral** es lo que escribimos (15,  $15_{(10}$  o  $23_{(6)}$ ).
- El número es la cantidad de la cual estamos hablando (la misma en los tres casos).

## Indicando la base

Anteriormente escribíamos **15** en el sistema de base 6 como **23**. Sin embargo, necesitamos evitar la confusión entre ambos significados de **23**. Para esto usamos índices subscriptos que indican la base. Así,

- **Quince** es  $15_{(10)}$  porque está en base diez (la del sistema decimal, habitual), y
- 23<sub>(10</sub> es veintitrés,
- pero 23<sub>(6</sub> es **dos tres en base 6**, y por lo tanto vale **quince**.

Como 10 es nuestra base habitual, cuando no usemos índice subscripto estaremos sobreentendiendo que hablamos **en base 10**. Es decir,  $15_{(10)}$  se puede escribir, simplemente, 15.

Cuando queremos pasar un número escrito en una base a un sistema con otra cantidad de dígitos, el procedimiento de averiguar los dígitos que van en cada posición se llama **conversión de base**. Más adelante veremos procedimientos de conversión de base para cualquier caso que aparezca.

## Sistema decimal

Si reflexionamos sobre el sistema decimal, de diez dígitos, encontramos que también forma un sistema posicional, sólo que con 10 dígitos en lugar de los seis del sistema anterior.

Cuando escribimos **15** en el sistema decimal, esta expresión equivale a decir "para saber de qué cantidad estoy hablando, tome el 1 y multiplíquelo por 10, y luego sume el 5".

Si el número (o, mejor dicho, el **numeral**) tiene más dígitos, esos dígitos van multiplicados por **potencias de 10** que van creciendo hacia la izquierda. La cifra de las unidades está multiplicada por la potencia de 10 de exponente 0 (es decir, por  $10^0$ , que es igual a 1).

Esto se cumple para todos los sistemas posicionales, sólo que con potencias **de la** base correspondiente.

## Sistema binario

Comprender y manejar la notación en sistema binario es sumamente importante para el estudio de la computación. El sistema binario comprende únicamente dos dígitos,  ${\bf 0}$  y  ${\bf 1}$ .

Igual que ocurre con el sistema decimal, los numerales se escriben como suma de dígitos del sistema multiplicados por potencias de la base. En este sistema, cada 1 en una posición indica que sumamos una potencia de 2. Esa potencia de 2 es  $2^n$ , donde n es la posición, y las posiciones se cuentan desde 0.

Por ejemplo,

$$10 = 1 \times 8 + 0 \times 4 + 1 \times 2 + 0 \times 1 = 1010_{(2)}$$

У

$$15 = 1 \times 8 + 1 \times 4 + 1 \times 2 + 1 \times 1 = 1111_{(2)}$$

#### Trucos para conversión rápida

Las computadoras digitales, tal como las conocemos hoy, almacenan todos sus datos en forma de números binarios. Es **muy recomendable**, para la práctica de esta materia, adquirir velocidad y seguridad en la conversión de y a sistema binario.

Una manera de facilitar esto es memorizar los valores de algunas potencias iniciales de la base 2:

$$2^0 = 1$$
$$2^1 = 2$$

$$2^2 = 4$$

$$2^3 = 8$$
$$2^4 = 16$$

$$2^5 = 32$$

$$2^6 = 64$$

$$2^7 = 128$$

Otro truco interesante consiste en ver que si un numeral está en base 2, **multiplicarlo por 2 equivale a desplazar un lugar a la izquierda todos sus dígitos, completando con un 0 al final**. Así, si sabemos que  $40_{(10}=101000_{(2)}$ , ¿cómo escribimos rápidamente **80**, que es  $40\times2$ ? Tomamos la expresión de 40 en base 2 y la desplazamos a la izquierda agregando un 0:  $1010000_{(2)}=80_{(10)}$ .

De todas maneras, estos no son más que trucos que pueden servir en no todos los casos. Más adelante veremos el procedimiento de conversión general correcto.

#### **Preguntas**

- ¿Cuál es el truco para calcular rápidamente la expresión binaria de 20, si conocemos la de 40?
- ¿Cómo calculamos la de 40, si conocemos la de 10?
- ¿Cómo podemos expresar estas reglas en forma general?

#### Sistema hexadecimal

Otro sistema de numeración importante es el hexadecimal o de base 16. En este sistema tenemos **más dígitos** que en el decimal, por lo cual tenemos que recurrir a "dígitos" nuevos, tomados del alfabeto. Así, A representa el 10, B el 11, etc.

El sistema hexadecimal nos resultará útil porque con él podremos expresar fácilmente números que llevarían muchos dígitos en sistema binario.

- La conversión entre binarios y hexadecimales es sumamente directa.
- Al ser un sistema con más dígitos que el binario, la expresión de cualquier número será más corta.

## Una expresión general

Como hemos visto intuitivamente en el sistema de contar con los dedos, y como hemos confirmado repasando los sistemas decimal, binario y hexadecimal, los sistemas posicionales tienen una cosa muy importante en común: las cifras de un **numeral** escrito en cualquier base no son otra cosa que los **factores por los cuales hay que multiplicar las sucesivas potencias de la base** para saber a qué **número** nos estamos refiriendo.

Por ejemplo, el numeral 2017 escrito en base 10 no es otra cosa que la suma de:

$$2 \times 1000 + 0 \times 100 + 1 \times 10 + 7 \times 1 = 2 \times 10^{3} + 0 \times 10^{2} + 1 \times 10^{1} + 7 \times 10^{0}$$

Los dígitos 2, 0, 1 y 7 multiplican, respectivamente, a  $10^3$ ,  $10^2$ ,  $10^1$  y  $10^0$ , que son potencias de la base 10. Este **numeral** designa al **número** 2017 porque esta cuenta, efectivamente, da **2017**.

Sin embargo, si el número está expresado en otra base, la cuenta debe hacerse con potencias de esa otra base. Si hablamos de  $2017_{(8)}$ , entonces las cifras 2, 0, 1 y 7

multiplican a  $8^3$ ,  $8^2$ ,  $8^1$  y  $8^0$ . Este **numeral** designa al **número** 1039 porque esta cuenta, efectivamente, da **1039**.

Este análisis permite enunciar una ley o expresión general que indica cómo se escribe un número n cualquiera, no negativo, en una base b:

$$n = x_k \times b^k + \ldots + x_2 \times b^2 + x_1 \times b^1 + x_0 \times b^0$$

Esta ecuación puede escribirse más sintéticamente en notación de sumatoria como:

$$n = \sum_{i=0}^{k} x_i \times b^i$$

En estas ecuaciones (que son equivalentes):

- Los números  $x_i$  son las cifras del numeral.
- Los números  $b^i$  son potencias de la base, cuyos exponentes crecen de derecha a izquierda y comienzan por 0.
- Las potencias están ordenadas y completas, y son tantas como las cifras del numeral
- Los números  $x_i$  son necesariamente **menores que** b, ya que son dígitos en un sistema de numeración que tiene b dígitos.

#### Conversión de base

Veremos algunos casos interesantes de conversiones de base. Serán especialmente importantes los casos donde el número de origen o de destino de la conversión esté en base 10, nuestro sistema habitual, pero también nos dedicaremos a algunas conversiones de base donde ninguna de ellas sea 10.

#### Conversión de base 10 a otras bases

El procedimiento para convertir un número escrito en base 10 a cualquier otra base (llamémosla **base destino**) es siempre el mismo y se basa en la división entera (sin decimales):

- Dividir el número original por la base destino, anotando cociente y resto
- Mientras se pueda seguir dividiendo:
  - Volver al paso anterior reemplazando el número original por el nuevo cociente
- Finalmente escribimos los dígitos de nuestro número convertido usando el último cociente y todos los restos en orden inverso a como aparecieron.

Ésta es la expresión de nuestro número original en la base destino.

- Notemos que cada uno de los restos obtenidos es con toda seguridad menor que la base destino, ya que, en otro caso, podríamos haber seguido adelante con la división entera.
- Notemos también que el último cociente es también menor que la base destino, por el mismo motivo de antes (podríamos haber proseguido la división).
- Lo que acabamos de decir garantiza que tanto el último cociente, como todos los restos aparecidos en el proceso, pueden ser dígitos de un sistema en la base destino al ser todos menores que ella.

## Pregunta

¿Cómo podemos usar la Expresión General para explicar por qué este procedimiento es correcto, al menos para el caso de convertir **61 a base 3**?

#### Conversión de otras bases a base 10

La conversión en el sentido opuesto, de una base b cualquiera a base 10, se realiza simplemente aplicando la Expresión General. Cada uno de los dígitos del número original (ahora en base b arbitraria) es el coeficiente de alguna potencia de la base original. Esta potencia depende de la posición de dicho dígito. Una vez que escribimos todos los productos de los dígitos originales por las potencias de la base, hacemos la suma y nos queda el resultado: el número original convertido a base 10.

Es de la mayor importancia cuidar de que las potencias de la base que intervienen en el cálculo estén **ordenadas y completas**. Es fácil si escribimos estas potencias a partir de la derecha, comenzando por la que tiene exponente 0, y vamos completando los términos de derecha a izquierda hasta agotar las posiciones del número original.

#### **Preguntas**

¿Cómo sería un sistema de **contar con los dedos en base 2**? Dedo arriba = 1, dedo abajo = 0. . .

- ¿Cómo hacemos el 1, el 2, el 3...?
- ¿Hasta qué número podemos contar con una mano? ¿Y con dos manos?
- ¿Y cómo se indica el 4 en este sistema?

#### Conversión entre bases arbitrarias

Hemos visto los casos de conversión entre base 10 y otras bases, en ambos sentidos. Ahora veamos los casos donde ninguna de las bases origen o destino son la base 10.

La buena noticia es que, en general, **esto ya sabemos hacerlo**. Si tenemos dos bases  $b_1$  y  $b_2$  cualesquiera, ninguna de las cuales es 10, sabiendo hacer las conversiones anteriores podemos hacer la conversión de  $b_1$  a  $b_2$  sencillamente haciendo **dos conversiones pasando por la base 10**. Si queremos convertir de  $b_1$  a  $b_2$ , convertimos primero **de**  $b_1$  **a base 10**, aplicando el procedimiento ya visto, y luego **de base 10** a  $b_2$ . Eso es todo.

Pero en algunos casos especiales podemos aprovechar cierta relación existente entre las bases a convertir: por ejemplo, cuando son **2 y 16**, o **2 y 8**. La base 2 es la del sistema **binario**, y las bases 16 y 8 son las del sistema **hexadecimal** y del sistema **octal** respectivamente.

En estos casos, como 16 y 8 son potencias de 2 (la otra base), podemos aplicar un truco matemático para hacer la conversión en un solo paso y con muchísima facilidad. Por fortuna son estos casos especiales los que se presentan con mayor frecuencia en nuestra disciplina.

## Equivalencias entre sistemas

Para poder aplicar este truco se necesita la tabla de equivalencias entre los dígitos de los diferentes sistemas. Si no logramos memorizarla, conviene al menos saber reproducirla, asegurándose de saber **contar** en las bases 2, 8 y 16 para reconstruir la tabla si es necesario. Pero con la práctica, se logra memorizarla fácilmente.

#### Notemos que:

- El sistema octal tiene ocho dígitos (0 ... 7) y cada uno de ellos se puede representar con tres dígitos binarios:
  - 000
  - 001
  - 010
  - 011
  - 100
  - 101
  - 110
  - 111

#### Notemos que:

- El sistema hexadecimal tiene dieciséis dígitos (0 ... F) y cada uno de ellos se puede representar con cuatro dígitos binarios:
  - 0000
  - 0001
  - 0010

- 0011
- 0100
- 0101
- 0110
- 0111
- 1000
- 1001
- 1010
- 1011
- 1100
- 1101
- 1110
- 1111

### Conversión entre sistemas binario y hexadecimal

El truco para convertir de base 2 a base 16 consiste simplemente en agrupar los dígitos binarios de a cuatro, y reemplazar cada grupo de cuatro dígitos por su equivalente en base 16 según la tabla anterior.

Si hace falta completar un grupo de cuatro dígitos binarios, se completa con ceros a la izquierda.

Si el problema es convertir, inversamente, de base 16 a base 2, de igual forma reemplazamos cada dígito hexadecimal por los cuatro dígitos binarios que lo representan.

### Conversión entre sistemas binario y octal

El problema de convertir entre bases 2 y 8 es igual de sencillo. Basta con reemplazar cada grupo de **tres** dígitos binarios (completando con ceros a la izquierda si hace falta) por el dígito octal equivalente. Lo mismo si la conversión es en el otro sentido.

## Unidades de Información

En este segundo tema de la unidad veremos qué es la información y cómo podemos cuantificar, es decir, medir, la cantidad de información que puede alojar un dispositivo, o la cantidad de información que representa una pieza cualquiera de información. Veremos además las relaciones entre las diferentes unidades de información.

## Información

A lo largo de la historia se han inventado y fabricado máquinas, que son dispositivos que **transforman la energía**, es decir, convierten una forma de energía en otra. Las

computadoras, en cambio, convierten una forma de información en otra.

Los programas de computadora reciben alguna forma de información (la **entrada** del programa), la **procesan** de alguna manera, y emiten alguna información de **salida**. La **entrada** es un conjunto de datos de partida, para que trabaje el programa, y la **salida** generada por el programa es alguna forma de respuesta o solución a un problema. Sabemos, además, que el material con el cual trabajan las computadoras son textos, documentos, mensajes, imágenes, sonido, etc. Todas estas son formas en las que se codifica y se almacena la información.

Un epistemólogo dice que la información es "una diferencia relevante". Si vemos que el semáforo cambia de rojo a verde, recibimos información ("podemos avanzar"). Al cambiar el estado del semáforo aparece una **diferencia** que puedo observar. Es **relevante** porque modifica de alguna forma el estado de mi conocimiento o me permite tomar una decisión respecto de algo.

¿Qué es, exactamente, esta información? No podemos tocarla ni pesarla, pero ¿se puede medir? Y si se puede medir, ¿entonces se puede medir la cantidad de información que aporta un texto, una imagen?

#### Bit

La Teoría de la Información, una teoría matemática desarrollada alrededor de 1950, dice que el **bit** es "la mínima unidad de información". Un bit es la información que recibimos "cuando se especifica una de dos alternativas igualmente probables". Si tenemos una pregunta **binaria**, es decir, aquella que puede ser respondida **con un sí o con un no**, entonces, al recibir una respuesta, estamos recibiendo un bit de información. Las preguntas binarias son las más simples posibles (porque no podemos decidir entre **menos** respuestas), de ahí que la información necesaria para responderlas sea la mínima unidad de información.

De manera que un bit es una unidad de información que puede tomar sólo dos valores. Podemos pensar estos valores como **verdadero o falso**, como **sí o no**, o como 0 y 1.

Cuando las computadoras trabajan con piezas de información complejas, como los textos o imágenes, estas piezas son representadas como conjuntos ordenados de bits, de un cierto tamaño. Así, por ejemplo, la secuencia de ocho bits **0100001** puede representar la letra A mayúscula. Un documento estará constituido por palabras; éstas están formadas por símbolos como las letras, y éstas serán representadas por secuencias de bits.

La memoria de las computadoras está diseñada de forma que **no se puede almacenar otra cosa que bits** en esa memoria. Los textos, las imágenes, los sonidos, los videos, los programas que ejecuta, los mensajes que recibe o envía; todo lo que puede guardar, procesar, o emitir una computadora digital, debe estar en algún momento representado por una secuencia de bits. Los bits son, en cierta forma, como los

átomos de la información. Por eso el bit es la unidad fundamental que usamos para medirla, y definiremos también algunas unidades mayores, o múltiplos.

## El viaje de un bit

En una famosa película de aventuras hay una ciudad en problemas. Uno de los héroes enciende una pila de leña porque se prepara un terrible ataque sobre la ciudad. La pila de leña es el dispositivo preestablecido que tiene la ciudad para pedir ayuda en caso de emergencia.

En la cima de la montaña que está cruzando el valle existe un puesto similar, con su propio montón de leña, y un vigía. El vigía ve el fuego encendido en la ciudad que pide ayuda, y a su vez enciende su señal. Lo mismo se repite de cumbre en cumbre, atravesando grandes distancias en muy poco tiempo, hasta llegar rápidamente a quienes están en condiciones de prestar la ayuda. En una tragedia griega se dice que este ingenioso dispositivo se utilizó en la realidad, para comunicar en tan sólo una noche la noticia de la caída de Troya.

La información que está transportando la señal que viaja es la respuesta a una pregunta muy sencilla: "¡la ciudad necesita nuestra ayuda?".

Esta pregunta es **binaria**: se responde con un sí o con un no. Por lo tanto, lo que ha viajado es **un bit de información**.

Notemos que, en los manuales de lógica o de informática, encontraremos siempre asociados los **bits** con los valores de **0 y 1**. Aunque esto es útil a los efectos de emplear los bits en computación, no es del todo exacto. Un bit no es exactamente un dígito. Lo que viajó desde la ciudad sitiada hasta su destino no es un 0 ni un 1. Es **un bit de información**, aquella unidad de información que permite tomar una decisión entre dos alternativas. Sin embargo, la identificación de los bits con los dígitos binarios es útil para todo lo que tiene que ver con las computadoras.

## Byte

Como el bit es una medida tan pequeña de información, resulta necesario definir unidades más grandes. En particular, y debido a la forma como se organiza la memoria de las computadoras, es útil tener como unidad al **byte** (abreviado **B** mayúscula), que es una secuencia de **8 bits**. Podemos imaginarnos la memoria de las computadoras como una estantería muy alta, compuesta por estantes que contienen ocho casilleros. Cada uno de estos estantes es una **posición o celda de memoria**, y contiene exactamente ocho bits (un byte) de información.

Como los valores de los bits que forman un byte son independientes entre sí, existen  $2^8$  diferentes valores para esos ocho bits. Si los asociamos con números en el sistema binario, esos valores serán 00000000, 00000001, 00000010, ..., etc., hasta el 11111111. En decimal, esos valores corresponden a los números 0, 1, 2, ..., 255.

Cada byte de la memoria de una computadora, entonces, puede alojar un número entre 0 y 255. Esos números representarán diferentes piezas de información: si los vemos como bytes independientes, pueden representar **caracteres** como letras y otros símbolos, pero también pueden estar formando parte de otras estructuras de información más complejas, y tener otros significados.

## Representando datos con bytes

Para poder tratar y comunicar la información, que está organizada en bytes, es necesario que exista una asignación fija de valores binarios a caracteres. Es decir, se necesita una **tabla de caracteres** que asigne un símbolo a cada valor posible entre 0 y 255.

La memoria de la computadora es como un espacio donde se almacenan temporariamente contenidos del tamaño de un byte. Si pudiéramos ver el contenido de una sección de la memoria mientras la computadora está trabajando, veríamos que cada byte tiene determinados contenidos binarios. Esos contenidos pueden codificar los caracteres de un mensaje, carácter por carácter.

Sabiendo que la memoria está organizada en bytes, es interesante saber qué capacidad tendrá la memoria de una computadora dada y qué tamaño tendrán las piezas de información que caben en esta memoria. Como la memoria de una computadora, y la cantidad de información que compone un mensaje, un programa, una imagen, etc., suelen ser muy grandes, utilizamos **múltiplos** de la unidad de memoria, que es el byte.

Existen en realidad dos sistemas diferentes de múltiplos: el **Sistema Internacional** y el **Sistema de Prefijos Binarios**. Las unidades de ambos sistemas son parecidas, pero no exactamente iguales.

Los dos sistemas difieren esencialmente en el factor de la unidad en los sucesivos múltiplos. En el caso del Sistema Internacional, todos los factores son alguna potencia de 1000. En el caso del Sistema de Prefijos Binarios, todos los factores son potencias de 1024.

#### Sistema Internacional

En el llamado Sistema Internacional, la unidad básica, el byte, se multiplica por potencias de 1000. Así, tenemos:

- El kilobyte (1000 bytes)
- El **megabyte** ( $1000 \times 1000$  bytes = 1000 kilobytes = un millón de bytes)
- El **gigabyte** ( $1000 \times 1000 \times 1000$  bytes = mil megabytes = mil millones de bytes)

El terabyte (1000 × 1000 × 1000 × 1000 bytes = mil gigabytes = un billón de bytes), y otros múltiplos mayores como petabyte, exabyte, zettabyte, vottabyte.

Como puede verse, cada unidad se forma multiplicando la anterior por 1000.

Los símbolos de cada múltiplo, utilizados al especificar las unidades, son **k minúscula** para **kilo**, **M mayúscula** para **mega**, **G mayúscula** para **giga**, **T mayúscula** para **tera**, etc.

#### Sistema de Prefijos Binarios

En el llamado Sistema de Prefijos Binarios, el byte se multiplica por potencias de  $2^{10}$ , que es 1024. Así, tenemos:

- El kibibyte (1024 bytes)
- El **mebibyte** (1024 × 1024 bytes, **aproximadamente** un millón de bytes, pero exactamente 1048576 bytes)
- El gibibyte (1024 × 1024 × 1024 bytes, aproximadamente mil millones de bytes)
- El **tebibyte** (1024 × 1024 × 1024 × 1024 bytes, aproximadamente un millón de mebibytes, o aproximadamente un billón de bytes), y otros múltiplos mayores como **pebibyte**, **exbibyte**, **zebibyte**, **yobibyte**.

Como puede verse, cada unidad se forma multiplicando la anterior por 1024.

Notemos que los prefijos **kilo, mega, giga, tera**, del Sistema Internacional, cambian a **kibi, mebi, gibi, tebi**, del sistema de Prefijos Binarios.

Los símbolos de cada múltiplo, utilizados al especificar las unidades, son **Ki**, con K mayúscula, para **kibi**, **Mi** para **mebi**, **Gi** para **gibi**, **Ti** para **tebi**, etc.

¿Por qué existen **dos** sistemas en lugar de uno? En realidad la adopción del Sistema de Prefijos Binarios se debe a las características de la memoria de las computadoras:

- Cada posición o celda de la memoria tiene su dirección, que es el número de la posición de esa celda dentro del conjunto de toda la memoria de la computadora.
- Cuando la computadora accede a una posición o celda de su memoria, para leer o escribir un contenido en esa posición, debe especificar la dirección de la celda.
- Como la computadora usa exclusivamente números binarios, al especificar la dirección de la celda usa una cantidad de dígitos binarios.
- Por lo tanto, la cantidad de posiciones que puede acceder usando direcciones es una potencia de 2: si usa 8 bits para especificar cada dirección, accederá a 2<sup>8</sup> bytes, cuyas direcciones estarán entre 0 y 255. Si usa 10 bits, accederá a 2<sup>10</sup> bytes, cuyas direcciones serán 0 a 1023.

- Entonces, tener una memoria de, por ejemplo, exactamente mil bytes, complicaría técnicamente las cosas porque las direcciones 1000 a 1023 no existirían. Si un programa quisiera acceder a la posición 1020 habría un grave problema. Habría que tener en cuenta excepciones por todos lados y la vida de los diseñadores de computadoras y de los programadores sería lamentable.
- En consecuencia, todas las memorias se fabrican en tamaños que son potencias de 2 y el Sistema de Prefijos Binarios se adapta perfectamente a medir esos tamaños.

En computación se utilizan, en diferentes situaciones, ambos sistemas de unidades. Es costumbre usar el Sistema Internacional para hablar de velocidades de transmisión de datos o tamaños de archivos, pero usar Prefijos Binarios al hablar de almacenamiento de memoria, o en unidades de almacenamiento permanente, como los discos.

- Entonces, cuando un proveedor de servicios de Internet ofrece un enlace de 1
   Mbps, nos está diciendo que por ese enlace podremos transferir exactamente
   1 millón de bits por segundo. El proveedor utiliza el Sistema Internacional.
- Los textos, imágenes, sonido, video, programas, etc., se guardan en **archivos**, que son sucesiones de bytes. Encontramos archivos en el disco de nuestra computadora, y podemos descargar archivos desde las redes. Cuando nos interesa saber cuánto mide un archivo, en términos de bytes, usamos el Sistema Internacional porque el archivo no tiene por qué tener un tamaño que sea potencia de 2.
- Por el contrario, los fabricantes de medios de almacenamiento, como memorias, discos rígidos o pendrives, deberían (aunque a veces no lo hacen) utilizar Prefijos Binarios para expresar las capacidades de almacenamiento de esos medios. Así, un "pendrive de dieciséis gigabytes", si tiene una capacidad de  $16 \times 2^{30}$  bytes, debería publicitarse en realidad como "pendrive de dieciséis gibibytes".

## Representación de la Información

Veremos de qué manera puede ser tratada mediante computadoras la información correspondiente a números, textos, imágenes y otros datos. Necesitaremos conocer las formas de representación de datos, y comenzaremos por los datos numéricos.

## Representación de datos numéricos

Hemos visto ejemplos de sistemas de numeración: en base 6, en base 10, o decimal, en base 2, o binario, en base 16, o hexadecimal, y en base 8, u octal; y sabemos convertir la representación de un número en cada una de estas bases, a los sistemas en las demás bases. Sin embargo, aún nos falta considerar la representación numérica de varios casos importantes:

- Hemos utilizado estos sistemas para representar únicamente números enteros.
   Nos falta ver de qué manera representar números racionales, es decir aquellos que tienen una parte fraccionaria (los "decimales").
- Además estos enteros han sido siempre no negativos, es decir, sabemos representar únicamente el 0 y los naturales. Nos falta considerar los negativos.
- Por otra parte, no nos hemos planteado el problema de la cantidad de dígitos. Idealmente, un sistema de numeración puede usar infinitos dígitos para representar números arbitrariamente grandes. Si bien esto es matemáticamente correcto, las computadoras son objetos físicos que tienen unas ciertas limitaciones, y con ellas no es posible representar números de infinita cantidad de dígitos.

En esta parte de la unidad mostraremos sistemas de representación utilizados en computación que permiten tratar estos problemas.

#### Clasificación de los números

Es conveniente repasar la clasificación de los diferentes conjuntos de números y conocer las diferencias importantes entre éstos. Los títulos en el cuadro (tomado de Wikipedia) son referencias a los artículos enciclopédicos sobre cada uno de esos conjuntos.

- Números complejos
- Complejos
- Reales
- Racionales
- Enteros
- Naturales
- Uno
- Naturales primos
- Naturales compuestos
- Cero
- Enteros negativos
- Fraccionarios
- Fracción propia
- Fracción impropia
- Irracionales
- Irracionales algebraicos
- Trascendentes
- Imaginarios

### **Preguntas**

- El cero, ¿es un natural?
- ¿Existen números naturales negativos? ¿Y racionales negativos?
- ¿Es correcto decir que un racional tiene una parte decimal que es, o bien finita, o bien periódica?
- ¿Puede haber dos expresiones diferentes para el mismo número, en el mismo sistema de numeración decimal?
- El número 0.9999... con 9 periódico, y el número 1, ¿son dos números diferentes o el mismo número? Si son diferentes, ¿qué número se encuentra entre ellos dos?
- El número 1 es a la vez natural y entero. ¿Por qué no puede haber un número que sea a la vez racional e irracional?
- ¿Por qué jamás podremos computar la sucesión completa de decimales de  $\pi$ ?

#### **Datos enteros**

Veremos un sistema de representación de datos no negativos, llamado **sin signo**, y tres sistemas de representación de datos numéricos enteros, llamados **signo-magnitud**, **complemento a 2** y **notación en exceso**.

#### **Datos fraccionarios**

Para representar fraccionarios consideraremos los sistemas de **punto fijo** y **punto flotante**.

## Rango de representación

Cada sistema de representación de datos numéricos tiene su propio **rango de representación** (que podemos abreviar **RR**), o intervalo de números representables. Ningún número fuera de este rango puede ser representado en dicho sistema. Conocer este intervalo es importante para saber con qué limitaciones puede enfrentarse un programa que utilice alguno de esos sistemas.

El rango de los números representados bajo un sistema está dado por sus **límites inferior y superior**, que definen qué zona de la recta numérica puede ser representada. Como ocurre con todo intervalo numérico cerrado, el rango de representación puede ser escrito como [a,b], donde a y b son sus límites inferior y superior, respectivamente.

Por la forma en que están diseñados, algunos sistemas de representación sólo pueden representar números muy pequeños, o sólo positivos, o tanto negativos como positivos. En general, el RR **será más grande cuantos más dígitos binarios**, o bits, tenga el sistema. Sin embargo, el RR depende también de la forma como el sistema **utilice** esos dígitos binarios, ya que un sistema puede ser más o menos **eficiente** que otro en el uso de esos dígitos, aunque la cantidad de dígitos sea la misma en ambos sistemas.

Por lo tanto, decimos que el rango de representación depende a la vez de la **cantidad de dígitos** y de la **forma de funcionamiento** del sistema de representación.

## Representación sin signo SS(k)

Consideremos primero qué ocurre cuando queremos representar números enteros **no negativos** (es decir, **positivos o cero**) sobre una cantidad fija de bits.

En el sistema **sin signo**, simplemente usamos el sistema binario de numeración, tal como lo conocemos, **pero limitándonos a una cantidad fija** de dígitos binarios o bits. Podemos entonces abreviar el nombre de este sistema como SS(k), donde k es la cantidad fija de bits, o ancho, de cada número representado.

#### Rango de representación de SS(k)

¿Cuál será el rango de representación? El **cero** puede representarse, así que el límite inferior del rango de representación será 0. Pero ¿cuál será el límite superior? Es decir, si la cantidad de dígitos binarios en este sistema es k, ¿cuál es el número más grande que podremos representar?

Podemos estudiarlo de dos maneras.

#### 1. Usando combinatoria

Contemos cuántos números diferentes podemos escribir con k dígitos binarios. Imaginemos un número binario cualquiera con k dígitos. El dígito de más a la derecha tiene únicamente dos posibilidades (0 o 1). Por cada una de éstas hay nuevamente dos posibilidades para el siguiente hacia la izquierda (lo que da las cuatro posibilidades 00, 01, 10, 11). Por cada una de éstas, hay dos posibilidades para el siguiente (dando las ocho posibilidades 000, 001, 010, 011, 100, 101, 110, 111), etc., y así hasta la posición k. No hay más posibilidades. Como hemos multiplicado 2 por sí mismo k veces, la cantidad de números que se pueden escribir es  $2^k$ . Luego, el número más grande posible es  $2^k-1$ . (**Pregunta**: ¿Por qué  $2^k-1$  y no  $2^k$ ?).

## 2. Usando álgebra

El número más grande que podemos representar en un sistema sin signo a k dígitos es, seguramente, aquel donde todos los k dígitos valen 1. La Expresión General que hemos visto nos dice que si un número n está escrito en base 2, **con** k **dígitos**, entonces

$$n = x_{k-1} \times 2^{k-1} + \dots + x_1 \times 2^1 + x_0 \times 2^0$$

y, si queremos escribir el más grande de todos, deberán ser todos los  $x_i$  iguales a 1. (**Pregunta**: ¿Por qué si el número n tiene k dígitos binarios, el índice del más significativo es k-1 y no k?)

Esta suma vale entonces

$$x_{k-1} \times 2^{k-1} + \dots + x_1 \times 2^1 + x_0 \times 2^0 =$$

$$= 1 \times 2^{k-1} + \dots + 1 \times 2^1 + 1 \times 2^0 =$$

$$= 2^{k-1} + \dots + 2^1 + 2^0 =$$

$$= 2^k - 1$$

Usando ambos argumentos hemos llegado a que el número más grande que podemos representar con k dígitos binarios es  $2^k-1$ . Por lo tanto, **el rango de representación de un sistema sin signo a** k **dígitos, o SS(k), es**  $[0,2^k-1]$ . Todos los números representables en esta clase de sistemas son **positivos o cero**.

## **Ejemplos**

■ Para un sistema de representación sin signo a 8 bits:  $[0, 2^8 - 1] = [0, 255]$ 

• Con 16 bits:  $[0, 2^{16} - 1] = [0, 65, 535]$ 

• Con 32 bits:  $[0, 2^{32} - 1] = [0, 4,294,967,295]$ 

## Representación con signo

En la vida diaria manejamos continuamente números negativos, y los distinguimos de los positivos simplemente agregando un signo "menos". Representar esos datos en la memoria de la computadora no es tan directo, porque, como hemos visto, la memoria solamente puede alojar ceros y unos. Es decir, ¡no podemos simplemente guardar un signo "menos"! Lo único que podemos hacer es almacenar secuencias de ceros y unos.

Esto no era un problema cuando los números eran no negativos. Para poder representar, ahora, tanto números **positivos como negativos**, necesitamos cambiar la forma de representación. Esto quiere decir que una secuencia particular de dígitos binarios, que en un sistema sin signo tiene un cierto significado, ahora tendrá un significado diferente. Algunas secuencias, que antes representaban números positivos, ahora representarán negativos.

Veremos los sistemas de representación con signo llamados Signo-magnitud (SM), Complemento a 2 (C2) y Notación en exceso.

Es importante tener en cuenta que solamente se puede operar entre datos representados con el mismo sistema de representación, y que el resultado de toda operación vuelve a estar representado en el mismo sistema.

## **Preguntas**

¿Cuáles son los límites del rango de representación de un sistema de representación numérica?

- Un número escrito en un sistema de representación con signo, ¿es siempre negativo?
- ¿Para qué querríamos escribir un número positivo en un sistema de representación con signo?

## Sistema de Signo-magnitud SM(k)

El sistema de **Signo-magnitud** no es el más utilizado en la práctica, pero es el más sencillo de comprender. Se trata simplemente de utilizar un bit (el de más a la izquierda) para representar el **signo**. Si este bit tiene valor 0, el número representado es positivo; si es 1, es negativo. Los demás bits se utilizan para representar la **magnitud**, es decir, el **valor absoluto** del número en cuestión.

## **Ejemplos**

 $7_{(10} = 00000111_{(2)$   $-7_{(10} = 10000111_{(2) }$ 

Como estamos reservando un bit para expresar el signo, ese bit ya no se puede usar para representar magnitud; y como el sistema tiene una cantidad de bits fija, el RR ya no podrá representar el número máximo que era posible con el sistema **sin signo**.

#### Rango de representación de SM(k)

- En todo número escrito en el sistema de signo-magnitud a k bits, ya sea positivo o negativo, hay un bit reservado para el signo, lo que implica que quedan k-1 bits para representar su valor absoluto.
- Siendo un valor absoluto, estos k-1 bits representan un número **no negativo**. Además este número está representado con el sistema **sin signo** sobre k-1 bits, es decir, SS(k-1).
- Este número no negativo en SS(k-1) tendrá un valor máximo representable que coincide con el **límite superior** del rango de representación **de SS(k-1)**.
- Sabemos que el rango de representación de SS(k) es  $[0, 2^k 1]$ . Por lo tanto, el rango de SS(k-1), reemplazando, será  $[0, 2^{k-1} 1]$ .
- Esto quiere decir que el número representable en SM(k) cuyo valor absoluto es máximo, es  $2^{k-1} 1$ . Por lo tanto éste es el límite superior del rango de representación de SM(k).
- Pero en SM(k) también se puede representar su opuesto negativo, simplemente cambiando el bit más alto por 1. El opuesto del máximo positivo representable es a su vez el número más pequeño, negativo, representable:  $-(2^{k-1}-1)$ .

Con lo cual hemos calculado tanto el límite inferior como el superior del rango de representación de SM(k), que, finalmente, es  $[-(2^{k-1}-1),2^{k-1}-1]$ .

## Limitaciones de Signo-Magnitud

Si bien **SM(k)** es simple, no es tan efectivo, por varias razones:

- Existen dos representaciones del 0 ("positiva" y "negativa"), lo cual desperdicia un representante.
- Esto acorta el rango de representación.
- La aritmética en SM no es fácil, ya que cada operación debe comenzar por averiguar si los operandos son positivos o negativos, operar con los valores absolutos y ajustar el resultado de acuerdo al signo reconocido anteriormente.
- El problema aritmético se agrava con la existencia de las dos representaciones del cero: cada vez que un programa quisiera comparar un valor resultado de un cómputo con 0, debería hacer dos comparaciones.

Por estos motivos, el sistema de SM dejó de usarse y se diseñó un sistema que eliminó estos problemas, el sistema de **complemento a 2**.

## Sistema de Complemento a 2

Para comprender el sistema de complemento a 2 es necesario primero conocer la **operación** de complementar a 2.

## Operación de Complemento a 2

La **operación** de complementar a 2 consiste aritméticamente en obtener el **opuesto** de un número (el que tiene el mismo valor absoluto pero signo opuesto).

Para obtener el complemento a 2 de un número escrito en base 2, se invierte cada uno de los bits (reemplazando 0 por 1 y viceversa) y al resultado se le suma 1.

#### Otra forma

Otro modo de calcular el complemento a 2 de un número en base 2 es copiar los bits, desde la derecha, hasta el primer 1 inclusive; e invertir todos los demás a la izquierda.

#### Propiedad fundamental

El resultado de esta operación, C2(a), es el opuesto del número original a, y por lo tanto tiene la propiedad de que a y C2(a) suman 0:

$$C2(a) + a = 0$$

#### Comprobación

Podemos comprobar si la complementación fue bien hecha aplicando la **propiedad fundamental** del complemento. Si, al sumar nuestro resultado con el número original, no obtenemos 0, corresponde revisar la operación.

#### **Ejemplos**

- Busquemos el complemento a 2 de 111010. Invirtiendo todos los bits, obtenemos 000101. Sumando 1, queda 000110.
- Busquemos el complemento a 2 de 0011. Invirtiendo todos los bits, obtenemos 1100. Sumando 1, queda 1101.
- Comprobemos que el resultado obtenido en el último caso, 1101, es efectivamente el opuesto de 0011: 0011 + 1101 = 0.

#### Representación en Complemento a 2

Ahora que contamos con la **operación de complementar a 2**, podemos ver cómo se construye el **sistema de representación en Complemento a 2**.

Para representar un número a en complemento a 2 a k bits, comenzamos por considerar su signo:

- Si a es positivo o cero, lo representamos como en SM(k), es decir, lo escribimos en base 2 a k bits.
- Si a es negativo, tomamos su valor absoluto y lo complementamos a 2.

### **Ejemplos**

- Representemos el número 17 en complemento a 2 con 8 bits. Como es positivo, lo escribimos en base 2, obteniendo 00010001, que es 17 en notación complemento a 2 con 8 bits.
- Representemos el número -17 en complemento a 2 con 8 bits. Como es negativo, escribimos su valor absoluto en base 2, que es 00010001, y lo complementamos a 2. El resultado final es 11101111 que es -17 en notación complemento a 2 con 8 bits.

#### Conversión de C2 a base 10

Para convertir un número n, escrito en el sistema de complemento a 2, a decimal, lo primero es determinar el signo. Si el bit más alto es 1, n es negativo. En otro caso, n es positivo. Utilizaremos esta información enseguida.

Si n es positivo, se interpreta el número como en el sistema sin signo, es decir, se utiliza la Expresión General para hacer la conversión de base como normalmente. Si n es negativo, se lo complementa a 2, obteniendo el opuesto de n. Este número, que ahora es positivo, se convierte a base 10 como en el caso anterior; y finalmente se le agrega el signo "-" para reflejar el hecho de que es negativo.

#### **Ejemplos**

- Convertir a decimal n=00010001. Es positivo, luego, aplicamos la Expresión General dando  $17_{(10)}$ .
- Convertir a decimal n=11101111. Es negativo; luego, lo complementamos a 2 obteniendo 00010001. Aplicamos la Expresión General obteniendo  $17_{(10)}$ . Como n era negativo, agregamos el signo menos y obtenemos el resultado final  $-17_{(10)}$ .

#### RR de C2 con k bits

La forma de utilizar los bits en el sistema de complemento a 2 permite recuperar un representante que estaba desperdiciado en SM.

El rango de representación del sistema complemento a 2 sobre k bits es  $[-(2^{k-1}), 2^{k-1}-1]$ . El límite superior del RR de C2 es el mismo que el de SM, pero el **límite inferior** es menor; luego el RR de C2 es mayor que el de SM.

El sistema de complemento a 2 tiene otras ventajas sobre SM:

- El cero tiene una única representación, lo que facilita las comparaciones.
- Las cuentas se hacen bit a bit, en lugar de requerir comprobaciones de signo.
- El mecanismo de cálculo es eficiente y fácil de implementar en hardware.
- Solamente se requiere diseñar un algoritmo para sumar, no uno para sumar y otro para restar.

#### Comparando rangos de representación

Diferentes sistemas, entonces, tienen diferentes rangos de representación. Si construimos un cuadro donde podamos comparar los rangos de representación **sin signo, signo-magnitud y complemento a 2** para una misma cantidad de bits, veremos que todas las combinaciones de bits están utilizadas, sólo que de diferente forma.

El cuadro comparativo para cuatro bits mostrará que las combinaciones 0000...1111 representan los primeros 16 números no negativos para el sistema sin signo, mientras que esas mismas combinaciones tienen otro significado en los sistemas con signo. En éstos últimos, una misma combinación con el bit más significativo en 1 siempre es negativa, pero el orden en que aparecen esas combinaciones es diferente entre SM y C2.

Por otro lado, los números positivos quedan representados por combinaciones idénticas en los tres sistemas, hasta donde lo permite el rango de representación de cada uno.

Si descartamos el bit de signo y consideramos sólo las magnitudes, los números negativos en SM aparecen con sus magnitudes crecientes alejándose del 0, mientras que en C2 esas magnitudes comienzan en cero al representar el negativo más pequeño posible y crecen a medida que se acercan al cero.

#### Aritmética en C2

Una gran ventaja que aporta el sistema en Complemento a 2 es que los diseñadores de hardware no necesitan implementar algoritmos de resta además de los de la suma. Cuando se necesita efectuar una resta, **se complementa el sustraendo** y luego se lo **suma** al minuendo. Las computadoras no restan: siempre suman.

Por ejemplo, la operación 9-8 se realiza como 9+(-8), donde (-8) es el complemento a 2 de 8.

#### **Preguntas**

- Un número en complemento a 2, ¿tiene siempre su bit más a la izquierda en 1?
- El complemento a 2 de un número, es decir, C2(x), ¿es siempre un número negativo?
- ¿Quién es **C2(0)**?
- ¿Cuánto vale C2(C2(x))? Es decir, ¿qué pasa si complemento a 2 el complemento a 2 de x?
- ¿Cuánto vale x + C2(x)? Es decir, ¿qué pasa si sumo a x su propio complemento a 2?
- ¿Cómo puedo verificar si calculé correctamente un complemento a 2?

## Overflow o desbordamiento en C2

En todo sistema de ancho fijo, la suma de **dos números positivos, o de dos números negativos** puede dar un resultado que sea imposible de representar debido a las limitaciones del rango de representación. Este problema se conoce como desbordamiento, u *overflow*. Cuando ocurre una situación de overflow, el resultado de la operación **no es válido** y debe ser descartado.

Si conocemos los valores en decimal de dos números que queremos sumar, usando nuestro conocimiento del rango de representación del sistema podemos saber si el resultado quedará dentro de ese rango, y así sabemos, de antemano, si ese resultado será válido. Pero las computadoras no tienen forma de conocer a priori esta condición, ya que todo lo que tienen es la representación en C2 de ambos números. Por eso

necesitan alguna forma de detectar las situaciones de overflow, y el modo más fácil para ellas es comprobar los dos últimos bits de la fila de bits de acarreo o *carry*.

El último bit de la fila de carry, el que se posiciona en la última de las k columnas de la representación, se llama *carry-in*. El siguiente bit de carry, el que ya no puede acarrearse sobre ningún dígito válido porque se han rebasado los k dígitos de la representación, se llama el *carry-out*.

- Si, luego de efectuar una suma en C2, los valores de los bits de carry-in y carry-out son iguales, entonces la computadora detecta que el resultado no ha desbordado y que la suma es válida. La operación de suma se ha efectuado exitosamente.
- Si, luego de efectuar una suma en C2, los valores de los bits de carry-in y carry-out son diferentes, entonces la computadora detecta que el resultado ha desbordado y que la suma no es válida. La operación de suma no se ha llevado a cabo exitosamente, y el resultado debe ser descartado.

#### Suma sin overflow

Siguiendo atentamente la secuencia de bits de carry podemos detectar, igual que lo hace la computadora, si se producirá un desbordamiento. En el caso de la operación 23+(-9), el resultado (que es 14) cae dentro del rango de representación, y esto se refleja en los bits de *carry-in* y de *carry-out*, cuyos valores son iguales.

#### Suma con overflow

En el caso de la operación 123+9 en C2 a 8 bits, el resultado (que es 132) cae fuera del rango de representación. Esto se refleja en los bits de *carry-in* y de *carry-out*, que son diferentes. El resultado no es válido y debe ser descartado.

## **Preguntas**

- ¿Qué condición sobre los bits de carry permite asegurar que no habrá overflow?
- ¿Para qué sistemas de representación numérica usamos la condición de detección de overflow?
- ¿Puede existir overflow al sumar dos números de diferente signo?
- ¿Qué condición sobre los bits de signo de los operandos permite asegurar que no habrá overflow?
- ¿Puede haber casos de overflow al sumar dos números negativos?
- ¿Puede haber casos de overflow al restar dos números?

## Extensión de signo en C2

Para poder efectuar una suma de dos números, ambos operandos deben estar representados en el mismo sistema de representación.

- Una suma de dos operandos donde uno esté, por ejemplo, en SM y el otro en C2, no tiene sentido aritmético.
- Además, la cantidad de bits de representación debe ser la misma.

En una suma en C2, si uno de los operandos estuviera expresado en un sistema con menos bits que el otro, será necesario convertirlo al sistema del otro (**extenderlo**) y operar con ambos en ese sistema de mayor ancho.

Si el operando en el sistema de menor ancho es positivo, la extensión se realiza simplemente **completando con ceros a la izquierda** hasta obtener la cantidad de dígitos del otro sistema. Si el operando del menor ancho es negativo, la extensión de signo se hace **agregando unos**.

## **Ejemplos**

- $A + B = 00101011_{(2)} + 00101_{(2)}$ 
  - ullet A está en  $C_2^8$  y B en  $C_2^5 
    ightarrow {
    m Ilevar}$  ambos a  $C_2^8$
  - Se completa B (positivo) como  $00000101_{(2)}$
- $A + B = 1010_{(2} + 0110100_{(2)}$ 
  - ullet A está en  $C_2^4$  y B en  $C_2^7 
    ightarrow {
    m Ilevar}$  ambos a  $C_2^7$
  - Se completa A (negativo) como 1111010<sub>(2)</sub>

#### Notación en exceso o bias

En un sistema de notación en exceso, se elige un intervalo [a,b] de enteros a representar, y todos los valores dentro del intervalo se representan con una secuencia de bits de la misma longitud.

La cantidad de bits deberá ser la necesaria para representar todos los enteros del intervalo, inclusive los límites, y por lo tanto estará en función de la longitud del intervalo. Un intervalo [a,b] de enteros, con sus límites incluidos, comprende exactamente n=b-a+1 valores. Esta longitud del intervalo debe ser cubierta con una cantidad k de bits suficiente, lo cual obliga a que  $2^k \geq n$ . Supongamos que n sea una potencia de 2 para facilitar las ideas, de forma que  $2^k = n$ .

Las  $2^k$  secuencias de k bits, ordenadas como de costumbre según su valor aritmético, se aplican a los enteros en [a,b], uno por uno. Es decir, si usamos 3 bits, las secuencias serán 000, 001, 010, ... hasta 111; y los valores representados serán respectivamente:

- 000 = a
- 001 = a + 1
- 1010 = a + 2
- **.** . . .

■ 111 = *b* 

Notemos que tanto a como b pueden ser **negativos**. Así podemos representar intervalos de enteros arbitrarios con secuencias de k bits, lo que nos vuelve a dar un sistema de representación con signo.

Con este método no es necesario que el bit de orden más alto represente el signo. Tampoco que el intervalo contenga la misma cantidad de números negativos que positivos o cero, aunque para la mayoría de las aplicaciones es lo más razonable.

El sistema en exceso se utiliza como componente de otro sistema de representación más complejo, la representación en punto flotante.

#### Conversión entre exceso y decimal

Una vez establecido un sistema en exceso que representa el intervalo [a, b] en k bits:

- Para calcular la secuencia binaria que corresponde a un valor decimal d, a d le restamos a y luego convertimos el resultado (que será no negativo) a SS(k), es decir, a binario sin signo sobre k bits.
- Para calcular el valor decimal d representado por una secuencia binaria, convertimos la secuencia a decimal como en SS(k), y al resultado (que será no negativo) le sumamos el valor de a.

#### **Ejemplos**

Representemos en sistema en exceso el intervalo [10,25] (que contiene 25-10+1=16 enteros). Como necesitamos 16 secuencias binarias, usaremos 4 bits que producirán las secuencias 0000, 0001, ..., 1111.

- Para calcular la secuencia que corresponde al número 20, hacemos 20-10=10 y el resultado será la secuencia **1010**.
- Para calcular el valor decimal que está representando la secuencia **1011**, convertimos 1011 a decimal, que es 11, y le sumamos 10; el resultado es 21.

Representemos en sistema en exceso el intervalo [-3,4] (que contiene 4-(-3)+1=8 enteros). Como necesitamos 8 secuencias binarias, usaremos 3 bits que producirán las secuencias 000, 001, ..., 111.

- Para calcular la secuencia que corresponde al número 2, hacemos 2-(-3)=5 y el resultado será la secuencia **101**.
- Para calcular el valor decimal que está representando la secuencia 011, convertimos 011 a decimal, que es 3, y le sumamos -3; el resultado es 0.

## Preguntas sobre Notación en Exceso

- Dado un valor decimal a representar, ¿cómo calculamos el binario?
- Dado un binario, ¿cómo calculamos el valor decimal representado?
- El sistema en exceso ¿destina un bit para representar el signo?
- ¿Se puede representar un intervalo que no contenga el cero?
- ¿Cómo se comparan dos números en exceso para saber cuál es el mayor?

## Representación de fraccionarios

#### Racionales

Los números fraccionarios son aquellos **racionales** que no son enteros. Se escriben como una razón, fracción o cociente de dos enteros. Por ejemplo, 3/4 y -12/5 son números fraccionarios. El signo de división que usamos para escribir las fracciones tiene precisamente ese significado aritmético: si hacemos la operación de división correspondiente entre numerador y divisor de la fracción, obtenemos la forma decimal del mismo número, con **una parte entera y una parte decimal**. Así, por ejemplo, 3/4 también puede escribirse como 0.75, y -12/5 como -2.4. Estas dos formas son equivalentes. En los racionales, la parte decimal es **finita** o **periódica**.

#### Aproximación racional a los irracionales

Por otro lado, existen números reales que no son racionales, en el sentido de que no existe una razón, fracción o cociente que les sea igual, pero también pueden escribirse como decimales con una parte entera y una parte decimal. Estos son los **irracionales**. Los irracionales pueden expresarse sintéticamente como el resultado de alguna operación (como cuando escribimos  $\sqrt{2}$ ) o en su forma decimal. Sin embargo, tienen la característica de que su desarrollo decimal **es infinito** no periódico, por lo cual siempre que escribimos un irracional por su desarrollo decimal, en realidad estamos **truncando** ese desarrollo a alguna porción inicial. Jamás podremos escribir la sucesión completa de decimales.

De manera que, al escribir irracionales en su forma decimal, en realidad siempre tratamos con **aproximaciones racionales** a esos irracionales. Por ejemplo, 3.14 y 3.1459 son aproximaciones racionales al verdadero valor irracional de  $\pi$ , cuya parte decimal tiene infinitos dígitos.

#### Coma o punto decimal

Al escribir un número con cifras decimales en nuestro sistema numérico habitual de base 10, usamos una marca especial para separar la parte entera de la decimal: es la **coma o punto decimal**. En el desarrollo decimal, la coma o punto decimal señala el lugar donde los exponentes de la base en el desarrollo de potencias de 10 **se hacen negativos**. Cuando queremos representar números fraccionarios con computadoras, nos vemos en el problema de representar este signo especial.

Podemos trasladar la idea de coma o punto decimal al sistema binario. Si extendemos la Expresión General con exponentes negativos, podemos escribir números fraccionarios en base 2.

#### Fraccionario en base 2 a decimal

Si encontramos una expresión como  $11{,}101_{(2)}$ , la Expresión General extendida nos dice cómo obtener su valor en base 10:

$$11,101_{(2} =$$

$$1 \times 2^{1} + 1 \times 2^{0} +$$

$$1 \times 2^{-1} + 0 \times 2^{-2} + 1 \times 2^{-3} =$$

$$2 + 1 + 0,5 + 0 + 0,125 =$$

$$3.625$$

#### Otra manera

Otra manera de obtener el valor decimal de un número fraccionario n en base 2 consiste en utilizar el hecho de que cada vez que desplazamos el punto fraccionario un lugar hacia la derecha, estamos multiplicando n por 2, y viceversa, si desplazamos el punto hacia la izquierda, lo dividimos por 2.

El método consiste en:

- Identificar cuántas posiciones fraccionarias tiene n (llamémoslas k)
- Multiplicar n por  $2^k$  obteniendo un **entero** en base 2
- Convertir el entero resultante a base 10, lo cual ya sabemos hacer
- Dividir el resultado por  $2^k$ , obteniendo n en base 10

Con este método esencialmente estamos calculando el valor decimal de n sin considerar el signo de coma fraccionaria (es decir, imaginando que n fuera un entero); convirtiendo ese valor a decimal, y luego dividiendo el resultado en base 10 por  $2^k$  para recuperar el valor original de n, sólo que ahora en base 10.

### **Ejemplo**

El número  $n=11,101_{(2)}$  tiene tres cifras decimales (k=3). Lo convertimos en entero dejando  $11101_{(2)}$ ; averiguamos que este número en base 10 es 29; y finalmente dividimos 29 por  $2^3$ . Concluimos que  $n=11,101_{(2)}=29/8=3,625$ .

#### Decimal fraccionario a base 2

Para convertir un decimal con parte fraccionaria a base 2:

- 1. Se separan la parte entera (PE) y la parte fraccionaria (PF).
- 2. Se convierte la PE a base 2 separadamente.
- 3. La PF se multiplica por 2 y se toma la PE del resultado. Este dígito binario se agrega al resultado.
- 4. Se repite el paso anterior hasta llegar a 0, o hasta lograr la precisión deseada.

### **Ejemplo**

Convirtamos el número  $n=3{,}625$  a base 2. Primero separamos parte entera (3) y parte fraccionaria (0.625).

#### Parte entera

La parte entera de n se convierte a base 2 como entero sin signo (dando  $11_{(2)}$ ).

#### Parte fraccionaria

Para calcular la parte fraccionaria binaria de n seguimos un procedimiento iterativo (es decir, que consta de pasos que se repiten).

La parte fraccionaria decimal de n se multiplica por 2:  $0.625 \times 2 = 1.25$ . Separamos este resultado a su vez en parte entera y parte fraccionaria. Guardamos la parte entera del resultado (que es 1) **y repetimos**, es decir, volvemos a multiplicar por 2 la parte fraccionaria recién obtenida (que es 0.25), separamos la parte entera, etc.

La sucesión de dígitos aparecidos como partes enteras durante este procedimiento servirán para construir la parte fraccionaria del resultado. Notemos que estos dígitos que aparecen solamente pueden ser ceros y unos, porque son la parte entera de  $2 \times x$  con x < 1.

El procedimiento de separar, guardar, multiplicar, se repite hasta que la parte entera obtenida sea 0 (ya no tiene sentido seguir el procedimiento porque el resultado será siempre 0) o hasta que tengamos suficientes dígitos computados para nuestra aplicación.

El resultado final es la suma, en base 2, de la parte entera de n calculada anteriormente, más una parte fraccionaria construida con los dígitos que fueron apareciendo durante el procedimiento de duplicar la parte fraccionaria.

La conversión a base 2 del número  $n=3{,}625$  que buscábamos será  $11_{(2}+0{,}101_{(2}=11{,}101_{(2}.$ 

# Representación de punto fijo

¿Cómo aplicamos el método de conversión visto, de fraccionarios decimales a binarios y viceversa, en las computadoras? El problema es parecido al de almacenar el signo

"menos": no podemos guardar en la memoria otra cosa que bits, de forma que habrá que establecer alguna convención para indicar dónde está el punto o coma fraccionaria.

A veces las computadoras utilizan sistemas **de punto fijo** para representar números con parte fraccionaria. Los sistemas de punto fijo establecen una cantidad de bits o **ancho** total (que llamaremos n) y una cantidad fija de bits para la parte fraccionaria (que llamaremos k). Todos los datos manipulados por la computadora tienen la misma cantidad n-k de bits de parte entera y la misma cantidad k de bits de parte fraccionaria. Por ejemplo, la notación PF(8,3) denota un **sistema de punto fijo con 8 bits en total, de los cuales 3 son para la parte fraccionaria**.

Esta convención contiene toda la información necesaria. Al ser fijos los anchos de parte entera y fraccionaria, la computadora **puede tratar aritméticamente a todos los números como si fueran enteros**, sin preocuparse por partes enteras ni fraccionarias. Solamente habrá que utilizar la convención al momento de imprimir o comunicar un resultado. La impresora, o la pantalla, deberán mostrar un resultado con coma fraccionaria en el lugar correcto.

Sin embargo, todas las operaciones intermedias, entre datos expresados en punto fijo, habrán podido llevarse a cabo sin tener en cuenta el lugar de la coma. Dos números en punto fijo se sumarán como si los representados fueran dos enteros.

### **Ejemplo**

- Supongamos que queremos computar 3,625+1,25 en un sistema PF(8,3).
- Las conversiones de estos sumandos a fraccionarios binarios son, respectivamente, 11,101 y 1,01.
- Pero en la memoria se almacenarán como 00011101 y 00001010. Nótese que al ser todas las partes fraccionarias del mismo ancho, quedan automáticamente "encolumnados" los invisibles puntos fraccionarios.
- La suma se efectuará bit a bit como si se tratara de enteros y será 00100111.
- Si pedimos a la computadora que imprima este valor, aplicará la convención PF(8,3) e imprimirá **00100.111**, o su interpretación en decimal, 4,875, que es efectivamente 3,625+1,25.

### Decimal a PF(n,k)

Para representar un decimal fraccionario a, positivo o negativo, en notación de punto fijo en n lugares con k fraccionarios (PF(n,k)), necesitamos obtener su parte entera y su parte fraccionaria, y expresar cada una de ellas en la cantidad de bits adecuada a la notación. Para esto completaremos la parte entera con ceros a la izquierda hasta obtener n-k dígitos, y completaremos la parte fraccionaria con ceros por la derecha, hasta obtener k dígitos. Una vez expresado así, lo tratamos como si en realidad fuera  $a \times 2^k$ , y por lo tanto, un entero.

- Si es positivo, calculamos la secuencia de dígitos binarios que expresan su parte entera y su parte fraccionaria, y escribimos ambas sobre la cantidad de bits adecuada.
- Si es negativo, consideramos su valor absoluto y procedemos como en el punto anterior. Luego complementamos a 2 como si se tratara de un entero.

#### Truncamiento

Al escribir la parte fraccionaria de un número a en k bits (porque ésta es la capacidad del sistema de representación de punto fijo con k dígitos fraccionarios), en el caso general estaremos **truncando** el desarrollo fraccionario. El número a podría tener otros dígitos diferentes de cero más allá de la posición k. Sin embargo, el sistema no permite representarlos, y esa información se perderá.

La consecuencia del truncamiento es la aparición de un **error de truncamiento** o pérdida de precisión. El número almacenado en el sistema PF(n,k) será una aproximación con k dígitos fraccionarios al número original a, y no estará representándolo con todos sus dígitos fraccionarios.

¿Cuál es el valor de este error de truncamiento, es decir, cuál es, cuantitativamente, la diferencia entre a y la representación en PF(n,k)? Si los primeros k dígitos del desarrollo fraccionario real de a se han conservado, entonces la diferencia es menor que  $2^{-k}$ .

### **Ejemplo**

Representemos 3.1459 en notación PF(8,3). Parte entera: 00011. Parte fraccionaria: 001. Representación obtenida: 00011001. Reconvirtiendo 00011001 a decimal, obtenemos parte entera 3 y parte fraccionaria 0.125; de modo que el número representado en PF(8,3) como 00011001 es en realidad **3.125** y no 3.1459.

El error de truncamiento es 3,1459-3,1250 = 0,0209, que es menor que  $2^{-3} = 0,125$ .

# PF(n,k) a decimal

Para convertir un binario en notación de punto fijo en n lugares con k fraccionarios (PF(n,k)) a decimal:

- Si es positivo, aplicamos la Expresión General extendida, utilizando los exponentes negativos para la parte fraccionaria.
- O bien, lo consideramos como un entero, convertimos a decimal y finalmente lo dividimos por  $2^k$ .
- Si es negativo, lo complementamos a 2 y terminamos operando como en el caso positivo.
- Finalmente agregamos el signo para expresar que se trata de un número negativo.

# **Preguntas**

- ¿A qué número decimal corresponde...
  - 0011,0000?
  - 0001,1000?
  - 0000.1100?
- ¿Cómo se representan en PF(8,4)...
  - 0,5?
  - -7.5?
- ¿Cuál es el RR de PF(8,3)? ¿Y de PF(8,k)?

La representación de punto fijo es adecuada para cierta clase de problemas donde los datos que se manejan son de magnitudes y precisiones comparables.

- En la situación contraria, cuando las magnitudes de los datos son muy variadas, habrá datos de valor absoluto muy grande, lo que hará que sea necesario elegir una representación de una gran cantidad de bits de ancho. Pero esta cantidad de bits quedará desperdiciada al representar los datos de magnitud pequeña.
- Otro tanto ocurre con los bits destinados a la parte fraccionaria. Si los requerimientos de precisión de los diferentes datos son muy altos, será necesario reservar una gran cantidad de bits para la parte fraccionaria. Esto permitirá almacenar los datos con mayor cantidad de dígitos fraccionarios, pero esos bits quedarán desperdiciados al almacenar otros datos.

Las ventajas de la representación en punto fijo provienen, sobre todo, de que permite reutilizar completamente la lógica ya implementada para tratar enteros en complemento a 2, sin introducir nuevos problemas ni necesidad de nuevos recursos. Como la lógica para C2 es sencilla y rápida, la representación de punto fijo es adecuada para sistemas que deben ofrecer una determinada *performance*:

- Los sistemas que deben ofrecer un tiempo de respuesta corto, especialmente aquellos interactivos, como los juegos.
- Los de tiempo real, donde la respuesta a un cómputo debe estar disponible en un tiempo menor a un plazo límite, generalmente muy corto.
- Los sistemas empotrados o embebidos, que suelen enfrentar restricciones de espacio de memoria y de potencia de procesamiento.

Por el contrario, algunas clases de programas suelen manipular datos de otra naturaleza. No es raro que aparezcan en el mismo programa, e incluso en la misma

instrucción de programa, datos o variables de magnitud o precisión extremadamente diferentes.

Por ejemplo, si un programa de cómputo científico necesita calcular el **tiempo en** que la luz recorre una millonésima de milímetro, la fórmula a aplicar relacionará la velocidad de la luz en metros por segundo (unos 300,000,000m/s) con el tamaño en metros de un nanómetro (0,000000001m).

Estos dos datos son extremadamente diferentes en magnitud y cantidad de dígitos fraccionarios. La velocidad de la luz es un número astronómicamente grande en comparación a la cantidad de metros en un nanómetro; y la precisión con que necesitamos representar al nanómetro no es para nada necesaria al representar la velocidad de la luz.

#### Notación Científica

En Matemática, la respuesta al problema del cálculo con variables tan diferentes existe desde hace mucho tiempo, y es la llamada **Notación Científica**. En Notación Científica, los números se expresan en una forma estandarizada que consiste de un **coeficiente, significando o mantisa** multiplicado por **una potencia de 10**. Es decir, la forma general de la notación es  $m \times 10^e$ , donde m, el coeficiente, **es un número positivo o negativo**, y e, el **exponente**, es un entero positivo o negativo.

La notación científica puede representar entonces números muy pequeños y muy grandes, todos en el mismo formato, con economía de signos y permitiendo operar entre ellos con facilidad. Al operar con cantidades en esta notación podemos aprovechar las reglas del Álgebra para calcular m y e separadamente, y evitar cuentas con muchos dígitos.

### **Ejemplo**

Los números mencionados hace instantes, la velocidad de la luz en metros por segundo, y la longitud en metros de un nanómetro, se representarán en notación científica como  $3\times 10^8$  y  $1\times 10^{-9}$ , respectivamente.

El tiempo en que la luz recorre una millonésima de milímetro se computará con la fórmula t=e/v, con los datos expresados en notación científica, como:

$$e = 1 \times 10^{-9} m$$

$$v = 3 \times 10^{8} m/s$$

$$t = e/v = (1 \times 10^{-9} m)/(3 \times 10^{8} m/s) =$$

$$t = 1/3 \times 10^{-9-8} s =$$

$$t = 0.333 \times 10^{-17} s$$

### Normalización

El resultado que hemos obtenido en el ejemplo anterior debe quedar **normalizado** llevando el coeficiente m a un valor **mayor o igual que 1 y menor que 10**. Si modificamos el coeficiente al normalizar, para no cambiar el resultado debemos ajustar el exponente.

# **Ejemplo**

El resultado que obtuvimos anteriormente al computar  $t=1/3\times 10^{-9-8}~s$  fue  $0.333\times 10^{-17}~s$ . Este coeficiente 0.333 no cumple la regla de normalización porque no es **mayor o igual que 1**.

- Para normalizarlo, lo multiplicamos por 10, convirtiéndolo en 3,33.
- Para no cambiar el resultado, dividimos todo por 10 afectando el exponente, que de -17 pasa a ser -18.
- El resultado queda normalizado como  $0.333 \times 10^{-18}$ .

#### Normalización en base 2

Es perfectamente posible definir una notación científica en otras bases. En base 2, podemos escribir números con parte fraccionaria en notación científica normalizada desplazando la coma o punto fraccionario hasta dejar una parte entera **igual a 1** (ya que es el único valor binario que cumple la condición de normalización) y ajustando el exponente de base 2, de manera de no modificar el resultado.

## **Ejemplos**

- $\bullet 100,111_{(2} = 1,00111_{(2} \times 2^2)$
- $0.0001101_{(2)} = 1.101_{(2)} \times 2^{-4}$

# Representación en Punto Flotante

La herramienta matemática de la Notación Científica ha sido adaptada al dominio de la computación definiendo métodos de **representación en punto flotante**. Estos métodos resuelven los problemas de los sistemas de punto fijo, abandonando la idea de una cantidad fija de bits para parte entera y parte fraccionaria. En su lugar, inspirándose en la notación científica, los formatos de punto flotante permiten escribir números de un gran rango de magnitudes y precisiones en un campo de tamaño fijo.

Actualmente se utilizan los estándares de cómputo en punto flotante definidos por la organización de estándares **IEEE** (Instituto de Ingeniería Eléctrica y Electrónica, o "I triple E").

Estos estándares son dos, llamados IEEE 754 en precisión simple y en precisión doble.

- IEEE 754 precisión simple
  - Se define sobre un campo de 32 bits
  - Cuenta con 1 bit de signo
  - Reserva 8 bits para el exponente
  - Reserva 23 bits para la mantisa
- IEEE 754 precisión doble
  - Se define sobre un campo de 64 bits
  - Cuenta con 1 bit de signo igual que en precisión simple
  - Reserva 11 bits para el exponente
  - Reserva 52 bits para la mantisa

La definición de los formatos está acompañada por la especificación de mecanismos de cálculo para usarlos, manejo de errores y otra información importante.

#### Conversión de decimal a punto flotante

Para convertir manualmente un número decimal n a punto flotante necesitamos calcular los tres elementos del formato de punto flotante: **signo** (que llamaremos s), **exponente** (que llamaremos e) y **mantisa** (que llamaremos m), en la cantidad de bits correcta según el formato de precisión simple o doble que utilicemos.

En el curso utilizaremos siempre el formato de precisión simple. Una vez conocidos  $s,\ e$  y m, sólo resta escribirlos como secuencias de bits de la longitud que especifica el formato.

- 1. Separar el **signo** y escribir el valor absoluto de n en base 2.
  - Si n es positivo (respectivamente, negativo), s será 0 (respectivamente, 1). Separado el signo, consideramos únicamente el valor absoluto de n y lo representamos en base 2 como se vio al convertir un decimal fraccionario a base 2.
- 2. Escribir el valor binario de n en notación científica \*\* en base 2 normalizada\*\*.
  - Para convertir n a notación científica lo multiplicamos por una potencia de 2 de modo que la parte entera sea 1 (condición para la normalización).
     El resto de la expresión binaria se convierte en parte fraccionaria. Para no cambiar el valor de n, lo multiplicamos por una potencia de 2 inversa a aquella que utilizamos.
- 3. El exponente, positivo o negativo, que aplicamos en el paso anterior debe ser expresado en notación en exceso a 127.
  - Al exponente se le suma 127 para representar valores en el intervalo [-127,128] con 8 bits. Esta representación se elige para poder hacer comparables directamente dos números expresados en punto flotante.

- 4. El coeficiente calculado se guarda sin su parte entera en la parte de mantisa.
  - Como la normalización obliga a que la parte entera de la mantisa sea 1, no tiene mayor sentido utilizar un bit para guardarlo en el formato de punto flotante: guardarlo no aportaría ninguna información. Por eso basta con almacenar la parte fraccionaria de la mantisa, hasta los 23 bits disponibles (o completando con ceros).

### Ejemplo de Punto Flotante

Recorramos los pasos para la conversión manual a punto flotante precisión simple, partiendo del decimal n=-5.5. Recordemos que necesitamos averiguar s, e y m.

- n es negativo, luego s = 1.
- |n| = 5.5. Convirtiendo el valor absoluto a binario obtenemos  $101.1_{(2)}$ .
- Normalizando, queda  $101,1_{(2}=1,011_{(2}\times 2^2.$
- Del paso anterior, el exponente 2 se representa en exceso a 127 como e = 2 + 127 = 129. En base 2,  $129 = 10000001_{(2)}$ .
- Del mismo paso anterior extraemos la mantisa quitando la parte entera: 1,011-1=0,011. Los bits de m son 011000000... con ceros hasta la posición 23.
- Finalmente, s, e, m = 1,10000001,011000000000...

Lo que significa que la representación en punto flotante de -5,5 es igual a 1100000010110000000... (con ceros hasta completar los 32 bits de ancho total).

### Expresión de punto flotante en hexadecimal

Para facilitar la escritura y comprobación de los resultados, es conveniente leer los 32 bits de la representación en punto flotante precisión simple como si se tratara de 8 dígitos hexadecimales. Se aplica la regla, que ya conocemos, de sustituir directamente cada grupo de 4 bits por un dígito hexadecimal.

Así, en el ejemplo anterior, la conversión del decimal -5.5 resultó en la secuencia de bits 11000000101100000... (con más ceros).

Es fácil equivocarse al transcribir este resultado. Pero sustituyendo los bits, de a grupos de 4, por dígitos hexadecimales, obtenemos la secuencia equivalente C0B00000, que es más simple de leer y de comunicar.

### Conversión de punto flotante a decimal

Teniendo un número expresado en punto flotante precisión simple, queremos saber a qué número decimal equivale. Separamos la representación en sus componentes s, e

y m, que tienen **1, 8 y 23 bits** respectivamente, y "deshacemos" la transformación que llevó a esos datos a ocupar esos lugares. De cada componente obtendremos un factor de la fórmula final.

- Signo
  - El valor de s nos dice si el decimal es positivo o negativo.
  - La fórmula  $(-1)^s$  da -1 si s=1, y 1 si s=0.
- Exponente
  - El exponente está almacenado en la representación IEEE 754 como ocho bits en exceso a 127. Corresponde restar 127 para volver a obtener el exponente de 2 que afectaba al número originalmente en notación científica normalizada.
  - $\bullet$  La fórmula  $2^{(e-127)}$  dice cuál es la potencia de 2 que debemos usar para ajustar la mantisa.
- Mantisa
  - La mantisa está almacenada sin su parte entera, que en la notación científica normalizada en base 2 **siempre es 1**. Para recuperar el coeficiente o mantisa original hay que restituir esa parte entera igual a 1.
  - La fórmula 1+m nos da la mantisa binaria original.

Reuniendo las fórmulas aplicadas a los tres elementos de la representación, hacemos el cálculo multiplicando los tres factores:

$$n = (-1)^s \times 2^{(e-127)} \times (1+m)$$

obteniendo finalmente el valor decimal representado.

# **Ejemplo**

Para el valor de punto flotante IEEE 754 precisión simple representado por la secuencia hexadecimal C0B00000, encontramos que  $s=1,\ e=129,\ m=011000...$ 

- Signo
  - $(-1)^s = (-1)^1 = -1$
- Exponente

• 
$$e = 129 \rightarrow 2^{(e-127)} = 2^2$$

- Mantisa
  - $m = 0110000... \rightarrow (1+m) = 1,011000....$

Ajustando la mantisa  $1{,}011000...$  por el factor  $2^2$  obtenemos  $101{,}1$ . Convirtiendo a decimal obtenemos  $5{,}5$ . Aplicando el signo recuperamos finalmente el valor  $-5{,}5$ , que es lo que está representando la secuencia C0B00000.

#### Error de truncamiento

Aunque los 23 bits de mantisa del formato de punto flotante en precisión simple son suficientes para la mayoría de las aplicaciones, existen números que no pueden ser representados, ni aun en doble precisión. El caso más evidente es el de aquellos números que por su magnitud caen fuera del rango de representación del sistema. Sin embargo, el formato IEEE 754 también encuentra limitaciones al tratar con números aparentemente tan pequeños como 0.1 o 0.2. ¿Cuál es el problema en este caso?

Si hacemos manualmente el cálculo de la parte fraccionaria binaria de 0.1 (o de 0.2) encontraremos que esta parte fraccionaria es **periódica**. Esto ocurre porque 0.1 = 1/10, y el denominador 10 contiene factores que no dividen a la base (es decir, el 5, que no divide a 2). Lo mismo ocurre en base 10 cuando computamos 1/3, que tiene infinitos decimales periódicos porque el denominador 3 no divide a 10, la base.

Cuando un lenguaje de computación reconoce una cadena de caracteres como "0.1", introducida por el programador o el usuario, advierte que se está haciendo referencia a un número con decimales, e intenta representarlo en la memoria como un número en punto flotante. La parte fraccionaria debe ser forzosamente **truncada**, ya sea a los 23 bits, porque se utiliza precisión simple, o a los 52 bits, cuando se utiliza precisión doble. En ambos casos, el número representado es una aproximación al 0.1 original, y esta aproximación será mejor cuantos más bits se utilicen; pero en cualquier caso, esta parte fraccionaria almacenada en la representación en punto flotante es **finita**, de manera que nunca refleja el verdadero valor que le atribuimos al número original.

A partir del momento en que ese número queda representado en forma aproximada, todos los cómputos realizados con esa representación adolecen de un **error de truncamiento**, que va agravándose a medida que se opera con ese número representado.

En precisión simple, se considera que tan sólo **los primeros siete decimales** de un número en base 10 son representados en forma correcta. En precisión doble, sólo los primeros quince decimales son correctos.

#### Casos especiales en punto flotante

En el estándar IEEE 754, no todas las combinaciones de s, e y m dan representaciones con sentido, o con el sentido esperable.

Por ejemplo, con las fórmulas presentadas, no es posible representar el **cero**, ya que toda mantisa normalizada lleva una parte entera igual a 1, y los demás factores nunca pueden ser iguales a 0. Entonces, para representar el 0 en IEEE 754 se recurre a una **convención**, que se ha definido como la combinación de **exponente 0 y mantisa 0**, cualquiera sea el signo.

Los números **normalizados** en IEEE 754 son aquellos que provienen de una expresión en notación científica normalizada con exponente diferente de -127, y son la gran

mayoría de los representables. Sin embargo, el estándar permite la representación de una clase de números muy pequeños, con parte entera 0 en la notación científica, que son los llamados **desnormalizados**.

Otros números especiales son aquellos donde el exponente consiste en ocho **unos** binarios con mantisa 0. Estos casos están reservados para representar los valores **infinito** positivo y negativo (que aparecen cuando una operación arroja un resultado de **overflow** del formato de punto flotante).

Similarmente, cuando el exponente vale ocho unos, y la mantisa es diferente de 0, se está representando un caso de **NaN** (**Not a Number**, "no es un número"). Estos casos patológicos sólo ocurren cuando un proceso de cálculo lleva a una condición de error (por intentar realizar una operación sin sentido en el campo real, como obtener una raíz cuadrada de un real negativo).

# Representación de Texto y multimedia

En esta parte de la unidad veremos la forma de representar otras clases de información no numérica, como los textos y las imágenes.

### Codificación de texto

Cuando escribimos texto en nuestra computadora, estamos almacenando temporariamente en la memoria una cierta secuencia de números que corresponden a los **caracteres**, o símbolos que tipeamos en nuestro teclado.

Estos caracteres tienen una **representación gráfica** en nuestro teclado, en la pantalla o en la impresora, pero mientras están en la memoria no pueden ser otra cosa que **bytes**, es decir, conjuntos de ocho dígitos binarios.

Para lograr almacenar caracteres de texto necesitamos adoptar una **codificación**, es decir, una tabla que asigne a cada carácter un patrón de bits fijo.

Esta codificación debe ser universal: para poder compartir información entre usuarios, o entre diferentes aplicaciones, se requiere algún estándar que sea comprendido y respetado por todos los usuarios y las aplicaciones. Hacia la mitad del siglo XX no existía un único estándar, y cada fabricante de computadoras definía el suyo propio. La comunicación entre diferentes computadoras y sistemas era complicada y llevaba mucho trabajo improductivo.

# Códigos de caracteres

Inicialmente se estableció con este fin el **código ASCII**, que durante algún tiempo fue una buena solución. El código ASCII relaciona cada secuencia de **siete bits** con

un carácter (o **grafema**) específico de la **Tabla ASCII**. Es decir que hay  $2^7=128$  posibles caracteres codificados por el código ASCII.

Sin embargo, el código ASCII es insuficiente para muchas aplicaciones: no contempla las necesidades de diversos idiomas. Por ejemplo, nuestra letra Ñ no figura en la tabla ASCII. Tampoco las vocales acentuadas, ni con diéresis, como tampoco decenas de otros caracteres de varios idiomas europeos. Peor aún, con solamente 128 posibles patrones de bits, es imposible representar algunos idiomas orientales como el chino, que utilizan miles de ideogramas.

Por este motivo se estableció más tarde una familia de nuevos estándares, llamada Unicode. Uno de los estándares o esquemas de codificación definidos por Unicode, el más utilizado actualmente, se llama **UTF-8**. Este estándar mantiene la codificación que ya empleaba el código ASCII para su conjunto de caracteres, pero agrega códigos de dos, tres y cuatro bytes para otros símbolos. El resultado es que hoy, con UTF-8, se pueden representar todos los caracteres de cualquier idioma conocido. Más aún, con UTF-8 pueden codificarse textos multilingües.

Otro estándar utilizado, **ISO/IEC 8851**, codifica los caracteres de la mayoría de los idiomas de Europa occidental.

El código ASCII, los diferentes esquemas de Unicode, y el estándar ISO/IEC 8851, coinciden en la codificación de las letras del alfabeto inglés, que son comunes a la mayoría de los idiomas occidentales, y en la codificación de símbolos usuales como los dígitos, símbolos matemáticos, y otros. Por este motivo son relativamente compatibles, aunque cuando el texto utiliza otros caracteres aparecen diferencias.

# Tabla de códigos ASCII

El código ASCII asigna patrones de siete bits a un conjunto de caracteres que incluye:

- Las 25 letras del alfabeto inglés, mayúsculas y minúsculas;
- Los dígitos del 0 al 9,
- Varios símbolos matemáticos, de puntuación, etc.,
- El espacio en blanco,
- Y 32 caracteres no imprimibles. Estos caracteres no imprimibles son combinaciones de bits que no tienen una representación gráfica o grafema, sino que sirven para diversas funciones de comunicación de las computadoras con otros dispositivos. Suelen ser llamados caracteres de control.

En general, prácticamente todos los símbolos que figuran en nuestro teclado tienen un código ASCII asignado. Como sólo se usan siete bits, el bit de mayor orden (el de más a la izquierda) de cada byte siempre es cero, y por lo tanto los códigos ASCII toman valores de 0 a 127.

# Textos y documentos

Un archivo de texto es una sucesión de caracteres codificados bajo algún estándar. Puede manipularse con programas básicos como los **editores de texto** u otras herramientas que ofrece el ambiente del sistema operativo. Un archivo de texto es directamente legible por humanos porque contiene únicamente los caracteres que constituyen las palabras, espacios en blanco o saltos de línea.

Otra clase de archivos, los que son creados y manipulados por **procesadores de texto**, además de esa información tienen una estructura compleja que permite definir características de presentación y organización del texto. Esto incluye los diferentes tipos, tamaños o colores de los caracteres, las dimensiones de la página, la organización en secciones o capítulos, etc. La estructura de los archivos generados por los procesadores de texto es específica de cada programa y convierte al documento en algo que sólo puede ser leído con el procesador de texto correspondiente.

# Archivos de hipertexto

Una página HTML servida por un servidor Web es un archivo de texto que suele estar codificado en el estándar UTF-8. El contenido de este texto es directamente legible, pero no es exactamente lo que muestra el navegador, sino que esa representación gráfica está indicada por el lenguaje HTML en el que está escrito el documento. Las propiedades de navegación del documento también están determinadas por elementos del lenguaje HTML.

Las primeras líneas del documento HTML definen cuestiones relativas a la presentación que hará el navegador, como el idioma en el cual está escrita la página, el conjunto de caracteres que la codifica, el título que debe presentarse en la ventana de visualización, etc. Estas líneas se especifican en el lenguaje especial de la Web, el lenguaje de marcado de hipertexto, o HTML.

Con el navegador podemos visualizar el texto de esa página pulsando las teclas CTRL+U. Lo mismo si descargamos la página hacia un archivo y usamos el comando head. Lo que se ve es diferente de lo que muestra el navegador: se trata del **código** fuente de la página HTML.

Presentemos otras vistas del mismo archivo de texto, a fin de mostrar que se compone simplemente de una secuencia de bytes.

Con diferentes comandos o programas de visualización podemos ver, carácter por carácter, cómo está construido este texto. El comando **hexdump** -**bc** nos da la lista de los caracteres que componen el texto, con la notación en octal de su código, que aparece encima de cada uno de ellos.

Las letras acentuadas se representan con una serie de caracteres UTF-8 especiales, no pertenecientes a la zona visible del ASCII. El comando separa el carácter en los bytes que lo componen y los muestra individualmente.

Los caracteres de control, como el tabulador y el fin de línea, no tienen un grafema asociado, sino que se representan por las secuencias  $\t$  y  $\t$  respectivamente. Estos caracteres desplazan el cursor de posición que escribe los caracteres en pantalla (o en una impresora) para organizar visualmente la presentación del texto, y también son parte del código fuente de la página.

Del mismo modo, el comando **hexdump -C** muestra cada uno de los grafemas de los caracteres acompañado de su codificación en hexadecimal. Esta vista no muestra los caracteres acentuados ni los de control, sino que los reemplaza por puntos.

# Pregunta

Estos comandos aplicados a un documento HTML muestran información legible porque se trata, esencialmente, de un archivo de texto. ¿Qué ocurre si los mismos comandos se aplican a un archivo creado por un procesador de texto?

# Imagen digital

Otras clases de datos, diferentes del texto, también requieren codificación (porque siempre deben ser almacenados en la memoria en forma de bits y bytes), pero su tratamiento es diferente.

Introducir en la computadora, por ejemplo, una imagen analógica (tal como un dibujo o una pintura hecha a mano), o un fragmento de sonido tomado del ambiente, requiere un proceso previo de **digitalización**. Digitalizar es convertir en digital la información que es analógica, es decir, convertir un rango **continuo** de valores (lo que está en la naturaleza) a un conjunto **discreto** de valores numéricos.

Si partimos de una imagen analógica, el proceso de digitalización involucra la división de la imagen en una fina cuadrícula, donde cada elemento de la cuadrícula abarca un pequeño sector cuadrangular de la imagen. A cada elemento de la cuadrícula se le asignan valores discretos que codifican el color de la imagen en ese lugar.

Estos elementos o puntos se llaman **pixels** (del inglés, **picture element**). La imagen queda constituida por una sucesión de valores de color para cada pixel de los que forman la imagen.

En general, mientras más elementos de cuadrícula (más pixels) podamos representar, mejor será la aproximación a nuestra pieza de información original. Mientras más fina la cuadrícula (es decir, mientras mayor sea la **resolución** de la imagen digitalizada), y mientras más valores discretos usemos para representar los colores, más se parecerá nuestra versión digital al original analógico.

Notemos que la digitalización de una imagen implica la discretización de **dos** variables analógicas:

 Por un lado, los infinitos puntos de la imagen analógica, bidimensional, deben reducirse a unos pocos rectángulos discretos.  Por otro lado, los infinitos valores de color deben reducirse a unos pocos valores discretos, en el rango de nuestro esquema de codificación.

Este proceso de digitalización es el que hacen automáticamente una cámara de fotos digital o un celular, almacenando luego los bytes que representan la imagen tomada.

# Color

Hay varias maneras de representar el color en las imágenes digitales. Una forma es definir, para cada pixel o punto de la imagen, tres coordenadas que describen las intensidades de luz **roja, verde y azul** que conforman cada color.

Cuando se crea una mezcla de rayos de luz de colores con diferentes intensidades, usando un proyector o una pantalla como los displays LED, las ondas luminosas individuales del rojo, verde y azul se suman formando otros colores. Este esquema de representación del color se llama **RGB** por las iniciales de los colores rojo, verde y azul en inglés.

Para cada punto, esas tres coordenadas son números en un cierto intervalo. El valor mínimo de una coordenada, el 0, representa la ausencia de ese color. El valor máximo, la intensidad máxima de ese color que se puede reproducir con el dispositivo de salida que lo está visualizando. Cuando las coordenadas se representan en un byte, cada coordenada puede ir entre 0 y 255.

Así, la terna (0, 0, 0) representa el negro (ausencia de los tres colores), la terna (255, 255, 255) el blanco (valores máximos de los tres colores, sumados), etc.

#### Profundidad de color

Con este esquema de representación de color, cada pixel o elemento de la imagen quedaría representado por tres bytes, o 24 bits. Sin embargo, las cámaras fotográficas digitales modernas utilizan un esquema de codificación con mucha mayor **profundidad de color** (es decir, más bits por cada coordenada de color) que en el ejemplo anterior.

## Formato de imagen

Lógicamente, para las imágenes con muchos colores (como las escenas de la naturaleza donde hay gradaciones de colores) es conveniente contar con muchos bits de profundidad de color. Sin embargo, cuando una imagen se compone de pocos colores, la imagen digital es innecesariamente grande, costosa de almacenar y de transmitir. En estos casos es útil definir un **formato de imagen** que represente esos pocos colores utilizando menos bits.

Una forma de hacerlo es definir una **paleta de colores**, que es una lista de los diferentes colores utilizados en la imagen, codificados con la mayor economía de bits posible. Si conocemos la cantidad de colores en la imagen, podemos determinar la cantidad mínima de bits que permite codificarlos a todos.

Así, cada pixel de la imagen, en lugar de quedar representado por una terna de valores, puede representarse por un número de color en la paleta.

Queda por especificar **cuál color es el que está codificado por cada número de color** de la paleta. Si una imagen tiene dos bits de profundidad de color, los colores serán cuatro, y sus códigos serán **00, 01, 10, 11**. Pero, ¿cuáles exactamente son estos colores? Tal vez, blanco, negro, rojo y azul. Pero tal vez sean cuatro niveles de gris. O cuatro diferentes tonos de verde.

Para simplificar nuestro trabajo asumiremos que esto no es importante, sino que el problema consiste únicamente en que nuestro formato determine los códigos de colores de cada uno de los pixels. El problema de cuáles son los colores asignados a esos códigos puede resolverse de otras maneras: por ejemplo, suponiendo que existe una hipotética tabla universal de colores y códigos, conocida por todos.

La imagen queda entonces representada por una sucesión de bits que codifican los colores de los pixels. Esta sucesión de bits está lista para ser comunicada a otra computadora a través de la red, o un programa puede entregarla a otro para efectuarle algún procesamiento. O bien, esta sucesión de bits puede ser almacenada y recuperada en un momento futuro.

Sin embargo, si sólo se almacena o transfiere esta sucesión de bits, la imagen puede no ser correctamente interpretada.

El programa que reciba esta sucesión de bits debe conocer además cómo se disponen en el espacio los pixels, es decir, cuál es el ancho y el alto de la imagen; y exactamente cuántos bits codifican un pixel. Si esta información no está presente en el archivo que representa la imagen, su reconstrucción puede ser errónea o imposible.

Nuestro formato de imagen digital debe contener información **de dimensiones y de profundidad de color**, para poder ser comunicado efectivamente hacia otros programas o computadoras.

### Un formato de imagen

Teniendo en cuenta todo lo anterior, podemos definir un formato de imagen como sigue. El formato de archivo de imagen tendrá una primera sección o **cabecera** con datos acerca de la imagen, o **metadatos**, y una segunda sección con los bits o datos de la imagen propiamente dichos.

 El primer byte de la cabecera del archivo se reserva para especificar el ancho de la imagen, es decir, cuántos pixels hay en cada fila.

- El segundo byte se reserva para especificar la altura o cantidad de filas de pixels de la imagen.
- El tercer byte especifica la profundidad de color, o cantidad de bits por pixel. Esta cantidad de bits por pixel define la cantidad de colores que se pueden codificar en la imagen. Si la imagen tiene n bits por pixel, hay 2<sup>n</sup> posibilidades para el código de color y por lo tanto 2<sup>n</sup> colores representables.
- Finalmente, el resto del archivo contiene los bits que representan a cada uno de los pixels por su color. Éstos son los datos de la imagen propiamente dicha.

#### **Eiemplo**

Un archivo que define una imagen de **cinco por cinco pixels, a cuatro colores**, comienza con los bytes 00000101, 00000101, 00000010, y sigue con los datos de la imagen.

Como la cantidad de datos binarios de un archivo en este formato es muy grande, para hacerlo más manejable usaremos notación hexadecimal. Entonces el archivo del ejemplo se representa por el hexadecimal 050502... y a continuación siguen en hexadecimal los códigos de color de los pixels.

# Reconstruyendo una imagen

Para interpretar qué imagen describe un archivo dado, consideramos primero su cabecera y buscamos cuál es el ancho y el alto (indicados por los primeros dos bytes), y cuántos bits por pixel están codificados en el resto del archivo (indicados por el tercer byte). De esta manera no es difícil dibujar la imagen.

## **Ejemplo**

- Una imagen dada por la cadena hexadecimal **070401AEBF3...** tendrá  $7 \times 4$  pixels, y un solo bit de paleta.
- Como la paleta se codifica con un solo bit, esta imagen es en blanco y negro (no puede haber más que dos valores de color).
- Los dígitos hexadecimales a partir de la cadena **AEBF3...** se analizan como grupos de cuatro bits y nos dicen cuáles pixels individuales están en negro (bits en 1) y en blanco (bits en 0).

### Compresión de datos

Muchas veces es interesante reducir el tamaño de un archivo, para que ocupe menos espacio de almacenamiento o para que su transferencia a través de una red sea más rápida. Al ser todo archivo una secuencia de bytes, y por lo tanto de números, disponemos de métodos y herramientas matemáticas que permiten, en ciertas condiciones, reducir ese tamaño. La manipulación de los bytes de un archivo con este fin se conoce como **compresión**.

La compresión de un archivo se ejecuta mediante un programa que utiliza un algoritmo especial de compresión. Este algoritmo puede ser de **compresión sin pérdida**, o de **compresión con pérdida**.

# Compresión sin pérdida

Decimos que la compresión ha sido **sin pérdida** cuando puede extraerse del archivo comprimido exactamente la misma información que antes de la compresión, utilizando otro algoritmo que ejecuta el trabajo inverso al de compresión. En otras palabras, la compresión sin pérdida es reversible: aplicando el algoritmo inverso, o de descompresión, siempre puede volverse a la información de partida. Esto es un requisito indispensable cuando necesitamos recuperar exactamente la secuencia de bytes original, como en el caso de un archivo de texto, una base de datos, una planilla de cálculo.

Como usuarios de computadoras, es muy probable que hayamos utilizado más de una vez la compresión sin pérdida, al tener que comprimir un documento de texto, utilizando un programa utilitario como ZIP, RAR u otros. Si la compresión no fuera reversible, no podríamos recuperar el archivo de texto tal cual fue escrito.

También somos usuarios de la compresión, muchas veces sin sospecharlo, al consultar páginas de Internet. Muchos sitios populares utilizan compresión para acelerar la descarga de sus contenidos. Los navegadores cuentan con el conocimiento para identificar cuándo una página está comprimida, y saben descomprimirla en forma transparente, es decir, sin que el usuario necesite hacer ni saber nada.

## Compresión con pérdida

Cuando la compresión se hace con una técnica **con pérdida**, no existe un algoritmo de descompresión que recupere la información original; es decir, no existe un algoritmo inverso.

El resultado de la compresión con pérdida de un archivo es otro archivo del cual ya no puede recuperarse la misma información original, pero que de alguna manera sigue sirviendo a los fines del usuario. La pérdida de información **es intencional**, y es el usuario quien ha elegido descartar esa información porque no es necesaria.

En el mundo analógico es frecuente la compresión con pérdida, por ejemplo en el caso de la compresión de audio, al descartar componentes del sonido con frecuencias muy bajas o muy altas, inaudibles para los humanos (como en la tecnología de grabación de CDs), con lo cual la diferencia entre el material original y el comprimido no es perceptible al oído. También es útil, para algunos fines, reducir la calidad del audio quitando algunos componentes audibles (lo que hacen, por ejemplo, los sistemas telefónicos, o algunos grabadores "de periodista" para lograr archivos más pequeños, con audio de menor fidelidad, pero donde el diálogo sigue siendo comprensible).

Al utilizar un servicio de *streaming* de video o audio, muchas veces se nos da la oportunidad de elegir una "calidad" menor del audio o del video, lo que quiere decir que el audio o la imagen se representarán con menos bits por segundo, y se transferirán a través de la red más rápidamente. Estas diferentes "calidades" menores son formas de compresión con pérdida.

Los estándares MP3 y MP4 son ejemplos de formatos de archivos digitales comprimidos con pérdida. Para comprimir con pérdida imágenes, se reduce su calidad, ya sea disminuyendo la resolución o utilizando menos colores.

#### Reducción de color

Si la imagen tiene  $ancho \times alto$  pixels, y la información de color es de n bits por pixel, el archivo sin su cabecera mide  $ancho \times alto \times n$  bits. Una forma sencilla de compresión con pérdida, que no modifica la resolución, es la reducción de la profundidad de color de una imagen. Si la imagen puede seguir siendo útil con menos colores, comprimiendo la paleta de colores puede obtenerse un archivo de menor tamaño.

Comprimir la paleta de colores consiste en reescribir la imagen con una cantidad menor de bits por pixel. Cada vez que la cantidad de bits por pixel decrece en uno, la profundidad de color, es decir, la cantidad de colores diferentes, se divide por dos. De esta forma se puede reducir la cantidad de bits utilizados para expresar cada pixel, claro está, al costo de perder información de color de la imagen.

#### **Ejemplo**

Sea una imagen a cuatro colores; luego la cantidad de bits por pixel es 2. Al reducir la profundidad de color, los colores 00 y 10 pasan a ser el único color 0; y los colores 10 y 11 pasan a ser el único color 1. Todos los pixels quedan expresados por un único bit 0 o 1, reduciendo efectivamente el tamaño de la imagen.

- La información ha sido comprimida con pérdida porque el archivo original no puede ser reconstruido a partir de este nuevo archivo.
- El nuevo archivo, sin su cabecera, mide  $ancho \times alto \times (n-1)$ , o sea, es  $ancho \times alto$  bits más corto que el original.

Un método para reducir a la mitad la profundidad de color puede ser como sigue:

- 1. Escribir la tabla de códigos de color.
- 2. Retirar el bit más alto de cada código de color en la paleta.
- 3. Eliminar de la paleta los códigos duplicados.
- 4. Reescribir la cabecera del archivo manteniendo ancho y alto pero con la nueva cantidad de bits por pixel.
- 5. Reescribir los datos de la imagen reemplazando el código original de color de cada pixel por el nuevo código, es decir, quitando el bit más alto de cada pixel.

Dos pixels cuyos códigos de color diferían sólo en el bit de orden más alto ahora tendrán el mismo código, y por lo tanto se "pintarán" del mismo color. El archivo ya no contiene la información necesaria para saber cuál era el color original de cada pixel.

### **Ejemplo**

- 1. La tabla de códigos de color es {00 01 10 11}.
- 2. Sin su bit más alto, estos códigos son {0 1 0 1}.
- 3. Sin duplicados, quedan los códigos {0 1}.
- 4. La cabecera del nuevo archivo es {ancho: 5, alto: 5, bits por pixel: 1}.
- 5. Los bits que describen los pixels de la nueva imagen son {0 0 1 0 0 0 1 1 1 1 1 0 0 1 0 0 0 0 1 0 0 0 0 0 }.

La imagen comprimida queda como **05050123C82000** (ancho: 5, alto: 5, bits por pixel: 1, pixels: 0 0 1 0 0 0 1 1 1 1 0 0 1 0 0 0 0 0 1 0 0 0 0 0).

### Pregunta

Se ha visto cómo reducir la profundidad de color en exactamente 1 bit. ¿Cómo podemos generalizar el método, para reducir la información de color en una cantidad de bits cualquiera?

# Algoritmos de compresión sin pérdida

Aunque los programas que aplican algoritmos de compresión sin pérdida pueden ser muy sofisticados, algunas ideas básicas son muy sencillas.

### Run Length Encoding o RLE

Supongamos tener una imagen en el formato que ya hemos descripto, y supongamos además que los datos de la imagen, es decir, la sucesión de bits que codifican los pixels, presentan grandes zonas de pixels con el mismo valor (muchos "1" seguidos, y muchos "0" seguidos). Si quisiéramos transmitir esta información por teléfono a alguien más, para que la imagen pudiera ser dibujada del otro lado, tarde o temprano la conversación incluiría frases como "...ahora cinco unos, ahora doce ceros...". Esta forma de descripción es mucho más económica, y menos propensa a errores.

Resulta natural abreviar la descripción de la imagen usando este tipo de expresiones, donde las cantidades funcionan como **coeficientes**. Un método inspirado directamente en esta idea se llama **Run Length Encoding (RLE)** o **Codificación por** 

**longitud de secuencia**. Una **secuencia** es una subsucesión de elementos del mismo valor. El método RLE identifica secuencias de elementos de un mismo valor, computa su longitud, y emite, en lugar de la secuencia, el coeficiente de longitud y el valor que corresponde.

Por supuesto, la efectividad de este método de compresión depende de la **redundancia** presente en el material original. Si no hay secuencias largas, el método no logrará compresión aceptable, e inclusive puede resultar contraproducente (el archivo final puede ser más largo que el original).

Para comprimir sin pérdida una pieza de información cualquiera con la técnica RLE o de Run Length Encoding, primeramente fijamos la cantidad de bits que ocuparán los coeficientes de longitud de secuencias. Esta cantidad de bits, ya que define el tamaño máximo de los coeficientes, debe ser elegida con cuidado:

- Si los coeficientes son pequeños, y la redundancia del archivo es muy alta, no aprovecharemos la capacidad de compresión del método.
- Si los coeficientes son muy grandes, y la imagen tiene poca redundancia, se desperdiciarán bits en los coeficientes y no lograremos buena compresión.

## **Ejemplo**

Si quisiéramos almacenar o transmitir un patrón de 253 "unos" seguidos de 119 "ceros" y luego 87 "unos", sin ninguna compresión, deberíamos manejar 458 bits. Si nuestra compresión utilizara la técnica RLE con ocho bits para el "coeficiente" y un bit para el valor repetido, bastaría con la secuencia binaria (11111101, 1, 01110111, 0, 01010111, 1) (en decimal 253, 1, 119, 0, 87, 1) que ocuparía tan sólo 27 bits.

### Códigos de Huffmann o de longitud variable

La compresión sin pérdida por el método de Huffmann utiliza códigos de longitud variable. El método consiste esencialmente en examinar el archivo completo buscando subsecuencias de bits repetidas. Se computa la frecuencia, o cantidad de veces que aparece, para cada una de estas subsecuencias. Las subsecuencias se ordenan descendentemente por frecuencia, y cada una se reemplaza por un código instantáneo de bits de longitud creciente.

Por ejemplo, el carácter más frecuente será reemplazado por el código 1; el siguiente en frecuencia, por el código 01; el siguiente, por 001; etc. Así, los caracteres que aparecen más veces serán codificados por patrones de bits más cortos. De esta forma el archivo comprimido ocupará menos espacio que con un código de longitud uniforme.

### **Ejemplo**

■ El texto de once caracteres "ABRACADABRA" contiene cinco "A", dos "B", dos "R", una "C" y una "D". Si no utilizamos compresión, se necesitan  $11 \times 8 = 88$  bits para representarlo. Si utilizamos compresión por códigos de longitud variable, crearemos un pequeño diccionario de la forma  $\{A \to 1, B \to 01, R \to 001, C \to 0001, D \to 00001\}$ . Con este diccionario, el texto se podrá representar como "1 01 001 1 0001 1 00001 1 01 001 1", en tan sólo 23 bits.

#### Interesante

Ley de Zipf

### Compresión de imágenes con RLE

Fijada la cantidad de bits para coeficientes, la imagen se comprime indicando, para cada secuencia de pixels iguales, qué factor de repetición corresponde y qué valor de color llevan los pixels repetidos.

#### **Ejemplo**

Si utilizamos tres bits para el coeficiente, los coeficientes RLE 2, 7 y 6 se expresarán como 010, 111 y 110. Los datos de la imagen se comprimirán como { 010 10 111 11 110 10...} Los primeros treinta bits de los datos de imagen han quedado comprimidos a quince bits.

## Compresión con pérdida y pérdida de información

Es importante insistir en el punto siguiente, que con frecuencia es mal comprendido.

Si un archivo es comprimido **sin pérdida** y luego transferido a través de la red, llega a destino un cierto conjunto de bits que, en algunos casos, puede contener errores. El conjunto de bits puede tener valores intercambiados (ceros por unos) o estar incompleto. En estas condiciones, la descompresión o reconstrucción del archivo original no será posible, por pérdida de información. El programa que intente la descompresión fallará o entrará en una condición de error.

Se ha perdido información. Sin embargo, éste no es un caso de compresión con pérdida.

- La compresión con pérdida implica una pérdida de información que es intencional. La información ha sido quitada a propósito porque estaba de más, y no existe la intención de reconstruir el archivo original.
- Al comprimir sin pérdida, si existe pérdida de información, ésta ha sido accidental. La idea al comprimir era reconstruir el archivo en un momento posterior.

# Arquitectura y Organización de Computadoras

¿Cómo **definimos** una computadora? ¿Cuándo un dispositivo es una computadora y cuándo decimos que no lo es? En esta unidad, vemos estos temas y estudiamos los diferentes componentes que tienen las computadoras.

# Componentes de una computadora simple

En primer lugar, una **memoria principal**, que es donde se almacenan todos los datos y las instrucciones de programa. Todo lo que puede hacer la computadora, lo hace únicamente con contenidos que estén en la memoria. Para poder procesar un dato, primero hay que hacerlo llegar a la memoria principal, no importa de dónde venga. Un conjunto de datos puede estar en disco, en un pendrive, o ser introducido por el teclado, pero sólo cuando llega a la memoria principal es que puede ser procesado por la CPU.

La CPU, o Unidad Central de Procesamiento, es el componente que realmente lleva a cabo los cómputos. Trabaja leyendo instrucciones y datos de la memoria; y ejecuta esas instrucciones que operan sobre esos datos. Vamos a hablar mucho más sobre la CPU en esta unidad.

Los **dispositivos de Entrada y Salida** son todos aquellos dispositivos que conectamos a la computadora para hacer que el conjunto CPU + Memoria se comunique con el ambiente.

- Con dispositivos como el teclado, mouse, o tableta digitalizadora, podemos introducir datos. Son dispositivos de entrada.
- Con dispositivos como pantalla o impresora, podemos hacer que la computadora presente los resultados de los cómputos y los entregue al usuario. Son dispositivos de salida.
- Algunos dispositivos son de entrada y salida a la vez, como la tarjeta de red.

Todos estos componentes, y muchos otros que pueden estar o no presentes, dependiendo de la **arquitectura**, o modo de construcción, de la computadora, están conectados entre sí mediante **buses** o líneas de interconexión.

#### Memoria

La memoria es un componente fundamental de la computadora. Está implementada con circuitos que pueden estar en uno de dos estados eléctricos, y por esto los llamamos **biestables**.

Cada circuito biestable puede almacenar la información correspondiente a un **bit**. Los bits están agrupados de a ocho formando los **bytes**. Estos circuitos, con las tecnologías de hoy, están super miniaturizados y contienen muchos millones de

posiciones donde se pueden almacenar temporariamente los datos y las instrucciones de programa.

Para poder utilizar la memoria es imprescindible conocer el número, o **dirección**, de la posición de memoria donde está el dato o instrucción que se necesita acceder. Con esta dirección podemos **recuperar**, es decir, **leer**, el valor que está alojado en ese byte de la memoria, o escribir sobre ese byte un contenido de ocho bits.

#### **CPU**

La CPU está implementada como un circuito sumamente complejo que contiene **registros**. Éstos son lugares de almacenamiento temporario de datos e instrucciones que se utilizan durante el cómputo.

Si, en un momento dado, sacamos una foto instantánea de una CPU, sus registros tendrán un cierto conjunto de valores. Ese conjunto de valores se llama el **estado** de la CPU. La CPU, mientras opera, va cambiando de estado, es decir, paso a paso va modificando los valores de sus registros hasta llegar a un resultado de cada instrucción.

Por atravesar esta sucesión de cambios de estado, se dice que una CPU es un circuito **secuencial**. Los cambios de estado son disparados por un **reloj**, que es un circuito auxiliar que produce pulsos o impulsos eléctricos que hacen marchar a la CPU.

La CPU puede interpretar un conjunto determinado de instrucciones. Estas instrucciones han sido definidas en su arquitectura; y son las únicas que puede ejecutar. El funcionamiento de la CPU está limitado a estas instrucciones, que son muy básicas, como sumar dos datos, o leer el dato que está en una determinada dirección de la memoria.

Sin embargo, cuando escribimos una secuencia de instrucciones en la memoria, es decir, un **programa**, podemos hacer que la CPU desarrolle otras tareas que no estaban previstas en su arquitectura. Por ejemplo, podemos tener una CPU que no sepa multiplicar o dividir, pero si cuenta con un programa con las instrucciones adecuadas, puede ejecutar operaciones de multiplicación o división de datos.

La CPU está constituida por varios circuitos componentes o unidades funcionales, como la **Unidad de Control** y la **Unidad Lógico-Aritmética**.

- La Unidad de Control es la que contiene la lógica necesaria para leer cada instrucción del programa que está en memoria, ejecutarla, y pasar a la siguiente instrucción. Esta lógica se llama el ciclo de instrucción y se repite continuamente mientras la CPU está funcionando.
- La Unidad Lógico-Aritmética es la que efectivamente realiza los cómputos con los datos.

# Arquitectura de Von Neumann

### Máquina de programa almacenado

Por supuesto, además de todos esos componentes que hemos nombrado, hay muchas otras cosas que físicamente forman parte de la computadora; pero la descripción de la computadora que hemos hecho hasta el momento dice, por lo menos en líneas generales, los componentes fundamentales que tiene cualquier computadora actual. Esta descripción puede resumirse diciendo que la computadora es una **máquina de Von Neumann o máquina de programa almacenado**.

En esta clase de máquinas, existe una memoria; que contiene instrucciones y datos; que como contenidos de esa memoria, no se diferencian, salvo por la forma como son utilizados.

Estas máquinas ejecutan las instrucciones almacenadas en memoria secuencialmente, es decir, procediendo desde las direcciones inferiores de la memoria hacia las superiores, leyendo y ejecutando cada instrucción y pasando a la siguiente.

### CPU y Memoria

En una **máquina de Von Neumann**, entonces, aparecen dos componentes básicos fundamentales que son la CPU y la memoria,

la primera conteniendo una Unidad de Control, o UC, para realizar el ciclo de instrucción.

y una Unidad Lógico-Aritmética, o ALU, para el cómputo.

### **Buses**

En la máquina existen diferentes clases de buses para interconectar los componentes:

- buses internos de la CPU para comunicar la UC y la ALU,
- buses de sistema que relacionan la CPU y la memoria,
- y otros buses de Entrada/Salida para comunicar todo el sistema con los dispositivos de entrada o de salida.

¿En qué momento se utilizará cada clase de bus?

 Cuando la UC disponga que se debe ejecutar una instrucción, tal como una suma, enviará los datos de partida, y la instrucción, a la ALU a través de un bus interno.

- Si la ALU necesita más datos, los obtendrá de la memoria a través de un bus de sistema.
- Si la CPU encuentra instrucciones que ordenan presentar el resultado del cómputo al usuario, usará un bus de Entrada/Salida para emitir ese resultado por pantalla o por impresora.

# Modelo Computacional Binario Elemental

Para comprender desde lo más básico cómo opera la computadora, recurrimos al MCBE o Modelo Computacional Binario Elemental, que es una máquina teórica. El MCBE es una computadora extremadamente simple, pero que podría ser implementada físicamente, y funcionaría como la mayoría de las computadoras actuales. Bueno, con muchas menos capacidades, claro, pero manteniendo lo esencial de las computadoras de programa almacenado.

### Esquema del MCBE

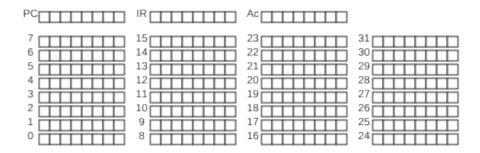


Figura 1: Esquema del MCBE

En este esquema del MCBE vemos los tres registros de la CPU: el **PC o contador de programa**, el **IR o registro de instrucción**, situados en la Unidad de Control, y el **Acumulador**, situado en la Unidad Lógico-aritmética. Los tres son registros de ocho bits.

Además se representa **la memoria**, compuesta por 32 bytes de ocho bits. Las direcciones de los bytes van, entonces, **de 0 a 31**. Aquí hemos descompuesto la memoria en trozos solamente para poder representarla completa en el esquema, pero conviene pensar en la memoria como una única sucesión de bytes, numerados de 0 a 31. Es costumbre, al representar los diagramas de memoria, ubicar las posiciones con direcciones menores en la parte inferior del diagrama, y las direcciones mayores arriba; como si la memoria fuera una escalera con posiciones numeradas a partir de 0 y ascendiendo.

### Estado de la máquina

Cada combinación posible de ceros y unos en los bits de cualquiera de los registros o posiciones de memoria representa un **estado** de la máquina, porque define los valores de la memoria y de los registros en un momento dado. Es decir, el estado de la máquina en cada momento es el conjunto de valores de los tres registros y de los 32 bytes de la memoria.

El estado de la máquina en cada momento define cuál será el estado siguiente. Ninguna otra cosa interviene en el comportamiento de la máquina. En particular, la máquina no tiene voluntad ni toma decisiones propias: solamente cumple el ciclo de instrucción, que la hace ejecutar las instrucciones del programa que tenga almacenado.

#### Memoria del MCBE

Las 32 posiciones de memoria, cada una de 8 bits, son casi todas iguales, con dos excepciones.

- La posición 30 (casi al final de la memoria) está reservada para comunicación con dispositivos de entrada. Es sólo de lectura, es decir, no se pueden escribir contenidos en esa dirección. Cuando leemos esa posición de memoria, la máquina detiene su programa y espera que el usuario introduzca un dato. Una vez que el usuario ha terminado de escribirlo, el MCBE continúa la operación del programa con el dato recién leído.
- La posición 31 es solamente de escritura. Al escribir un dato en la dirección 31, hacemos que el MCBE escriba ese valor por pantalla, y solamente así podemos saber el resultado de un cómputo.

# Registros del MCBE

Como hemos dicho, los registros son lugares de almacenamiento temporario para varios usos. Los registros funcionan en forma parecida a la memoria, en el sentido de que se pueden leer o escribir datos en ellos, pero normalmente en una computadora física su velocidad de acceso es mayor.

Los registros del MCBE tienen diferentes funciones. El registro **PC**, o contador de **programa**, contiene en cada momento la dirección de la próxima instrucción que se va a ejecutar; es decir, contiene un número que es la dirección de la posición de memoria donde está almacenada la instrucción que está por ejecutar el MCBE.

Antes de ejecutar cada instrucción, la CPU va a **copiarla** en el registro **IR, o registro de instrucción**; y mientras está almacenada allí la instrucción, va a ser decodificada, es decir, la CPU va a interpretar de qué instrucción se trata, y la va a ejecutar.

El registro **acumulador**, que pertenece a la ALU, es un registro que interviene en casi todas las operaciones del MCBE; sobre todo para las operaciones aritméticas.

### CPU del MCBE

Entonces la CPU del MCBE queda definida como el conjunto de **Unidad de Control** con dos registros **PC e IR**, más **Unidad lógico-aritmética** con un registro **acumulador**.

Esta CPU va a ser muy limitada y solamente va a ejecutar operaciones de suma y resta en complemento a 2, con ocho bits. No va a ejecutar **multiplicaciones**, ni **divisiones**, ni operaciones en **punto flotante**.

#### Formato de instrucciones del MCBE

**Código de instrucción** Las instrucciones del MCBE se codifican en ocho bits y por lo tanto pueden ser almacenadas en un byte de la memoria, o en el registro IR. Cada instrucción se divide en dos partes: los tres bits de más a la izquierda se destinan a representar el **código de instrucción**.

**Argumentos u operandos** Los cinco bits restantes representan el **argumento u operando** de esa instrucción, es decir, el dato con el cual tiene que operar esa instrucción.

**Direcciones y desplazamientos** Por otro lado, los operandos pueden ser de dos clases: o bien **direcciones**, o bien **desplazamientos**. Si el operando es una dirección, es porque la CPU necesita conocer la dirección de un dato. Si es un desplazamiento, ese desplazamiento es **una cantidad de posiciones** que hay que trasladarse en la memoria, para encontrar la siguiente instrucción que hay que procesar.

- Cuando el operando es una dirección, los cinco bits del operando representan una cantidad sin signo (porque no pueden existir direcciones negativas).
- Cuando es un desplazamiento, esos cinco bits son con signo, y más precisamente, en complemento a 2; porque el desplazamiento puede ser negativo, indicando que hay que volver hacia atrás, a una cierta dirección de la memoria a ejecutar una instrucción que tal vez ya fue ejecutada.

Notemos que al representar las direcciones con cinco bits, sin signo, tenemos un rango de representación de 0 a 31, justo lo que necesitamos para alcanzar todas las posiciones de memoria.

Para los desplazamientos, como estamos usando un sistema con signo, tenemos un rango de -16 a 15. Lo que quiere decir que al trasladarnos de un lugar a otro de la memoria, vamos a poder hacerlo en saltos de a lo sumo 16 bytes hacia atrás o 15 bytes hacia adelante.

#### Conjunto de instrucciones del MCBE

Las instrucciones del MCBE se dividen en cuatro grupos.

- Las instrucciones de transferencia de datos son las que leen o escriben datos en la memoria.
- Las aritméticas son las que operan entre esos datos de la memoria y el valor presente en el registro acumulador.
- Las de salto o transferencia de control, las que desvían, derivan o trasladan la ejecución a otra posición de memoria.
- Y las de control, completan el funcionamiento de la máquina, por ejemplo controlando cuándo va a detenerse el programa.

Notemos que, como tenemos un campo de **tres bits** para definir el código de instrucción, no vamos a poder tener más que **ocho instrucciones**. Precisamente hay dos instrucciones en cada grupo de estos cuatro que hemos definido.

#### Instrucciones de transferencia de datos

Las instrucciones de transferencia de datos son dos. El código 010 copia un byte de la memoria hacia el acumulador. Para esto se necesita la **dirección** de ese byte, y esa dirección es precisamente el argumento u operando de la instrucción, y por lo tanto esa dirección está codificada en los cinco bits de operando de la instrucción.

El código 011 es la operación inversa, es decir, copia el contenido del registro acumulador en una posición de memoria. La dirección de esa posición está, también, determinada por los cinco bits de operando.

En cualquiera de los dos casos, luego de ejecutarse la instrucción, el valor del PC queda valiendo 1 más de lo que valía antes, es decir, se incrementa en 1. Esto permite que el ciclo de instrucción pase a la instrucción siguiente.

El efecto sobre el estado de la máquina es exactamente lo que se describe aquí: cambia el valor del acumulador, en el caso de la instrucción 010, o el valor de una posición de memoria, en el caso del código 011, y el valor del PC se incrementa en 1. No ocurre ningún otro cambio en el estado de la máquina, ni en los registros ni en la memoria.

#### Instrucciones aritméticas

Las instrucciones aritméticas también son dos. Si el código es 100, la CPU va a buscar el valor contenido en la dirección dada por el operando, y lo suma al acumulador. Es decir, se suman el valor que tuviera anteriormente el acumulador, con el valor que proviene de esa posición de memoria. El resultado queda en el acumulador. El valor de la posición de memoria no varía.

Si el código es 101, la operación es una resta, que como sabemos consiste en complementar a 2 el operando y luego sumar. El resultado, igual que en la instrucción de suma, queda en el acumulador, y la posición de memoria queda sin cambios. Como en las instrucciones de transferencia de datos, el registro PC se incrementa en 1. Decimos que el PC **queda apuntando** a la siguiente instrucción.

#### Instrucciones de salto

Las dos instrucciones **de salto, o de transferencia de control**, tienen un efecto diferente. Funcionan modificando exclusivamente el valor del registro PC. En ambos casos, el operando es un valor con signo a cinco bits. En el caso del código 110, ese valor se suma algebraicamente al valor que tuviera hasta el momento el registro PC. Con lo cual el PC queda apuntando a alguna posición de memoria por delante o por detrás de donde estaba antes. Así, el ciclo de instrucción siguiente va a leer la instrucción ubicada en esa nueva dirección que ahora está contenida en el PC.

El código 110 es una instrucción de salto incondicional, es decir, siempre provoca un salto en la ejecución. En el caso del código 111, el salto es condicional, y depende del valor del registro acumulador. Si el acumulador tiene un valor 0, se produce el salto, sumando el valor del desplazamiento al registro PC. Pero si el acumulador no vale cero, simplemente se incrementa el PC en 1 como en el resto de las instrucciones; y el control sigue secuencialmente como es normal.

#### Otras instrucciones

Hasta el momento no hemos explicado cómo se detiene la máquina. El ciclo de instrucción continuamente va a ejecutar la instrucción siguiente, sin parar nunca. Para terminar la ejecución usamos la instrucción 001. El programa se detiene, y el estado final de la máquina queda con los valores que recibieron por última vez los registros y la memoria. El valor del PC no cambia.

La operación 000 no tiene ningún efecto sobre el estado del MCBE, salvo incrementar el PC. Ningún otro registro ni posición de memoria cambia su valor.

### Ciclo de instrucción

Ahora podemos definir con más rigurosidad lo que se entiende por **ciclo de instrucción**. El MCBE inicia su operación con todos los contenidos de la memoria y registros en 0, y se pone a ejecutar continuamente el ciclo de instrucción. Para esto repite continuamente las fases siguientes.

- 1. Copia en el registro IR la instrucción cuya dirección está en el PC. Como el PC comienza con un valor 0, esto significa copiar la instrucción almacenada en la dirección 0 hacia el IR.
- 2. Decodifica la instrucción, lo que significa separar la instrucción en sus dos componentes, que son el código de operación, de tres bits, y el operando o argumento, de cinco bits.
- 3. Se ejecuta la instrucción, lo que significa que va a haber algún efecto sobre el estado de la máquina. Si es una instrucción de transferencia de datos, cambiará el registro acumulador o alguna posición de memoria; si es una instrucción aritmética, cambiará el valor del registro acumulador; si es de transferencia de control, cambiará el valor del PC, etc.

4. Una vez ejecutada la instrucción, se vuelve a repetir el ciclo, leyendo la siguiente instrucción que haya que ejecutar, que será aquella cuya dirección esté contenida en el PC.

# Programación del MCBE

¿Cómo es, entonces, un programa para esta máquina teórica? Es una sucesión de bytes, que representan instrucciones y datos, contenidos en la memoria a partir de la dirección 0, y donde cada byte va a ser interpretado como instrucción o como dato según lo diga el programa. Como el estado inicial de la máquina es con todos los valores en 0, lo único que puede decirse con seguridad es que la primera posición de la memoria contiene una instrucción. Pero a partir de allí, el desarrollo de la ejecución va a ser dado por las instrucciones particulares que contenga el programa.

Dirección	Contenido
00000	01000110
00001	10000111
00010	01101000
00011	00100000
00100	
00101	
00110	00001100
00111	0000001
01000	

- En este programa en particular, la primera instrucción es 010 00110, que es una instrucción de transferencia de datos de la posición 6 al acumulador.
- La segunda instrucción es 100 00111, que es una suma del valor que haya en la posición 7 al acumulador.
- La tercera instrucción es 011 01000, que significa transferir el valor que haya en el acumulador a la posición 8.
- Y la cuarta instrucción es 001 00000, que es la instrucción de parada, con lo cual termina el programa.
- Todas éstas eran las instrucciones del programa. En las posiciones 6 y 7 de la memoria tenemos datos almacenados en complemento a 2 sobre ocho bits. Estos datos son el número 12, en la posición 6, y el número 1 en la posición 7.
- En las restantes posiciones de memoria hay contenidos nulos, o sea, todos los bits en 0, y no los escribimos para no complicar más el diagrama.

### Traza de ejecución

¿Qué es realmente lo que hace este programa, y cuál es el resultado de ejecutarlo? Para poder saberlo, lo más conveniente es hacer una **traza del programa**. Una traza es un diagrama o planilla donde preparamos **columnas** con los nombres de los **registros**, **la memoria y la salida**, para poder ir simulando manualmente la ejecución, e ir anotando qué valores toman esos registros; es decir, cuáles son los sucesivos estados del MCBE.

Para cada instrucción que se ejecute usaremos un renglón de la planilla.

En la traza solamente escribiremos los elementos del estado **que se modifiquen** en cada paso. En la columna de MEMORIA anotaremos cuándo hay una operación de escritura en memoria, en la columna de SALIDA anotaremos cuando haya un contenido que se escriba en pantalla, etc.

Este programa en particular presenta la traza que veremos a continuación.

Queda como ejercicio seguir la traza e interpretar qué está ocurriendo en cada momento con cada uno de los registros y las posiciones de memoria.

Dirección	Contenido
00000	01000110
00001	10000111
00010	01101000
00011	00100000
00100	
00101	
00110	00001100
00111	0000001
01000	00001101

## Ayuda

- 000 No operación
- 001 Parada
- lacksquare 010 Mem ightarrow Ac
- lacksquare 011 Ac ightarrow Mem
- 100 Sumar al Ac
- 101 Restar al Ac
- 110 Salto

#### ■ 111 Salto cond

# **Preguntas**

- 1. El MCBE, ¿puede encontrar una instrucción que no sea capaz de decodificar?
- 2. Supongamos que hemos almacenado en la posición 14 un dato numérico que representa la edad de una persona. ¿Qué pasa si en algún momento de la ejecución el PC contiene el número 14? ¿Qué pasa si esa persona tiene 33 años?
- 3. ¿Podría aumentarse la capacidad de memoria del MCBE? ¿Esto requeriría algún cambio adicional a la máquina?

Proponemos como ejercicio **examinar** las siguientes frases, tomadas de exámenes de la materia, a ver si descubrimos qué está mal en cada una de ellas.

- 1. El primer paso del ciclo de instrucción es cargar el IR en el PC.
- 2. Lo que hacen las instrucciones de salto es cambiar el efecto de las instrucciones en los registros del MCBE.
- 3. Las instrucciones de salto sirven como desplazamiento de instrucciones y cambian el orden de los registros.
- 4. La instrucción de salto incondicional es un desplazamiento sin signo, la de salto condicional es un desplazamiento con signo.
- 5. Las instrucciones de salto copian el contenido de la dirección en el acumulador.

## El Software

En esta parte de la unidad, **El Software**, nos interesa conocer el proceso de desarrollo de software, desde el punto de vista de la organización de computadoras. Explicaremos cómo se llega desde un programa, en un lenguaje de alto o bajo nivel, a obtener una sucesión de instrucciones de máquina para un procesador.

## Lenguajes de bajo nivel

# Lenguaje de máquina o código máquina

Hemos visto un conjunto de instrucciones y convenciones sobre cómo se utilizan los datos en el MCBE, que es el llamado **lenguaje de máquina** del MCBE. En este lenguaje, las operaciones y los datos se escriben como secuencias de dígitos binarios.

Por supuesto, escribir un programa para el MCBE y **depurarlo**, es decir, identificar y corregir sus errores, es una tarea muy dificultosa, porque los códigos de operación, las direcciones y los datos, fácilmente terminan confundiéndonos. Para facilitar la

programación, se ha definido un lenguaje alternativo llamado el **ensamblador** del MCBE.

### Lenguaje ensamblador

Cuando escribimos un programa en el lenguaje **ensamblador** del MCBE, las instrucciones se corresponden una a una con las del programa en lenguaje de máquina. Pero en el lenguaje ensamblador del MCBE:

- En lugar de códigos de tres bits usamos unas abreviaturas un poco más significativas (llamadas los mnemónicos de las instrucciones).
- En lugar de direcciones de cinco bits para los datos, usamos unos nombres simbólicos (rótulos o etiquetas) que hacen referencia a esas direcciones.
- Para las instrucciones de salto, en lugar de desplazamientos, también usamos rótulos o etiquetas para indicar la instrucción del programa adonde deseamos saltar.

Cada CPU del mundo real tiene su propio lenguaje de máquina, y aunque mucho más poderosos y de instrucciones más complejas, se parecen bastante, en líneas generales, al lenguaje de máquina del MCBE. Igual que ocurre con el lenguaje de máquina, cada CPU del mundo real tiene su propio lenguaje ensamblador, basado en los mismos principios que el que mostramos aquí.

El lenguaje de máquina de cualquier CPU, y su lenguaje ensamblador (o *Assembler*), son llamados en general **lenguajes de bajo nivel**.

### Mnemónicos

Los **mnemónicos** o nombres simbólicos de las instrucciones se basan en los nombres en inglés de las operaciones correspondientes. Disponemos de los mnemónicos:

- LD para la operación de cargar el Acumulador con un contenido de memoria (código 010), y ST para la operación inversa (código 011).
- ADD para la operación de suma (código 100) y SUB para la resta (código 101).
- JMP y JZ para los saltos incondicional y condicional (códigos 110 y 111), respectivamente.
- HLT para la instrucción de parada (código 001) y NOP para la operación nula o no operación (código 000).

# **Rótulos**

Cuando necesitamos hacer referencia a una dirección, como en las operaciones de transferencia o en las aritméticas, el ensamblador nos permite independizarnos del

valor de esa dirección y simplemente indicar un **nombre simbólico o rótulo** para esa dirección. Así, un rótulo equivale en lenguaje ensamblador a la **dirección de un dato**.

Para que el programa quede completo, ese nombre simbólico debe aparecer en algún lugar del programa, al principio de la instrucción, y separado por un carácter ":" del resto de la línea.

### **Ejemplo**

Dirección	Instrucción	Rótulo	Mnemónico	Argumento
00000	01000111		LD	CANT
00001	11100100	SIGUE:	JZ	FIN
00010	01111111		ST	OUT
00011	10100110		SUB	UNO
00100	11011101		JMP	SIGUE
00101	00100000	FIN:	HLT	
00110	0000001	UNO:	1	
00111	00000011	CANT:	3	

En este ejemplo, SIGUE, FIN, UNO y CANT son rótulos. El rótulo CANT, por ejemplo, nos permite referirnos en la primera instrucción, LD CANT, a un dato declarado más adelante con ese nombre. Del mismo modo, cuando la instrucción es de salto, podemos hacer referencia a la posición de memoria donde se hará el salto usando un rótulo, como en la quinta instrucción, JMP SIGUE.

#### Rótulos en instrucciones de salto

Es importante recordar que, de todas maneras, en la traducción de ensamblador a lenguaje de máquina **para las instrucciones de salto**, el rótulo se sustituye por un **desplazamiento**, y no por una dirección.

# **Ejemplo**

■ En el ejemplo existe un rótulo SIGUE que identifica a la instrucción en la posición 1. La instrucción del ejemplo JMP SIGUE, al ser ejecutada, deriva el control a la instrucción 1. Es decir, almacena un 1 en el registro PC, para que la siguiente iteración del ciclo de instrucción ejecute la instrucción en la dirección 1 de la memoria. Sin embargo, el argumento para la instrucción JMP no vale 1 sino -3, como podemos corroborar en la columna "Instrucción" de la tabla.

## Rótulos predefinidos

Los rótulos IN y OUT vienen predefinidos en el lenguaje ensamblador de MCBE y corresponden a las posiciones de memoria 30 (para entrada) y 31 (para salida) respectivamente.

## **Ejemplo**

La instrucción en línea 2, ST OUT, almacena el contenido del acumulador en la posición 31, lo que equivale a escribir ese contenido en la salida del MCBE.

#### **Traductores**

Uno puede pensar en un programa cualquiera como si se tratara de una máquina, cuyo funcionamiento es, en principio, desconocido. Todo lo que vemos es que, si introducimos ciertos datos, de alguna forma esta "máquina" devolverá un resultado.

Si pensamos en una clase especial de estos programas, donde los datos que ingresan son a su vez un programa, y donde la salida devuelta por la máquina es, a su vez, un programa, entonces esa clase especial de programas son los **traductores**.

### **Ensambladores**

Como hemos dicho anteriormente, una CPU como el MCBE sólo sabe ejecutar instrucciones de código máquina expresadas con unos y ceros. Cuando vimos el lenguaje ensamblador del MCBE lo propusimos simplemente como una forma de abreviar las instrucciones de máquina, o como una forma de facilitar la escritura, porque los mnemónicos y rótulos eran más fáciles de memorizar y de leer que las instrucciones con unos y ceros.

Sin embargo, un programa escrito en ensamblador del MCBE podría ser traducido automáticamente, por un traductor, a código de máquina MCBE, ahorrándonos mucho trabajo y errores.

Esta clase de traductores, que reciben un programa en lenguaje ensamblador y devuelven un programa en código de máquina, son los llamados ensambladores o assemblers.

#### Ensamblador x86

Cada CPU tiene su propio lenguaje ensamblador, y existen programas traductores (ensambladores) para cada una de ellas. Por ejemplo, la familia de procesadores de Intel para computadoras personales comparte el mismo ISA, o arquitectura y conjunto de instrucciones. Cualquiera de estos procesadores puede ser programado usando un ensamblador para la familia **x86**.

Según la tradición, el primer programa que uno debe intentar escribir cuando comienza a aprender un lenguaje de programación nuevo es "Hola mundo". Es un programa que simplemente escribe esas palabras por pantalla. Aquí mostramos el clásico ejemplo de "Hola mundo" en el lenguaje ensamblador de la familia x86.

```
.globl
        _start
.text
                     # seccion de codigo
_start:
                $len, %edx # carga parametros longitud
        movl
        movl
                $msg, %ecx # y direction del mensaje
        movl
                $1, %ebx
                                 # parametro 1: stdout
        movl
                $4, %eax
                                 # servicio 4: write
                $0x80
        int
                             # syscall
                $0, %ebx
                                 # retorna 0
        movl
        movl
                $1, %eax
                                 # servicio 1: retorno de llamada
                $0x80
        int
                             # syscall
                     # seccion de datos
.data
msg:
                 "Hola, mundo!\n"
        .ascii
        len =
                 . - msg
                             # longitud del mensaje
```

Los procesadores de la familia  $\times 86$  se encuentran en casi todas las computadoras personales y notebooks.

#### **Ensamblador ARM**

Por supuesto, los procesadores de familias diferentes tienen conjuntos de instrucciones diferentes. Así, un lenguaje y un programa ensamblador están ligados a un procesador determinado. El código máquina producido por un ensamblador no puede ser trasladado sin cambios a otro procesador que no sea aquel para el cual fue ensamblado. Las instrucciones de máquina tendrán sentidos completamente diferentes para uno y otro.

Por eso, el código máquina producido por un ensamblador para x86 no puede ser trasladado directamente a una computadora basada en un procesador como, por ejemplo, ARM; sino que el programa original, en ensamblador, debería ser **portado** o traducido al ensamblador propio de ARM, por un programador, y luego ensamblado con un ensamblador para ARM.

```
.global main
main:
    @ Guarda la direccion de retorno lr
    @ mas 8 bytes para alineacion
    push {ip, lr}
```

```
@ Carga la direccion de la cadena y llama syscall
ldr r0, =hola
bl printf
@ Retorna 0
mov r0, #0
@ Desapila el registro ip y guarda
@ el siguiente valor desapilado en el pc
pop {ip, pc}
hola:
    .asciz "Hola, mundo!\n"
```

El ARM es un procesador que suele encontrarse en plataformas móviles como *tablets* o teléfonos celulares, porque ha sido diseñado para minimizar el consumo de energía, una característica que lo hace ideal para construir esos productos portátiles. Su arquitectura, y por lo tanto, su conjunto de instrucciones, están basados en esos principios de diseño.

### **Ensamblador PowerPC**

Lo mismo ocurre con otras familias de procesadores como el PowerPC, un procesador que fue utilizado para algunas generaciones de consolas de juegos, como la PlayStation 3.

```
.data
                  # seccion de variables
msg:
    .string "Hola, mundo!\n"
   len = . - msg
                      # longitud de cadena
.text
                  # seccion de codigo
    .global _start
_start:
    li 0,4
                   # syscall sys_write
   li 3,1
               # 1er arg: desc archivo (stdout)
               # 2do arg: puntero a mensaje
    lis
            4,msg@ha
                     # carga 16b mas altos de &msg
            4,4, msg@l # carga 16b mas bajos de &msg
    addi
    li 5,len
                   # 3er arg: longitud de mensaje
               # llamada al kernel
    sc
    li 0,1
               # syscall sys_exit
    li 3,1
               # 1er arg: exit code
               # llamada al kernel
    SC
```

# Lenguajes de programación

## Lenguajes de bajo nivel

Como vemos, tanto el lenguaje de máquina como el ensamblador o **Assembler** son lenguajes **orientados a la máquina**. Ofrecen control total sobre lo que puede hacerse con un procesador o con el sistema construido alrededor de ese procesador. Por este motivo son elegidos para proyectos de software donde se necesita dialogar estrechamente con el hardware, como ocurre con los sistemas operativos.

Sin embargo, como están ligados a un procesador determinado, requieren conocimiento profundo de dicho procesador y resultan poco **portables**. Escribir un programa para resolver un problema complejo en un lenguaje de bajo nivel suele ser muy costoso en tiempo y esfuerzo.

## Lenguajes de alto nivel

Otros lenguajes, los de **alto nivel**, ocultan al usuario los detalles de la arquitectura de las computadoras y le facilitan la programación de problemas de software complejos. Son más **orientados al problema**, lo que quiere decir que nos aíslan de cómo funcionan los procesadores o de cómo se escriben las instrucciones de máquina, y nos permiten especificar las operaciones que necesitamos para resolver nuestro problema en forma más parecida al lenguaje natural, matemático, o humano.

Una ventaja adicional de los lenguajes de alto nivel es que resultan más portables, y su **depuración** (el proceso de corregir errores de programación) es normalmente más fácil.

# Niveles de lenguajes

Se han diseñado muchísimos lenguajes de programación. Cada uno de ellos es más apto para alguna clase de tareas de programación y cada uno tiene sus aplicaciones.

- Entre estos lenguajes, que podemos organizar en una jerarquía, encontramos los de bajo nivel u orientados a la máquina, los de alto nivel, u orientados al problema, y algunos en una zona intermedia.
- Pero también pueden clasificarse por el paradigma de programación al cual pertenecen.
- Además, algunos son habitualmente lenguajes compilables, y otros, interpretables.

# Paradigmas de programación

La programación en lenguajes de alto nivel puede adoptar varias formas. Existen diferentes modos de diseñar un lenguaje, y varios modos de trabajar para obtener los

resultados que necesita el programador. Esos modos de pensar o trabajar se llaman paradigmas de lenguajes de programación.

Hay al menos cuatro paradigmas reconocidos, que son, aproximadamente en orden histórico de aparición, **imperativo** o procedural, **lógico o declarativo**, **funcional** y **orientado a objetos**. Los paradigmas lógico y funcional son los más asociados a la disciplina de la Inteligencia Artificial.

### Paradigma imperativo o procedural

Bajo el paradigma imperativo, los programas consisten en una sucesión de instrucciones o comandos, como si el programador diera órdenes a alguien que las cumpliera. El ejemplo en lenguaje **C** explica cuáles son las órdenes que deben ejecutarse, una por una.

```
int factorial(int n)
{
    int f = 1;
    while (n > 1) {
        f *= n;
        n--;
    }
    return f;
}
```

### Paradigma lógico o declarativo

El lenguaje Prolog representa el paradigma lógico y con frecuencia constituye el corazón de los sistemas de Inteligencia Artificial que realizan **razonamiento**.

La definición de **factorial** en lenguaje Prolog que mostramos se compone de un hecho y dos reglas. El hecho consiste en que el **factorial** de 0 vale 1. La primera regla expresa que el factorial de un número **N** se calcula como el factorial de **N-1** multiplicado por N. Es una definición **recursiva** porque la definición de la regla se utiliza a sí misma.

```
factorial(0,X):- X=1.
factorial(N,X):- N1=N-1, factorial(N1,X1), X=X1*N.
factorial(N):- factorial(N,X), write(X).
```

El usuario de este programa puede usarlo de dos maneras. Podría preguntar el valor del factorial de un número N, o consultar si es cierto que el factorial de N es otro número dado Y.

## Paradigma funcional

En el lenguaje Lisp, perteneciente al paradigma funcional, una función es un enunciado entre paréntesis que puede contener a otras funciones. En particular la definición de **factorial** presentada aquí contiene a su vez una invocación de la misma función, volviéndola una función **recursiva**.

El lenguaje Lisp utiliza notación prefija para los operadores.

### Orientación a objetos

En un lenguaje **orientado a objetos**, definimos una **clase** que funciona como un molde para crear múltiples instancias de objetos que se parecen entre sí, ya que tienen los mismos datos que los componen y la misma funcionalidad. Los objetos creados se comunican entre sí por **mensajes**, disparando **métodos** o conductas de otros objetos.

```
class Combinatoria():
    def factorial(self,n):
        num = 1
        while n > 1:
            num = num * n
            n = n - 1
        return num

c = Combinatoria()
a = c.factorial(3)
print a
```

En el ejemplo de programación orientada a objetos en Python, definimos una clase **Combinatoria** que producirá objetos con la conducta **factorial**. El programa crea un objeto, instancia de la clase Combinatoria, llamado **c**, al cual se le envía el mensaje **factorial**, que dispara la conducta correspondiente especificada en el método del mismo nombre. Finalmente se imprime su valor.

# Compiladores e intérpretes

Los traductores de lenguajes de alto nivel pueden funcionar de dos maneras: o bien producen una versión en código máquina del programa fuente (compiladores) o

bien analizan instrucción por instrucción del programa fuente, y además de generar una traducción a código máquina de cada línea, la ejecutan (**intérpretes**).

Luego de la compilación, el programa en código máquina obtenido puede ser ejecutado muchas veces. En cambio, el programa interpretado debe ser traducido cada vez que se ejecute.

# Velocidad de ejecución

- Una ventaja comparativa de la compilación respecto de la interpretación es la mayor velocidad de ejecución. Al separar las fases de traducción y ejecución, un compilador alcanza la máxima velocidad de ejecución posible en un procesador dado.
- Por el contrario, un intérprete alterna las fases de traducción y ejecución, por lo cual la ejecución completa del mismo programa tardará algo más de tiempo.

#### **Portabilidad**

- El código interpretado presenta la ventaja de ser directamente portable. Dos plataformas diferentes podrán ejecutar el mismo programa interpretable, siempre que cuenten con intérpretes para el mismo lenguaje.
- Por el contrario, un programa compilado está en el código de máquina de alguna arquitectura específica, así que no será compatible con otras.

# Ciclo de compilación

### Terminología

- Cuando utilizamos un compilador para obtener un programa ejecutable, el programa que nosotros escribimos, en algún lenguaje, se llama programa fuente, y estará generalmente contenido en algún archivo fuente.
- El resultado de la traducción será un archivo llamado objeto conteniendo las instrucciones de código máquina equivalentes.
  - Sin embargo, este archivo objeto puede no estar completo, ya que el programador puede hacer uso de rutinas o funciones que vienen provistas con el sistema, y no necesita especificar cómo se realizan esas funciones.
  - Al no aparecer en el programa fuente, esas funciones no aparecerán en el archivo objeto.
  - Por ejemplo, cualquier programa "Hola Mundo", en cualquier lenguaje, imprime en pantalla un mensaje; pero la acción de imprimir algo en pantalla no es trivial ni sencilla, y la explicación de cómo se hace esta acción no está contenida en esos programas. En su lugar, existe una

llamada a una función de impresión cuya definición reside en algún otro lugar.

- Ese otro lugar donde están definidas funciones disponibles para el programador son las bibliotecas. Las bibliotecas son archivos conteniendo grupos o familias de funciones.
- El proceso de **vinculación**, que es posterior a la traducción, debe buscar en esas bibliotecas la definición de las funciones faltantes en el archivo objeto.
- Si la vinculación resulta exitosa, el resultado final es un programa ejecutable.

#### Fases del ciclo de compilación

- El desarrollador que necesita producir un archivo ejecutable utilizará varios programas de sistema como editores, traductores, vinculadores, etc.
- En algún momento anterior, alguien habrá creado una biblioteca de funciones para uso futuro. Esa biblioteca consiste en versiones objeto de varias funciones, compiladas, y reunidas con un programa bibliotecario, en un archivo.
- Esa biblioteca es consultada por el vinculador para completar las referencias pendientes del archivo objeto.
- En resumen, la primera fase del ciclo de compilación es necesariamente la edición del programa fuente.
- Luego, la traducción para generar un archivo objeto con referencias pendientes
- Luego, la vinculación con bibliotecas para resolver esas referencias pendientes.
- El resultado final del ciclo de compilación es un ejecutable.

## Entornos de desarrollo o IDE

Muchos desarrolladores utilizan algún **ambiente integrado de desarrollo (IDE)**, que es un programa que actúa como intermediario entre el usuario y los componentes del ciclo de compilación (editor, compilador, vinculador, bibliotecas).

El entorno integrado facilita el trabajo al desarrollador automatizando el proceso. Sin embargo, aunque el ambiente integrado lo oculte, el sistema de desarrollo **sigue trabajando como se ha descrito**, con fases separadas y sucesivas para la edición, traducción, vinculación y ejecución de los programas.

# Sistemas de Cómputo

Un sistema de cómputo es un conjunto de elementos electrónicos organizados para permitir el procesamiento de información. A lo largo del tiempo los sistemas de cómputo han evolucionado notablemente, y en este material vamos a ver las cosas más importantes que han ocurrido durante esta evolución.

# Evolución de los sistemas de cómputo

Los sistemas de cómputo constituyen una industria, y como en toda industria, existe la competencia entre los fabricantes, que buscan obtener más mercado mejorando las características de sus productos. En ninguna otra industria como en la computación es tan notable el crecimiento de las capacidades de los sistemas de cómputo y, simultáneamente, la reducción de costos y tamaños físicos de los componentes.

- Las sucesivas generaciones de sistemas de cómputo han ido creciendo en la velocidad de procesamiento y capacidad de memoria, así como en las capacidades de los discos y otras unidades de almacenamiento.
- Al mismo tiempo, se ha reducido notablemente el tamaño del sistema como un todo. Esto último se ha logrado a través de sucesivos avances en la integración de los componentes.
- La mayor integración ha facilitado la economía de escala, manteniendo o reduciendo en general los costos de producción.

Sin embargo, los diferentes componentes se producen con procesos de fabricación diferentes y que incorporan avances cada uno a su ritmo, por lo cual no siempre más rápido o más pequeño es mejor, sino que lo más importante es que las partes del sistema funcionen en armonía. De lo contrario, pueden presentarse desbalances que impidan que el sistema funcione en forma óptima.

#### Antecedentes históricos

En la antigüedad se crearon los que podríamos llamar sistemas de cómputo primitivos, aunque ingeniosos. Aquí citamos unos pocos ejemplos, como el ábaco chino; los quipus incas; los dispositivos de cálculo analógicos aparecidos en diferentes civilizaciones, como los que permitían calcular la torsión de los tensores de las catapultas romanas; el misterioso Mecanismo de Anticitera, un aparato astronómico encontrado entre los restos de un naufragio griego.

Más cerca de nuestros días, se crearon artefactos parecidos a las calculadoras y computadoras actuales, pero con la tecnología disponible en esos momentos, lo que lógicamente los hacían incómodos, o pobres en resultados, en comparación con las herramientas electrónicas de hoy.

Supuestamente construido por científicos griegos, el instrumento conocido como Mecanismo de Anticitera data de entre los años 150 a. C. y 100 a. C., o, según una observación reciente, del año 200 a. C.

Inventada en 1642 por el filósofo y matemático francés Blaise Pascal (1623-1662), la Pascalina permitía sumar y restar dos números de manera directa y hacer la multiplicación y división por repetición.

#### La Tabuladora de Hollerith

Entre estos proto-sistemas de computación es especialmente notable, por varios motivos, la máquina de Hollerith. Herman Hollerith trabajaba para la Oficina de Inmigración de EEUU hacia fines del siglo XIX, en momentos en que se formó una gran corriente inmigratoria desde Europa. La gran cantidad de personas que llegaban a radicarse, nunca vista antes, hizo desbordar el sistema de información nacional. Los responsables del censo poblacional se encontraban con un gran problema.

Mucho antes de Hollerith, un tapicero francés, Jacquard, había ideado un telar que se configuraba usando tarjetas perforadas. Alimentado con estas tarjetas, el telar creaba automáticamente el dibujo deseado. Inspirado en el telar de Jacquard, Hollerith creó un sistema de cómputo automático **electromecánico** basado en tarjetas perforadas. Cada tarjeta representaba a un individuo. La tarjeta se dividía en campos que representaban los atributos o características personales del individuo (nacionalidad, fecha de nacimiento, sexo, estado civil, etc). Al llegar un individuo, el oficial de inmigración le presentaba un cuestionario y codificaba sus respuestas con una perforación en cierto lugar de cada campo.

La Tabuladora de Hollerith era un dispositivo que contabilizaba perforaciones en esas tarjetas. Podía ser programada para contar la cantidad de individuos por nacionalidad, por edad, por sexo, etc., o por varios de estos atributos simultáneamente. De esa manera el censo nacional pudo lograrse en muchísimo menos tiempo que con los anteriores métodos manuales.

La máquina de Hollerith es especialmente interesante porque sienta las bases del cálculo digital como se conocerá en los años siguientes (de hecho, las tarjetas perforadas siguieron utilizándose hasta muchos años después como medio de entrada, para codificar programas y datos), porque demostró el poder del cómputo automático con una aplicación concreta e importante, y porque, tomando su invento como punto de partida, Hollerith formó una importante empresa de computación que tuvo gran influencia en el desarrollo de la tecnología del siglo XX.

### Primera generación

Las primeras computadoras electrónicas usaban **bulbos**, **tubos de vacío**, **o válvulas**, como interruptores, implementando dispositivos que realizaban operaciones aritméticas y lógicas.

Dado el momento histórico en el cual aparecieron estos equipos, los objetivos con los cuales se creaban eran, con frecuencia, los usos militares. Las máquinas de esta generación eran grandes instalaciones que ocupaban una habitación, y sus miles de válvulas disipaban una gran cantidad de calor, que debía combatirse con sistemas de aire acondicionado.

El **ENIAC** es un claro representante de esta clase de máquinas. Pesaba 30 toneladas, y ocupaba un recinto de 140 m². Era capaz de ejecutar 5000 operaciones de suma por segundo. El ENIAC usaba 18000 válvulas de vacío: cada dos días, en promedio, una de ellas fallaba, y debía ser reemplazada con un procedimiento que llevaba quince minutos.

El ENIAC no era una máquina de Von Neumann porque su programa no residía en memoria, sino que la computadora se programaba con un intricado sistema de interruptores manuales. Entre las máquinas de esta generación se encuentra la primera computadora de programa almacenado según el modelo de Von Neumann. Fue el IAS (siglas de **Institute for Advanced Study**), que usaba 1500 tubos de vacío y tenía 5 kB de memoria.

#### El tubo de vacío

El tubo de vacío o válvula termoiónica fue patentado por Edison y fue sucesivamente modificado para diferentes usos en electrónica hasta llegar a ser usado en las computadoras de la primera generación. Una de sus variedades, el triodo, tiene tres electrodos o terminales conectados al resto del circuito, llamados cátodo, ánodo y rejilla o grilla de control. En éstos, la corriente eléctrica se dirige siempre desde el cátodo al ánodo, pero únicamente circula cuando existe una determinada carga negativa en la grilla, que funciona como un interruptor.

De esta manera se puede controlar el flujo de corriente por un circuito y construir dispositivos que implementen funciones lógicas. Así, dos válvulas de este tipo, conectadas en serie, simulan una función lógica de conjunción o **AND**; dos válvulas conectadas en paralelo, simulan una disyunción u **OR**, etc. Con válvulas termoiónicas es posible además crear un dispositivo que mantenga permanentemente un cierto estado eléctrico, y que por lo tanto **puede almacenar un bit de información**.

La grilla de las válvulas necesita alcanzar una alta temperatura para poder gobernar el flujo de electrones. De ahí que el consumo de electricidad fuera altísimo y su funcionamiento sumamente lento. Unido esto a una alta tasa de fallos, las válvulas fueron rápidamente abandonadas en favor de una tecnología más conveniente, el transistor.

## Memorias de núcleos

Las primeras implementaciones de la memoria principal (memorias de núcleos o core memories) fueron realizadas con pequeños anillos metálicos atravesados por

alambres. El flujo eléctrico que conducían estos alambres magnetizaba en forma estable los anillos, que almacenaban un bit de información cada uno. El sistema de memoria podía leer, más tarde, la **polaridad** magnética de cada anillo, y así se recuperaba el valor binario que había sido almacenado en ese bit.

La tecnología de las memorias ha evolucionado espectacularmente desde la creación de las primitivas memorias de núcleos. Hoy, cincuenta años después, existen memorias de bajo costo, menor tamaño, mayor velocidad, y capacidad millones de veces superior. Una memoria Micro-SD de hoy, por ejemplo, puede alojar 32 GiB de información en una centésima parte del espacio ocupado por un 1 Kib de memoria de núcleos.

### **ENIAC**

Presentado en 1946, **ENIAC** es reconocido como el primer computador digital, completamente electrónico, de propósito general. Usaba números representados en base 10. Tenía una capacidad de memoria de 1000 bits donde podía almacenar unos veinte números decimales de diez dígitos.

El ENIAC fue propuesto para cómputos de trayectoria de proyectiles, aplicación en la que logró reducir el tiempo de cómputo de una tabla de datos, de 20 horas a 30 segundos. Sin embargo, la guerra terminó antes de que pudiera ser realmente aplicado, por lo que se lo destinó a otros usos. Por este hecho, llamó la atención sobre la capacidad de las computadoras de ser destinadas a propósitos generales, en lugar de las máquinas de programa cableado que existían hasta entonces y que eran preparadas específicamente para una única tarea.

Pero más notable todavía es que cincuenta años y varias generaciones de computadoras después, en 1997, el proyecto **ENIAC-on-a-chip** construyó un circuito integrado completamente equivalente al ENIAC... del tamaño de una moneda (y habrían cabido muchos más en el mismo espacio).

#### Clementina

¿Qué pasaba en nuestro país durante estas épocas? La actividad de la computación aquí no había comenzado. Recién a principios de los años 60 la universidad argentina decidió hacer una importante inversión, que fue la compra de una computadora de primera generación, bautizada aquí **Clementina**. El video adjunto cuenta interesantes detalles técnicos de la computadora, muestra cómo eran las personalidades involucradas por ese entonces en el proyecto científico y tecnológico argentino, y explica el contexto histórico en el que fue iniciado (y, lamentablemente, truncado) ese proyecto.

# Segunda generación

#### Semiconductores

En 1948 los físicos habían descubierto que combinando, en ciertas proporciones, elementos que eran vecinos en la Tabla Periódica, se creaban nuevos materiales con un desbalance de electrones; y que de esta manera se podía controlar el sentido de las corrientes eléctricas que atravesaban esos materiales. Así fue inventado un componente electrónico revolucionario, el **transistor**, que era básicamente un **triodo de estado sólido**, es decir, podía cumplir el mismo papel en un circuito que la válvula termoiónica de tres electrodos, pero era construido de una forma completamente diferente.

Esto significa que las mismas funciones lógicas de los interruptores, que en las computadoras de primera generación eran cumplidas por las válvulas termoiónicas, podían ser resueltas con dispositivos mucho más pequeños, de mucho menor consumo, con tiempos de reacción mucho menores y mucho más confiables. El impacto tecnológico y económico de este avance fue importantísimo y la computación "despegó". Fue posible aumentar la complejidad de las funciones, creando CPUs mucho más poderosas.

Decimos que esta segunda generación de computadoras fue construida con dispositivos **discretos**, es decir, separados, para distinguirla de la generación siguiente, donde esos dispositivos fueron **integrados**.

#### El transistor

El **transistor** consiste en tres pequeñas piezas, puestas en contacto entre sí, hechas de materiales especialmente preparados. Estas piezas consisten, cada una, de un núcleo de un cierto elemento, conteniendo impurezas de un segundo elemento diferente.

Si se contamina, en forma controlada, un núcleo principal de germanio o silicio, con una pequeña proporción de impurezas de boro, aluminio, arsénico, o galio, el material resultante tiene propiedades de conductividad especiales.

Según la combinación de los elementos, el material será de tipo **P** (atrae electrones de materiales cercanos) o de tipo **N** (emite electrones a los materiales cercanos). Disponiendo en capas alternadas tres pequeños bloques de materiales de tipos P y N se construyen dispositivos de tipo **PNP** o de tipo **NPN**. La capa central (llamada la **base** del transistor) actúa como la grilla de las válvulas: controla el paso de corriente a través de las otras dos capas (llamadas **colector** y **emisor** del transistor).

Gracias a estas propiedades el transistor funciona como un interruptor, con el cual se pueden implementar todas las funciones lógicas necesarias en los circuitos de la CPU y otros componentes de las computadoras. El transistor resulta así un reemplazo eficaz de las antiguas válvulas termoiónicas.

## Minicomputadoras

Los transistores abarataron las computadoras y redujeron su tamaño. Algunas de las desarrolladas en esta época recibieron el nombre de **minicomputadoras**.

El PDP-1 fue uno de los primeros computadores que pudieron ser accedidos masivamente por los estudiantes de computación. Tenía un **sistema de tiempo compartido** (time-sharing) que hacía posible la utilización de la máquina por varios usuarios a la vez. Tenía 144 KB de memoria principal y ejecutaba 100.000 instrucciones por segundo.

# Tercera generación

A mediados de los 60 se desarrollaron los circuitos integrados o microchips, que empaquetaban una gran cantidad de transistores en un solo componente, con importantes mejoras en el aspecto funcional y en la economía de la producción de computadoras. Aparecieron computadoras más baratas que llegaron a empresas y establecimientos educativos más pequeños, popularizándose el uso de la computación.

Los fabricantes comenzaron a producir familias de computadoras **compatibles**, comenzando con el System/360 de IBM. Los productos de la misma familia utilizaban el mismo lenguaje ensamblador, lo que permitía la portabilidad de los programas entre diferentes computadoras. El usuario podía hacer crecer su infraestructura de cómputo sin perder la inversión hecha en software.

También aparecieron las primeras **supercomputadoras**, como el Cray-1, en 1976, que ejecutaba 160 millones de instrucciones por segundo y tenía 8 MiB de memoria principal.

El microprocesador desarrollado por Intel reunió la mayor parte de las funciones de las computadoras en un solo microchip. La existencia del microprocesador favoreció la creación de una industria de las computadoras personales. En 1982 IBM propuso el PC (Personal Computer), un computador personal o microcomputador del cual descienden la mayoría de las computadoras domésticas y de oficina que se usan hoy. Al contrario que las computadoras de hasta entonces, construidas con procedimientos y componentes propios del fabricante, y a veces secretos, la arquitectura abierta del PC utilizaba componentes existentes y conocidos, y estaba públicamente documentada; de manera que otras empresas podían libremente fabricar componentes compatibles con esta computadora.

#### Circuitos integrados

Los circuitos integrados fueron el resultado de un proceso de fabricación completamente nuevo llamado fotomicrolitografía. Los ingenieros preparaban un diagrama del circuito deseado, con sus transistores, conexiones y demás componentes, y el

diagrama se reducía por medios ópticos hasta un tamaño casi microscópico. La imagen resultante se grababa sobre un sustrato de silicio.

Repitiendo el procedimiento con diferentes diagramas, sobre sucesivas capas de materiales semiconductores y aislantes, se lograba la miniaturización de un circuito completo con miles de transistores en un espacio muy reducido. Los modernos circuitos integrados reúnen miles de millones de transistores en menos de un centímetro cúbico de volumen.

## Microprocesador

Un programador utiliza un microprocesador a través de su **conjunto de instrucciones** (aritméticas, de transferencia, de salto, etc.). Por otro lado, el microprocesador tiene un cierto comportamiento, que el programador necesita conocer: qué papeles cumplen sus registros, qué efecto tienen las instrucciones sobre esos registros, qué modos de acceder a los datos son posibles, etc. Este comportamiento puede llamarse un **modelo de programación** del microprocesador.

Este conjunto de instrucciones y ese modelo de programación, reunidos, son la arquitectura del conjunto de instrucciones del microprocesador, abreviadas ISA por Instruction Set Architecture.

Este ISA ha sido implementado de alguna forma en el microprocesador, es decir, los ingenieros han definido un cierto circuito formado por transistores, compuertas y otros componentes, que hace que el microprocesador funcione de esta manera. Pero a medida que avanzan las tecnologías disponibles para la fabricación de los procesadores, aparecen nuevas formas de implementar ese funcionamiento. Un nuevo modelo de microprocesador podría tener mayores capacidades, sin cambiar el ISA. Por ejemplo, podría tener más de una ALU para realizar los cómputos más rápidamente, en forma paralela; pero manteniendo el mismo conjunto de instrucciones y el mismo modelo de programación de antes.

Es conveniente que estos cambios queden invisibles al programador, porque así él seguirá programando de la misma manera y seguirá corriendo sus programas sin necesidad de modificarlos.

La forma de implementar una arquitectura es llamada la **microarquitectura** del microprocesador. Una familia de microprocesadores puede evolucionar con cambios invisibles, cambiando su microarquitectura, sin cambiar la **arquitectura** y sin romper la compatibilidad con los productos anteriores.

Una familia de microprocesadores también puede ampliar su conjunto de instrucciones, pero manteniendo intactas todas las de los productos anteriores. Esta forma de compatibilidad se llama a veces retrocompatibilidad o **compatibilidad hacia atrás**.

# Cuarta generación

Gracias a nuevos procesos de fabricación de circuitos integrados, se logró cada vez mayor miniaturización de componentes.

■ SSI: de 10 a 100 componentes por chip

MSI: de 100 a 1.000
LSI: de 1.000 a 10.000
VLSI: de 10.000 a 100.000

ULSI: más de 100.000 (típicamente, millones de componentes por chip)

Ya en 1965, Gordon Moore había enunciado la observación de que, cada año y medio, los fabricantes de computadoras ponían el doble de transistores en un procesador que en el modelo anterior. Unido a que las velocidades de reloj aumentaban casi en la misma proporción, este hecho daba una curva de poder de procesamiento claramente creciente año tras año.

Esta mejora en el procesamiento era lo que mantenía en crecimiento a la industria del hardware, al generar constantemente nueva demanda del mercado. Renovando su equipamiento cada tres años, un usuario duplicaba su capacidad de procesamiento. Esta tendencia continuó hasta entrado el siglo XXI. Sin embargo, los procesadores pronto encontraron obstáculos que forzaron a un cambio de paso.

- Los componentes se acercaban entre sí cada vez más
- Las señales eléctricas entre los componentes cada vez tardaban menos en llegar
- Los ciclos de reloj debían acortarse para reaccionar a tiempo ante la llegada de las señales
- Más ciclos de reloj por segundo implicaban mayor consumo de energía
- Debido a la mayor energía consumida, el calor disipado era cada vez mayor, agravado por el hecho de que los componentes estaban cada vez más cerca
- Los diseñadores debieron enfrentar este problema desde múltiples ángulos: disminuyendo la velocidad de reloj; dividiendo los circuitos en núcleos o cores que pueden funcionar independientemente, y agregando a los microchips funciones de monitoreo capaces de desactivar parte de los circuitos mientras no se utilizaban
- Esta nueva etapa de los sistemas de cómputo suele llamarse la Era del Multicore.

Una consecuencia importante de la Era del Multicore es que la mejora en velocidad de ejecución ya no se logra simplemente comprando hardware nuevo; sino que los programas deben ser especialmente escritos para aprovechar las características de **procesamiento paralelo** de los procesadores multicore. La Ley de Moore se sigue cumpliendo, sólo que ahora los transistores se distribuyen en varios núcleos en lugar de concentrarse en un único procesador.

# Microprocesador Intel 17

El microprocesador I7 es actualmente el procesador más avanzado para computadoras personales de la firma Intel. Es retrocompatible con toda la línea de procesadores de la **arquitectura x86** desarrollada por esa firma. La cronología siguiente muestra algunos significativos cambios de microarquitectura.

- 1979: 8086, 8088, primeros microprocesadores de arquitectura x86
- 1980: 8087, coprocesador numérico
- 1982: 80286, multitarea, modo protegido
- 1985: 80386, procesador de 32 bits
- 1989: 80486, coprocesador numérico en el mismo circuito integrado
- 1993: Pentium, procesador superescalar
- 1995: Pentium Pro, procesador con ejecución fuera de orden y ejecución especulativa
- 1997: Pentium II, procesador que incorpora instrucciones vectoriales MMX
- 1999: Pentium III, incorpora instrucciones vectoriales SSE
- 2000: Pentium IV, mejoras en las instrucciones SSE
- 2006: Core 2, nueva microarquitectura, reducción del consumo, múltiples núcleos, **virtualización** en hardware, menores velocidades de reloj
- 2010: Core i3, i5, i7, procesadores con varias microarquitecturas en evolución; presentan desde 2 hasta 12 núcleos, velocidad de reloj variable

El i7 pertenece a una generación de procesadores donde, para enfrentar los problemas derivados de la microminiaturización, los diseñadores optaron por **replicar**, es decir, incorporar múltiples instancias de, las unidades de cómputo o **núcleos**.

- Cada uno de los núcleos, a su vez, puede ejecutar dos secuencias de programa independientes (dos threads o hilos).
- Cada núcleo tiene su memoria cache privada, dividida en cache de datos y de instrucciones, y además existe un segundo nivel de cache privada para datos e instrucciones a la vez.
- Además existe un tercer nivel de memoria cache compartida, donde se ubican datos que pueden ser necesitados por cualquiera de los núcleos.
- El procesador integra unidades para controlar la consistencia de la memoria interna, y para regular las diferentes actividades dentro del microchip a fin de mantener controlados el uso de energía y la generación de calor.
- En la misma "pastilla" o unidad física del microprocesador se encuentra una unidad procesadora de gráficos o GPU. Esta GPU es un procesador con una arquitectura especial, dedicado a la generación de gráficos avanzados, pero que además puede utilizarse para cómputos paralelos de propósito general.

# Tiempos de acceso a los datos

Como sabemos, no podemos utilizar un dato si no lo hacemos llegar primero al procesador o CPU; y el tiempo que tarda en llegar a un registro de la CPU, para poder operar sobre él, depende de dónde esté localizado este dato. Es interesante comparar los diferentes tiempos de demora en el acceso a un dato, o **latencia**, según en qué componente del sistema de cómputo se encuentra ese dato.

En la tabla adjunta tomamos como referencia un **ciclo de CPU**, es decir, el cambio de estado más pequeño posible en el circuito secuencial que implementa el procesador de la computadora. Los procesadores actuales utilizan pulsos de reloj de alrededor de 3 GHz, es decir, el reloj del sistema genera alrededor de 3.000.000.000 de señales por segundo; lo que da un tiempo de ciclo de unos 0.3 ns. Una instrucción de CPU puede llevar uno o varios ciclos para completarse, según la microarquitectura de la CPU. Pero la CPU, para ejecutar esa instrucción, necesita tener a disposición, en sus registros, los datos sobre los cuales debe operar.

Evento	Latencia	Escalado
Un ciclo de CPU	0.3 ns	1 s
Acceso a memoria cache	13 ns	40 s
Acceso a memoria RAM	120 ns	6 min
Disco de estado sólido	150 $\mu$ s	6 días
Disco magnético	10 ms	12 meses
$Internet\ Am\'erica \longleftrightarrow Europa$	81 ms	8 años
Reboot	5 min	32000 años

¿Cuánto lleva entonces acceder a un dato, en términos de esta duración básica de un ciclo? Si el dato está en memoria RAM, llevará unos 120 ns (unos cuatrocientos ciclos). Si está en el disco magnético, demorará unos 10 ms en llegar al procesador (unos 33000 ciclos).

Entonces, si una instrucción de CPU puede completarse en unos pocos ciclos, pero debe esperar ¡cientos o miles de ciclos! a que los datos atraviesen el sistema de memoria, habrá una **enorme** espera improductiva para la CPU. Peor aún, si el dato ¡debe llegar desde otro continente vía la Internet!

Si la CPU tuviera que esperar por los demás componentes, su **utilización** se reduciría ridículamente, y su gran velocidad de procesamiento quedaría completamente desperdiciada. Por esto es que se establece una **jerarquía de memoria**, con lugares de almacenamiento cuyas velocidades de acceso son cada vez mayores a medida que nos acercamos a la CPU en el sistema de cómputo. Por ejemplo, un dato que se encuentre en **memoria cache** ("cerca" de la CPU) tendrá una latencia de acceso

mucho menor y será preferible a tener que accederlo desde la memoria RAM (más "lejana" en el camino de los datos).

Hay muchas otras medidas técnicas que toman los ingenieros de las modernas computadoras para resolver esta disparidad de los tiempos de acceso, tales como fabricar CPUs con varias unidades de cómputo ("cores o núcleos") que funcionan en paralelo, o diseñar complejos mecanismos de cómputo que reordenan y procesan varias instrucciones a la vez, de manera de ocultar esas grandes latencias de acceso.

Para comprender mejor, desde nuestra perspectiva de humanos, la importancia relativa de esos tiempos de respuesta, la tabla se **escala** al tiempo del ciclo de CPU. Es decir, los tiempos bajo la columna "Escalado" son aquellos que tardaría cada acceso **si un ciclo de CPU durara un segundo**.

Para completar la tabla, comparamos un ciclo de CPU con el proceso de **reboot** o reencendido de la computadora ("¿probó apagar y volver a encender el equipo?").

# Sistemas Operativos

#### Del hardware al software

Hemos visto la evolución de los sistemas de cómputo desde el punto de vista del hardware, y cómo llegaron a soportar varios usuarios corriendo varias aplicaciones, todo sobre un mismo equipamiento.

Ahora veremos de qué manera evolucionó el software asociado a esos sistemas de cómputo para permitir que esos diferentes usuarios y esas diferentes aplicaciones pudieran compartir el hardware sin ocasionarse problemas unos a otros, y obteniendo el máximo rendimiento posible del equipamiento.

La pieza que falta en este complejo mecanismo es el **sistema operativo**, un software básico cuya función principal es la de ser intermediario entre los usuarios y el hardware del sistema de cómputo.

# Evolución del software de base

## **Open Shop**

Las primeras computadoras estaban dedicadas a una única tarea, perteneciente a un único usuario. Podían ser utilizadas por diferentes usuarios, pero cada uno debía esperar su turno para reprogramarlas manualmente, lo cual era laborioso y se llevaba gran parte del tiempo por el cual esos usuarios pagaban.

## Sistemas Batch

Una vez que se popularizaron las máquinas de programa almacenado, se pudo minimizar el tiempo ocioso adoptando **esquemas de carga automática** de trabajos. Un trabajo típico consistía en la compilación y ejecución de un programa, o la carga de un programa compilado más un lote de datos de entrada, y la impresión de un cierto resultado de salida del programa. Estos trabajos estaban definidos por conjuntos o lotes de tarjetas perforadas, de ahí su nombre de trabajos **por lotes** o, en inglés, *batch*.

#### Sistemas Multiprogramados

Más adelante, conforme las tecnologías permitían ir aumentando la velocidad de procesamiento, se notó que los procesadores quedaban desaprovechados gran parte del tiempo debido a la inevitable **actividad de entrada/salida**. Así se idearon sistemas que optimizaban la utilización de la CPU, al poderse cargar más de un programa en la memoria y poder conmutar el uso del procesador entre ellos. Éstos fueron los primeros **sistemas multiprogramados**.

### Sistemas de Tiempo Compartido

Una vez que llegó la posibilidad de tener varios programas coexistiendo simultáneamente en la memoria, se buscó que la conmutación del uso del procesador entre ellos fuera tan rápida, que pareciera que cada programa funcionaba sin interrupciones. Aunque el sistema era de **tiempo compartido**, el usuario utilizaba la computadora como si estuviera dedicada exclusivamente a correr su programa. Así los sistemas multiprogramados se volvieron **interactivos**.

#### Computación personal

Todas éstas fueron innovaciones de software, y fueron estableciendo principios y técnicas que serían adoptadas en lo sucesivo. Con la llegada de la computación personal, los sistemas de cómputo eran de capacidades modestas. Los **sistemas operativos** que permitían la ejecución de aplicaciones de los usuarios en estos sistemas de cómputo comenzaron pudiendo correr una sola aplicación por vez y de un solo usuario; es decir, se trataba de sistemas **monotarea** y **monousuario**.

Sin embargo, con la industria de las computadoras personales y la del software para computadoras personales traccionándose una a la otra, aparecieron sistemas operativos **multiusuario** y **multitarea**, sumamente complejos, que se convirtieron en un nuevo terreno para ensayar y mejorar las tecnologías de software y hardware.

## **Preguntas**

- ¿Cuáles son los cinco momentos evolutivos del software de base que reconocemos?
- ¿A qué se llama un trabajo batch o lote de trabajo? ¿Qué es un archivo batch en el mundo de la computación personal?
- ¿Cuál fue la necesidad que impulsó la creación de sistemas batch?
- ¿Cuál fue la necesidad que impulsó la creación de sistemas multiprogramados?
- ¿Cuál fue la necesidad que impulsó la creación de sistemas de tiempo compartido?

# Componentes del SO

Los modernos sistemas operativos tienen varios componentes bien diferenciados. Los sistemas operativos **de propósito general** normalmente se presentan en una **distribución** que contiene e integra al menos tres componentes.

#### Kernel

El componente que constituye el sistema operativo propiamente dicho es el llamado **núcleo** o **kernel**.

#### Software de sistema

Junto al kernel es habitual encontrar un conjunto de **programas utilitarios o software de sistema**, que no es parte del sistema operativo, estrictamente hablando, pero que en general es indispensable para la administración y mantenimiento del sistema.

#### ■ Interfaz de usuario

También se encuentra junto a este software del sistema alguna forma de **interfaz de usuario**, que puede ser gráfica o de caracteres. Esta interfaz de usuario se llama en general **shell**, especialmente cuando la interfaz es un procesador de comandos, basado en caracteres, y los comandos se tipean.

### Sistemas empotrados o embebidos

Hay algunas excepciones a esta estructura de componentes, por ejemplo, en los sistemas operativos **empotrados** o **embebidos** (*embedded systems*), que están ligados a un dispositivo especial y muy específico, como es el caso de algunos robots, instrumental médico, routers, electrodomésticos avanzados, etc.

Estos sistemas operativos constan de un kernel que tiene la misión de hacer funcionar cierto hardware especial, pero no necesariamente incluyen una interfaz de usuario (porque el usuario no necesita en realidad comunicarse directamente con ellos) o no incluyen software de sistema porque sus usuarios no son quienes se encargan de su mantenimiento.

# **Aplicaciones**

Un típico sistema operativo multipropósito, actual, debe dar soporte entonces a la actividad de una gran variedad de aplicaciones. No solamente a la interfaz de usuario o procesador de comandos, más el software de sistema incluido, sino también a toda la gama de aplicaciones que desee ejecutar el usuario, como programas de comunicaciones (navegadores, programas de transferencia de archivos, de mensajería); aplicaciones de desarrollo de programas (compiladores, intérpretes de diferentes lenguajes).

#### Kernel

El **kernel** o núcleo es esencialmente un conjunto de rutinas que permanecen siempre residentes en memoria mientras la computadora está operando. Estas rutinas intervienen en todas las acciones que tengan que ver con la operación del hardware.

#### Recursos

Los **recursos físicos** del sistema son todos los elementos de hardware que pueden ser de utilidad para el software, como la CPU, la memoria, los discos, los dispositivos de entrada/salida, etc. El kernel funciona no solamente como un mecanismo de administración y control del hardware o conjunto de recursos físicos, sino también de ciertos recursos del sistema que son **lógicos**, como los archivos.

#### **Procesos**

El kernel tiene la capacidad de poner en ejecución a los programas que se encuentran almacenados en el sistema. Cuando un programa está en ejecución, lo llamamos un **proceso**. El sistema operativo controla la creación, ejecución y finalización de los procesos.

## Llamadas al sistema o system calls

El kernel ofrece su capacidad de control de todos los recursos a los procesos o programas en ejecución, quienes le solicitan determinadas operaciones sobre esos recursos. Por ejemplo, un proceso que necesita utilizar un dispositivo de entrada/salida, o un recurso lógico como un archivo, hace una **petición de servicio**, **llamada al sistema, o system call**, solicitando un servicio al sistema operativo. El servicio puede tratarse de una operación de lectura, escritura, creación, borrado, etc. El sistema operativo centraliza y coordina estas peticiones de forma que los procesos no interfieran entre sí en el uso de los recursos.

## Modo dual de operación

Si los procesos de usuario pudieran utilizar directamente los recursos en cualquier momento y sin coordinación, los resultados podrían ser desastrosos. Por ejemplo, si dos o más programas quisieran usar la impresora al mismo tiempo, en el papel impreso se vería una mezcla de las salidas de los programas que no serviría a ninguno de ellos.

Como el sistema operativo debe coordinar el acceso de los diferentes procesos a esos recursos, resulta necesario que cuente con alguna forma de imponer conductas y límites a esos usuarios y programas, para evitar que alguno de ellos tome control del sistema en perjuicio de los demás. Para garantizarle este poder por sobre los usuarios, el sistema operativo requiere apoyo del hardware: su código se ejecuta en un modo especial de operación del hardware, el **modo privilegiado** del procesador.

Los modernos procesadores funcionan en lo que llamamos **modo dual** de ejecución, donde el ISA se divide en dos grupos de instrucciones.

- Ciertas instrucciones que controlan el modo de operación de la CPU, el acceso a memoria, o a las unidades de Entrada/Salida, pertenecen al grupo de instrucciones del modo privilegiado.
- Un programa de usuario que se está ejecutando funciona en modo no privilegiado, donde tiene acceso a la mayoría de las instrucciones del ISA, pero no a las instrucciones del modo privilegiado.

### Llamadas al sistema

El procesador ejecutará instrucciones del programa en ejecución en modo no privilegiado hasta que éste necesite un servicio del sistema operativo, tal como el acceso a un recurso físico o lógico.

Para requerir este servicio, el proceso ejecuta una instrucción de **llamada al sistema** o **system call**, que es la única instrucción del conjunto no privilegiado que permite a la CPU conmutar al modo privilegiado.

La llamada al sistema conmuta el modo de la CPU a modo privilegiado **y además** fuerza el salto a una cierta dirección fija de memoria donde existe código del kernel. En esa dirección de memoria existe una rutina de atención de llamadas al sistema, que determina, por el contenido de los registros de la CPU, qué es lo que está solicitando el proceso.

Con estos datos, esa rutina de atención de llamadas al sistema dirigirá el pedido al subsistema del kernel correspondiente, ejecutando siempre en modo privilegiado, y por lo tanto, con completo acceso a los recursos.

El subsistema que corresponda hará las verificaciones necesarias para cumplir el servicio:

- El usuario dueño del proceso, ¿tiene los permisos necesarios?
- El recurso, ¿está disponible o está siendo usado por otro proceso?
- Los argumentos proporcionados por el proceso, ¿son razonables para el servicio que se pide?, etc.

Si se cumplen todos los requisitos, se ejecutará el servicio pedido y luego se volverá a modo no privilegiado, a continuar con la ejecución del proceso.

# Ejecución de aplicaciones

Al ejecutar procesos de usuario o de sistema se pone en juego una jerarquía de piezas de software que ocupa varios niveles.

Normalmente, cualquier aplicación que funcione en el sistema, ya sean las del sistema o las generadas por el usuario, competirá con las demás por los recursos en igualdad de condiciones.

Todas las aplicaciones, en algún momento, requieren funciones que ya están preparadas para su uso y almacenadas en **bibliotecas** especializadas en algún área.

Algunas aplicaciones pueden requerir funciones matemáticas; otras, de gráficos; algunas, de comunicaciones. Todas ellas requerirán, sin duda, funciones de entrada/salida. Cada grupo de estas funciones está encapsulado en una o varias bibliotecas que forman parte del sistema.

La **vinculación** de los programas de usuario con las bibliotecas puede hacerse al tiempo de compilación o, cuando las bibliotecas son **de carga dinámica**, al tiempo de ejecución.

Al ejecutarse los procesos, normalmente las bibliotecas necesitan recurrir a servicios del kernel para completar su funcionamiento. Los diferentes subsistemas del kernel se ocupan de cada clase de servicios y de manejar diferentes clases de recursos.

# Por ejemplo:

- Si un proceso necesita solicitar más memoria durante la ejecución, la pedirá al subsistema de gestión de memoria.
- Cada vez que un proceso escriba datos en un archivo, estará comunicándose, a través de una biblioteca, con el subsistema de gestión de archivos.
- Si un proceso necesita enviar o recibir datos a través de la red, el kernel pondrá en funcionamiento el driver de la interfaz de red, la pieza de software que sabe comunicarse con ese hardware.

La comunicación entre los procesos de usuario y sus bibliotecas, por un lado, y el kernel y sus subsistemas, por otro, se produce cuando ocurre una llamada al sistema o system call. Es en este momento cuando se cruza el límite entre modo usuario y modo privilegiado, o espacio de usuario y espacio del kernel.

# Una cronología de los SO

Entre la década de 1960 y principios del siglo XXI surgieron gran cantidad de innovaciones tecnológicas en el área de sistemas operativos. Muchas de ellas han tenido éxito más allá de los fines experimentales y han sido adoptadas por sistemas operativos con gran cantidad de usuarios. Diferentes sistemas operativos han influido en el diseño de otros posteriores, creándose así líneas genealógicas de sistemas operativos.

Es interesante seguir el rastro de lo que ocurrió con algunos sistemas importantes a lo largo del tiempo, y ver cómo han ido reconvirtiéndose unos sistemas en otros.

- Por ejemplo, el sistema de archivos diseñado para el sistema operativo CP/M de la empresa Digital, en los años 70, fue adaptado para el MS-DOS de Microsoft, cuya evolución final fue Windows.
  - Los diseñadores de Windows NT fueron los mismos que construyeron el sistema operativo VMS de los equipos VAX, también de Digital, y aportaron su experiencia. De hecho, muchas características de la gestión de procesos y de entrada/salida de ambos sistemas son idénticas.
- Otra importante línea genealógica es la que relaciona el antiguo Multics, por un lado, con **Unix** y con Linux; y más recientemente, con el sistema para plataformas móviles Android.
  - Unix fue el primer sistema operativo escrito casi totalmente en un lenguaje de alto nivel, el **C**, lo cual permitió portarlo a diferentes arquitecturas. Esto le dio un gran impulso y la comunidad científica lo adoptó como el modelo de referencia de los sistemas operativos de tiempo compartido.

En 1991 Linus Torvalds lanzó un proyecto de código abierto dedicado a la construcción de un sistema operativo compatible con Unix pero sin hacer uso de ningún código anteriormente escrito, lo que le permitió liberarlo bajo una licencia libre. La consecuencia es que Linux, su sistema operativo, rápidamente atrajo la atención de centenares de desarrolladores de todo el mundo, que sumaron sus esfuerzos para crear un sistema que fuera completo y disponible libremente.

Linux puede ser estudiado a fondo porque su código fuente no es secreto, como en el caso de los sistemas operativos propietarios. Esto lo hace ideal, entre otras cosas, para la enseñanza de las Ciencias de la Computación. Esta cualidad de sistema abierto permitió que otras compañías lo emplearan en muchos otros proyectos.

Otra empresa de productos de computación de notable trayectoria, Apple, produjo un sistema operativo para su línea de computadoras personales Macintosh. Su sistema MacOS estaba influenciado por desarrollos de interfaces de usuario gráficas realizadas por otra compañía, Xerox, y también derivó en la creación de un sistema operativo para dispositivos móviles.

Otros sistemas operativos han cumplido un ciclo con alguna clase de final, al no superar la etapa experimental, haberse transformado definitivamente en otros sistemas, desaparecer del mercado o quedar confinados a cierto nicho de aplicaciones. Algunos, por sus objetivos de diseño, son menos visibles, porque están destinados a un uso que no es masivo, como es el caso del sistema de tiempo real QNX.

### Servicios del SO

Después de conocer estas cuestiones generales sobre los sistemas operativos, veremos con un poco más de detalle los diferentes **servicios** provistos por los principales subsistemas de un SO:

- Ejecución de procesos
- Gestión de archivos
- Operaciones de Entrada/Salida
- Gestión de memoria
- Protección

Si bien la discusión que sigue es suficientemente general para comprender básicamente el funcionamiento de cualquier sistema operativo moderno, nos referiremos sobre todo a la manera como se implementan estos subsistemas y servicios en la familia de sistemas **Unix**, que, como hemos dicho, es el modelo de referencia académico para la mayoría de la investigación y desarrollo de sistemas operativos.

# Ejecución de procesos

## Creación de procesos

¿Cómo se inicia la ejecución de un proceso? Todo proceso es **hijo** de algún otro proceso que lo crea.

Inicialmente, el SO crea una cantidad de procesos de sistema. Uno de ellos es un **shell** o interfaz de usuario. Este proceso sirve para que el usuario pueda comunicarse con el SO y solicitarle la ejecución de otros procesos.

El *shell* puede ser **gráfico**, con una interfaz de ventanas; o **de texto**, con un **intérprete de comandos**. En cualquiera de los dos casos, de una forma u otra, usando el shell el usuario selecciona algún **programa**, que está residiendo en algún medio de almacenamiento como los discos, y pide al SO que lo ejecute.

En respuesta a la petición del usuario, el SO carga ese programa en memoria y pone a la CPU a **ejecutar el código** de ese programa.

Una vez que el programa está en ejecución, decimos que tenemos un nuevo **proceso** activo en el sistema. Este nuevo proceso es un **hijo** del shell, y a su vez puede crear nuevos procesos hijos si es necesario.

### Estados de los procesos

Durante su vida, el proceso atravesará diferentes **estados**. Un proceso puede no estar siempre en estado de ejecución (utilizando la CPU), sino que en un momento dado puede pasar a otro estado, quedando transitoriamente suspendido, para dejar que otro proceso utilice la CPU.

## Scheduler o planificador

El ciclo de cambios de estado de los procesos es administrado por un componente esencial del SO, el **scheduler** o **planificador**, que lleva el control de qué proceso debe ser el próximo en ejecutarse. El planificador seguirá una estrategia que permita obtener el máximo rendimiento posible de la CPU.

El scheduler o planificador mantiene una cola de procesos que están esperando por la CPU, y elige qué proceso pasar a estado de ejecutando. Al elegir un nuevo proceso para ejecutar, el que estaba ejecutándose cambia de estado hasta que vuelva a tocarle el uso de la CPU.

- Cuando en el sistema coexisten varios procesos activos durante un espacio de tiempo, decimos que esos procesos son concurrentes.
- Cuando, además, puede haber más de uno en ejecución en el mismo instante, decimos que son paralelos o que su ejecución es paralela.

# Ciclo de estados

### Ciclo de estados en un sistema multiprogramado

En un sistema **multiprogramado**, varios procesos pueden estar presentes en la memoria del sistema de cómputo. Durante su vida en el sistema, cada proceso atravesará un ciclo de estados.

- Cuando recién se crea un proceso, su estado es listo, porque está preparado para recibir la CPU cuando el planificador o scheduler lo disponga.
- En algún momento recibirá la CPU y pasará a estado **ejecutando**.
- En algún momento, el proceso ejecutará la última de sus instrucciones y finalizará. Es posible que su trabajo sea realmente muy breve y que finalice pronto.

- Sin embargo, es mucho más probable que, durante su vida, el proceso requiera servicios del SO (por ejemplo, para operaciones de entrada/salida, como recibir datos por el teclado o por la red, imprimir resultados, etc.).
- Durante estas operaciones de entrada/salida, el proceso no utilizará la CPU para realizar cómputos, sino que deberá esperar el final de este servicio del SO. Como la operación de entrada/salida potencialmente puede demorarse mucho, el sistema lo pone en estado de espera hasta que finalice la operación de entrada/salida.
- Mientras tanto, como la CPU ha quedado libre, el SO aprovecha la oportunidad de darle la CPU a algún otro proceso que esté en estado listo.
- Cuando finalice una operación de entrada/salida que ha sido requerida por un proceso, este proceso volverá al estado de listo y esperará que algún otro proceso libere la CPU para volver a ejecutando.
- Al volver desde el estado de listo al estado de ejecutando, el proceso retomará la ejecución desde la instrucción inmediatamente posterior a la que solicitó el servicio del SO.

### Ciclo de estados en un sistema de tiempo compartido

Los sistemas **de tiempo compartido** están diseñados para ser **interactivos**, y tienen la misión de hacer creer a cada usuario que el sistema de cómputo está dedicado exclusivamente a sus procesos. Sin embargo, normalmente existen muchísimos procesos activos simultáneamente en un SO de propósito general.

Para lograr esto el planificador de estos SO debe ser capaz de hacer los cambios de estado con mucha velocidad. El resultado es que los usuarios prácticamente no perciben estos cambios de estado.

En un sistema **de tiempo compartido**, el ciclo de estados de los procesos es similar al del sistema multiprogramado, pero con una importante diferencia.

- El sistema de tiempo compartido tiene la capacidad de desalojar a un proceso de la CPU, sin necesidad de esperar a que el proceso solicite un servicio del SO
- Para esto, el SO define un quantum o tiempo máximo de ejecución (típicamente de algunos milisegundos), al cabo del cual el proceso obligatoriamente deberá liberar la CPU.
- El SO, al entregar la CPU a un proceso que pasa de listo a ejecutando, pone en marcha un reloj para medir un quantum de tiempo que pasará ejecutando el proceso.
- Al agotarse el quantum, el SO interrumpirá al proceso y le impondrá el estado de listo. Al quedar libre la CPU, el siguiente proceso planificado entrará en estado de ejecución.

Sin embargo, si un proceso decide solicitar un servicio del SO antes de que se agote su quantum, el ciclo continuará de la misma manera que en el sistema multiprogramado, pasando a estado en espera hasta que finalice el servicio.

# Comparando multiprogramación y time sharing

Notemos que los diagramas de estados del **sistema multiprogramado** y del sistema **de tiempo compartido** se diferencian sólo en una transición: la que lleva del estado de **ejecutando** al de **listo** en este último sistema.

- En un sistema multiprogramado, un proceso sólo abandona la CPU cuando ejecuta una petición de servicio al SO.
- En un sistema de tiempo compartido, un proceso abandona la CPU cuando ejecuta una petición de servicio al SO o bien cuando se agota su quantum.

## **Preguntas**

- ¿Por qué un proceso que ejecuta una solicitud de entrada/salida no pasa directamente al estado de **listo**?
- ¿En qué radica la diferencia entre el scheduling de un sistema multiprogramado y el de un sistema de tiempo compartido?
- Si en un sistema multiprogramado se ejecuta un programa escrito de forma que nunca ejecuta una operación de entrada/salida, ¿liberará alguna vez la CPU durante su vida?
- ¿Y en un sistema de tiempo compartido?

#### Concurrencia y paralelismo

Si el sistema de tiempo compartido dispone de una sola unidad de ejecución o CPU, habrá solamente un proceso ejecutándose en cada momento dado, pero muchos procesos podrán desarrollar su vida al mismo tiempo, alternándose en el uso de esa CPU.

- Cuando los procesos coexisten en el sistema simultáneamente pero se alternan en el uso de una única CPU decimos que esos procesos son concurrentes. Todos están activos en el sistema durante un período de tiempo dado; sin embargo, no hay dos procesos en estado de ejecución en el mismo momento, por lo cual no podemos decir que se ejecutan "simultáneamente".
- Cuando el sistema de cómputo tiene más de una CPU, entonces podemos tener dos o más procesos en estado de ejecución simultáneamente, y entonces decimos que esos procesos son paralelos. Para tener paralelismo, además de concurrencia debemos tener redundancia de hardware (es decir, más de una CPU).

## Monitorización de procesos

Los sistemas operativos suelen ofrecer herramientas para monitorizar o controlar los procesos del sistema.

#### Comando top

En Linux, el comando **top** ofrece una vista de los procesos, información acerca de los recursos que están ocupando, y algunas estadísticas globales del sistema.

Es conveniente consultar el manual del comando (man top) para investigar a fondo los significados de cada uno de los datos presentados en pantalla.

# Estadísticas globales

En el cuadro superior, top muestra:

- El tiempo de funcionamiento desde el inicio del sistema
- La cantidad de usuarios activos
- La carga promedio (longitud de la cola de procesos listos) medida en tres intervalos de tiempo diferentes
- La cantidad de procesos o tareas en actividad y en diferentes estados
- Las estadísticas de uso de la CPU, contabilizando los tiempos:
- De usuario
- De sistema
- **De nice** o "de cortesía"
- Ocioso
- De espera
- Tiempos imputables a interrupciones
- Estadísticas de memoria RAM total, usada y libre, y ocupada por buffers de entrada/salida
- Estadísticas de espacio de intercambio o swap total, usado y libre.

### Estadísticas de procesos

Para cada proceso, el programa top muestra:

- El PID o identificación de proceso
- El usuario dueño del proceso
- La prioridad a la cual está ejecutando y el valor de nice o de cortesía
- El tamaño del espacio virtual del proceso y los tamaños del conjunto residente y regiones compartidas
- El porcentaje de CPU recibido durante el ciclo de top
- El porcentaje de memoria del sistema ocupada
- El tiempo de ejecución que lleva el proceso desde su inicio

■ El comando u orden con la que fue creado el proceso.

El comando top tiene muchas opciones y comandos interactivos. Uno de ellos muestra los datos de sistema desglosados por CPU o unidad de ejecución.

# Comandos de procesos

En los sistemas operativos de la familia de Unix encontramos un rico conjunto de comandos de usuario destinados al control de procesos. Algunos interesantes son:

- ps y pstree listan los procesos activos en el sistema
- nice cambia la prioridad de un proceso
- kill envía una señal a un proceso

#### Interesante

Administración de procesos

Prioridades de ejecución de procesos

# Gestión de archivos

#### **Archivos**

La información que se guarda en medios de almacenamiento permanente, como los discos, se organiza en archivos, que son secuencias de bytes. Estos bytes pueden estar codificando cualquier clase de información: texto, código fuente de programas, código ejecutable, multimedia, etc.

Cualquier pieza de información que sea tratable mediante las computadoras puede ser almacenada y comunicada en forma de archivos.

# Sistema de archivos

El componente del SO responsable de los servicios relacionados con archivos es el llamado **sistema de archivos** o **filesystem**.

En general, el filesystem no se ocupa de cuál es el contenido de los archivos, o de qué sentido tienen los datos que contienen. Son las aplicaciones quienes tienen conocimiento de cómo interpretar y procesar los datos contenidos en los archivos.

En cambio, el filesystem mantiene información **acerca** de los archivos: en qué bloques del disco están almacenados, qué tamaño tienen, cuándo fueron creados, modificados o accedidos por última vez, qué usuarios tienen permisos para ejecutar qué acciones con cada uno de ellos, etc.

#### Metadatos

Como todos estos datos son acerca de los archivos, y no tienen nada que ver con los datos contenidos en los archivos, son llamados metadatos. El sistema de archivos o filesystem mantiene tablas y listas de metadatos que describen los archivos contenidos en un medio de almacenamiento.

#### **Directorios**

Una característica compartida por la mayoría de los sistemas de archivos es la organización jerárquica de los archivos en estructura de **directorios**. Los directorios son contenedores de archivos (y de otros directorios).

Los directorios han sido llamados, en la metáfora de las interfaces visuales de usuario, carpetas.

## Varios significados

En rigor de verdad, el nombre de sistema de archivos o filesystem designa varias cosas, relacionadas pero diferentes:

### Una pieza de software

El filesystem es el subsistema o conjunto de rutinas del kernel responsable de la organización de los archivos del sistema. Es un componente de software o módulo del kernel, y como tal, es **código** ejecutable.

#### Un conjunto de metadatos

Pero, por otro lado, también hablamos del filesystem como el conjunto de metadatos acerca de los archivos grabados en un medio de almacenamiento. El filesystem en este sentido, es la **información** que describe unos archivos y reside en el mismo medio de almacenamiento que ellos.

# Un conjunto de características

Además, cuando se diseña un sistema de archivos, se lo dota de ciertas capacidades distintivas. Al referirnos al filesystem, podemos estar hablando del **conjunto de características ofrecidas** por alguna implementación en particular de un sistema de archivos.

- Algunos sistemas de archivos específicos tienen ciertas restricciones en la forma de los nombres de los archivos, y otros no.
- Algunos permiten la atribución de permisos o identidades de usuario a los archivos, y otros no.
- Algunos ofrecen servicios como encriptación, compresión, o versionado de archivos.

# Árbol de directorios

En los filesystems de tipo Unix, la organización de los directorios es jerárquica y recuerda a un árbol con **raíz** y ramas. Algunos directorios cumplen una función especial en el sistema porque contienen archivos especiales, y por eso tienen nombres establecidos.

- Por ejemplo, el directorio raíz, donde se origina toda la jerarquía de directorios, tiene el nombre especial "/".
- El directorio lib (abreviatura de library o biblioteca) contiene bibliotecas de software
- Los directorios bin, sbin. /usr/bin, etc., contienen archivos ejecutables (a veces llamados binarios).

### Nombres de archivo y referencias

Los nombres completos, o **referencias absolutas**, de los archivos y directorios se dan indicando cuál es el camino que hay que recorrer, para encontrarlos, **desde la raíz** del sistema de archivos.

#### **Ejemplo**

La referencia absoluta para el archivo texto.txt ubicado en el directorio juan, que está dentro del directorio home, que está dentro del directorio raíz, es /home/juan/texto.txt.

Una **referencia relativa**, por otro lado, es una forma de mencionar a un archivo que depende de dónde está situado el proceso o usuario que quiere utilizarlo. Todo proceso, al ejecutarse, tiene una noción de lugar del filesystem donde se encuentra.

- Por ejemplo, el shell de cada usuario funciona dentro del directorio home o espacio privado del usuario.
- Éste es el directorio actual del proceso shell.
- Puede ser cambiado utilizando el comando cd.
- El comando pwd dice cuál es el directorio actual de un shell.

La referencia relativa de un archivo indica cuál es el camino que hay que recorrer para encontrarlo **desde el directorio actual** del proceso.

#### **Eiemplo**

Para el mismo archivo del ejemplo anterior, si el directorio activo del shell es /home/juan, la referencia relativa será simplemente texto.txt.

La referencia es relativa porque, si el proceso cambia de directorio activo, ya no servirá como referencia para ese mismo archivo.

# Elementos del sistema de archivos

#### **Particiones**

Los medios de almacenamiento se dividen en **particiones** o zonas de almacenamiento. Cada partición puede contener un sistema de archivos, con sus archivos y metadatos.

### **Bloques**

Los **bloques** son las unidades mínimas de almacenamiento que ofrecen los diferentes dispositivos, como los discos. Un **bloque** es como un contenedor de datos que se asigna a un archivo.

Los archivos quedan almacenados, en los discos y en otros medios, como una sucesión de bloques de datos. El filesystem tiene la responsabilidad de mantener la lista de referencias a esos bloques, para poder manipular los archivos como un todo.

### Inodos

Los **nodos indice** o **inodos** son estructuras de datos que describen, cada una, un archivo. Los inodos contienen los principales metadatos de cada archivo, excepto el nombre.

En los sistemas de archivos del tipo de Unix, los nombres y los inodos de los archivos están separados. Como consecuencia, un archivo puede tener más de un nombre.

#### Superblock

El **superblock** grabado en una partición es una estructura de datos compleja donde se mantienen los datos del sistema de archivos. El superblock contiene una lista de bloques libres y una lista de inodos.

# Inodos

Cada **inodo** describe a un archivo de datos en un filesystem. El inodo contiene metadatos como:

- El tamaño en bytes del archivo
- La identidad del usuario dueño del archivo y del grupo al cual pertenece el archivo
- El tipo de archivo
- Puede tratarse de un archivo regular (de datos) o de un directorio
- Puede ser un pseudoarchivo, o dispositivo de caracteres o de bloques

- Puede ser un dispositivo de comunicaciones entre procesos, como un socket, un pipe o tubería, u otros
- Los permisos o modo de acceso
- Los archivos en Unix pueden tener permisos de lectura, de escritura/modificación, o de ejecución
- Esos permisos se especifican en relación al dueño del archivo, al grupo del archivo, o al resto de los usuarios
- La fecha y hora de creación, de última modificación y de último acceso
- La cuenta de *links*, o cantidad de nombres que tiene el archivo
- Los números de bloque que almacenan los datos, o **punteros** a bloques

#### Metadatos

Los metadatos de cada archivo, contenidos en su inodo, pueden ser consultados y modificados con comandos de usuario.

## **Ejemplo**

El comando ls -l muestra los nombres de los archivos contenidos en un directorio. Para cada archivo, consulta el inodo correspondiente, extrae de él los metadatos del archivo, y los presenta en un listado.

El listado se compone de varios elementos por cada fila, separados por espacios.

```
$ 1s -1 util
total 60
-rwxr-xr-x 1 oso oso 40 Apr 18 16:54 github
-rw-r--r-- 1 oso oso 1337 May 4 12:11 howto.txt
-rwxrwxr-x 1 oso oso 458 Feb 9 16:28 macro
drwxr-xr-x 2 oso oso 4096 May 26 18:14 prueba
-rwxr-xr-x 1 oso oso 30 Feb 9 16:28 server
```

## Tipo de archivo

El primer elemento de cada fila contiene un carácter que indica el tipo del archivo, y los siguientes caracteres indican los permisos asignados al archivo. El tipo indicado por el **guión** es **archivo regular**, y el indicado por la letra **d** es **directorio**. En el ejemplo, todos los archivos son regulares salvo **prueba**, que es un directorio. Otros tipos de archivo tienen otros caracteres indicadores.

#### **Permisos**

Los permisos de cada archivo están indicados por los nueve caracteres siguientes hasta el espacio. Para interpretarlos, se separan en tres grupos de tres caracteres. Los primeros tres caracteres indican los permisos que tiene el usuario **dueño** del archivo; los siguientes tres, los permisos para el **grupo** al cual pertenece el archivo; y los últimos tres, los permisos que tienen **otros usuarios**.

Cada grupo de permisos indica si se permite la **lectura**, **escritura**, o **ejecución** del archivo. Una letra **r** en el primer lugar del grupo indica que el archivo puede ser escrito. Una **w** en el segundo lugar, que puede ser escrito o modificado. Una **x** en el tercer lugar, que puede ser ejecutado. Cuando no existen estos permisos, aparece un carácter **guión**.

- Así, el archivo github del ejemplo tiene permisos rwxr-xr-x, que se separan en permisos rwx para el dueño (el dueño puede leerlo, escribirlo o modificarlo, y ejecutarlo), r-x para el grupo (cualquier usuario del grupo puede leerlo y ejecutarlo), y lo mismo para el resto de los usuarios.
- Por el contrario, el archivo howto.txt tiene permisos rw-r-r-, que se separan en permisos rw- para el dueño (el dueño puede leerlo, escribirlo o modificarlo, pero no ejecutarlo), r- para el grupo (cualquier usuario del grupo puede leerlo, pero no modificarlo ni ejecutarlo), y lo mismo para el resto de los usuarios.

#### Cuenta de links

La cuenta de links es la cantidad de **nombres** que tiene un archivo.

### Dueño y grupo

Las columnas tercera y cuarta indican el usuario y grupo de usuarios al cual pertenece el archivo.

#### Tamaño

Aparece el tamaño en bytes de los archivos regulares.

### Fecha y hora

Aparecen la fecha y hora de última modificación de cada archivo.

## Nombre

El último dato de cada línea es el nombre del archivo.

# Bloques de disco

El SO ve los discos como un vector de bloques o espacios de tamaño fijo. Cada bloque se identifica por su número de posición en el vector, o **dirección de bloque**. Esta dirección es utilizada para todas las operaciones de lectura o escritura en el disco.

- Cuando el SO necesita acceder a un bloque para escribir o leer sus contenidos, envía un mensaje al controlador del disco especificando su dirección.
- Si la operación es de lectura, además indica una dirección de memoria donde desea recibir los datos que el controlador del disco leerá.
- Si la operación es de escritura, indica una dirección de memoria donde están los datos que desea escribir.

Cada vez que un proceso solicita la grabación de datos nuevos en un archivo, el filesystem selecciona un bloque de su lista de bloques libres. Para agregar los datos al archivo, el filesystem quita la dirección del bloque de la lista de libres, la añade al conjunto de bloques ocupados del archivo, y finalmente escribe en ese bloque los contenidos entregados por el proceso.

Recorrer un archivo (para leerlo o para hacer cualquier clase de procesamiento de sus contenidos) implica acceder a todos sus bloques de disco, en el orden en que han sido almacenados esos contenidos. La información para saber qué bloques componen un archivo, y en qué orden, está en el **inodo** del archivo.

El inodo contiene entre sus metadatos una lista de las direcciones de todos los bloques que contienen la información del archivo. Cada una de estas direcciones de bloques se llama un apuntador o **puntero** a bloque.

Como el inodo es una estructura de datos de tamaño fijo, esta lista de punteros tendrá un tamaño máximo. Como, además, los archivos tienen tamaños muy diferentes, se impone un diseño cuidadoso de esta lista de bloques.

- Si se define en el inodo un espacio demasiado pequeño para guardar la lista de punteros a bloques, cada inodo representará archivos con pocos bloques, y así el filesystem no podrá contener archivos grandes.
- Si, al contrario, el espacio en el inodo reservado para guardar la lista es grande, se podrán almacenar archivos de muchos bloques; pero si la mayoría de los archivos del sistema fueran pequeños, se estaría desperdiciando espacio en el superblock.

Para administrar mejor el espacio en el superblock, y para mantener el inodo de un tamaño razonable, esos punteros a bloques se dividen en tres clases: punteros directos, indirectos y doble-indirectos.

## **Punteros directos**

Los punteros **directos** son simplemente direcciones de bloques de datos. El filesystem clásico de Unix tiene una cantidad fija de diez punteros directos en el inodo. Si un archivo tiene una cantidad de bytes igual o menor a diez bloques de disco, los punteros directos permiten recorrer el archivo completo.

## **Punteros indirectos**

Si el archivo es más grande, y los diez punteros directos no alcanzan para enumerar los bloques que lo componen, se utilizan **punteros indirectos**. Un puntero indirecto contiene la dirección de un bloque **que a su vez contiene punteros directos**. Hay dos punteros indirectos en el inodo del filesystem Unix clásico.

#### Punteros doble-indirectos

Si tampoco son suficientes los punteros directos y los indirectos, el inodo del filesystem clásico de Unix contiene un puntero **doble-indirecto**. Es un puntero a un bloque **que a su vez contiene punteros indirectos**.

Esta estrategia de las tres clases de punteros permite que los inodos sean de tamaño reducido pero tengan la capacidad de direccionar una gran cantidad de bloques. Así, el filesystem puede contener archivos de tamaño considerablemente grande y al mismo tiempo conservar el espacio en el superblock.

#### **Preguntas**

Supongamos que un disco ha sido formateado de modo de contener 1 TiB de espacio de almacenamiento, y que el tamaño de un bloque de disco sea de 4 KiB. Propongamos las fórmulas necesarias para responder las siguientes preguntas.

- 1. ¿Qué cantidad cB de bloques habrá en el disco?
- 2. ¿Con cuántos bits **cb** representaremos cada dirección de bloque? Dicho de otra manera, ¿qué cantidad de bits serán necesarios para un puntero a bloque?
- 3. ¿Qué tamaño máximo de archivo se puede representar con tres punteros directos a bloque?
- 4. ¿Cuántos punteros a bloque cp caben en un bloque indirecto?
- 5. ¿Y en un doble-indirecto (cd)?
- 6. ¿Qué tamaño máximo de archivo se puede representar con tres punteros directos a bloque y uno indirecto?
- 7. Si el inodo tiene 10 punteros directos, 2 indirectos y uno doble-indirecto, ¿cuánto espacio (**tp**) ocupa la tabla de punteros dentro del inodo?
- 8. ¿Cuál es el tamaño máximo tm de un archivo según esta configuración del inodo?
- 9. Si sabemos que el tamaño promedio de un archivo de datos será de 512 MiB, ¿cuántos archivos (ca) podrá haber en el disco?
- 10. ¿Cuántos inodos (ci) deberá haber en el superblock entonces?
- 11. ¿Cuánto espacio ocupará la lista de inodos (ti) en el superblock?
- 12. ¿Cuánto espacio ocupará la lista de bloques libres (tl) en el superblock?
- 13. ¿Cuánto espacio ocupará el superblock (ts) en el disco?

## **Directorios**

Notemos que en ningún momento hemos mencionado el **nombre** de los archivos entre los metadatos. En el filesystem de Unix, los nombres de archivo no se encuentran en el superblock, sino en los directorios. Otros sistemas de archivos adoptan otras estrategias.

En Unix, un directorio es simplemente un conjunto de bloques de datos, como los archivos regulares, pero juega un papel especial en el funcionamiento del sistema de archivos, y sus contenidos tienen un formato especial. Los archivos especiales de tipo directorio son archivos de datos que podemos pensar organizados como una tabla de dos columnas. Contienen una lista de entradas con **nombres de archivo** (o **links**) y números de **inodos** que los representan.

#### Links o nombres de archivo

Al separar el archivo (representado por el inodo), de su nombre **o link** (contenido en el directorio), el filesystem permite que un archivo pueda tener **más de un nombre**.

- En un mismo directorio puede haber dos entradas con nombres diferentes, que apunten al mismo inodo.
- En dos directorios pueden existir sendas entradas con el mismo o diferente nombre, que apunten al mismo inodo.

En estos casos, el archivo podrá ser accedido por cualquiera de esos nombres. Ninguno de ellos es privilegiado o especial.

Si un proceso intenta borrar un archivo, en realidad estará borrando **uno de sus nombres**. La cuenta de links en el inodo se decrementará en 1. Sólo cuando la cuenta de links, o nombres, llegue a cero, se liberarán los bloques de datos del archivo y se devolverán a la lista de bloques libres en el superblock.

#### Búsqueda de un archivo en el filesystem

Supongamos que un proceso necesita leer los bloques de datos del archivo /etc/group. Deberá entregarle al filesystem el nombre de este archivo para que pueda localizarlo y devolverle esos datos.

Supongamos además que especifica el nombre mediante una referencia absoluta. El filesystem analizará la referencia absoluta que le ha entregado el proceso, descomponiéndola en sus partes componentes y usándola como mapa para llegar al archivo, desde el directorio raíz.

- Para encontrar el archivo, el filesystem lee el inodo 0, que corresponde al directorio raíz, y recoge de allí los bloques de datos del directorio raíz.
- Esos bloques de datos contienen nombres de otros archivos y directorios, junto al número del inodo que los representa. De aquí puede extraer el filesystem el número de inodo que representa al directorio /etc. Leerá este inodo de la tabla de inodos, en el superblock, y recuperará del disco los bloques que contienen a ese directorio. Los números de estos bloques están en la tabla de punteros a bloques del inodo.
- Como /etc es un directorio, contendrá una tabla de nombres de archivo y números de inodos. Aquí podrá encontrarse el número de inodo que corresponde a /etc/group.
- Finalmente, leyendo este inodo, el filesystem recorrerá los punteros a bloques devolviendo el contenido del archivo /etc/group.

#### Gestión de memoria

En un sistema multiprogramado, la memoria debe ser dividida de alguna forma entre los procesos que existen simultáneamente en el sistema. La tarea de controlar qué proceso recibe qué región de memoria, o **gestión de memoria**, es un problema con varias soluciones.

## Mapa de memoria

Un programa se compone, como mínimo, de:

- Las instrucciones para el procesador (código o texto del programa).
- Los datos con los que operarán esas instrucciones.

Para que este programa pueda convertirse en un proceso, tanto instrucciones como datos deben estar almacenados en posiciones de **memoria principal**. Solamente de allí pueden ser leídos por el procesador.

Además, los procesos requieren otros espacios de memoria para varios otros usos.

- Por ejemplo, al llamar a una función o rutina, es necesario guardar temporariamente la dirección de retorno, que es la dirección de la instrucción a la cual se debe volver una vez terminada la rutina. Estas direcciones se guardan en una zona denominada la pila o stack del proceso.
- El proceso puede necesitar crear dinámicamente estructuras de datos que no existían al momento de carga del programa en memoria. Estos componentes también necesitan ser almacenados en memoria, típicamente en una zona denominada el heap.

Todos estos componentes forman lo que a veces se llama **mapa de memoria** de cada proceso, y requieren memoria física.

## Espacios de direcciones

## Espacio de direcciones físicas

La memoria física del sistema se ve como un arreglo, vector o secuencia ordenada de celdas o posiciones de almacenamiento. Cada posición tiene una **dirección** que es el número con el que se la puede acceder para leer o escribir su contenido. En un sistema de cómputo, el conjunto de direcciones de la memoria física es un **espacio de direcciones físicas**.

## Espacio de direcciones lógicas

Al ejecutarse un proceso, las instrucciones que va ejecutando la CPU **referenciarán** a los objetos del mapa de memoria mediante su dirección. Cada vez que la CPU necesite cargar una instrucción para decodificarla, hará una referencia a la dirección donde reside esa instrucción. Cada vez que una instrucción necesite acceder a un dato en memoria, la CPU hará una referencia a su dirección. El conjunto de todas las direcciones de estos objetos forma el **espacio de direcciones lógicas** del proceso.

#### **Ejemplo**

En nuestro modelo MCBE, los espacios físico y lógico coinciden. Como sabemos, una instrucción como **01000111** indica que se debe cargar en el acumulador el contenido de la dirección 7.

- Al ejecutarse esta instrucción, el procesador envía el número 7 al sistema de memoria para que éste le entregue el contenido de esa posición. El procesador hace una referencia a la dirección 7. Por lo tanto, la dirección 7 pertenece al espacio lógico del programa.
- Además, el sistema de memoria utiliza directamente el número 7 recibido de la CPU como la dirección de memoria que debe devolver. La posición física consultada por el sistema de memoria es exactamente la número 7.

## Traducción de direcciones

En un sistema multiprogramado, los programas son cargados en diferentes posiciones del espacio de memoria física. Esto hace que los espacios **lógico y físico** de direcciones de un proceso, en general, no coincidan.

Para que las referencias a direcciones **lógicas** conserven el sentido deseado por el programador, el sistema utiliza alguna forma de **traducción de direcciones**. Las referencias a direcciones generadas por el procesador pertenecerán al espacio lógico del proceso; pero el mecanismo de traducción de direcciones **mapeará** esas direcciones lógicas a las direcciones físicas asignadas.

#### Unidad de gestión de memoria o MMU

Esta traducción tiene lugar, automáticamente, en el momento en que el procesador emite una dirección hacia el sistema de memoria, y está a cargo de un componente especial del hardware. Este componente se llama la unidad de gestión de memoria (MMU, Memory Management Unit).

 El sistema de memoria recibe únicamente las direcciones físicas, traducidas, y "no sabe" que el procesador ha solicitado acceder a una dirección lógica diferente.  Por su parte, el procesador "no sabe" que la dirección física accedida es diferente de la dirección lógica cuyo acceso ha solicitado.

Si el sistema no ofreciera un mecanismo automático de traducción de direcciones, el programador necesitaría saber de antemano en qué dirección va a ser cargado su programa, y debería preparar las referencias a las direcciones de modo de que ambos espacios coincidieran.

### **Ejemplo**

El siguiente programa sencillo en lenguaje ensamblador de MCBE hace referencias a algunas direcciones.

00000		LD	DATO
00001		ADD	CANT
00010		ST	SUMA
00011		HLT	
00100	DATO:	10	
00101	CANT:	1	
00110	SUMA:	0	

En este ejemplo, DATO, CANT y SUMA son las posiciones de memoria 4, 5 y 6. Si este programa se carga en la posición **cero** de la memoria física, los espacios físico y lógico coincidirán. Sin embargo, en un sistema multiprogramado, es posible que el proceso reciba otras posiciones de memoria física.

Por ejemplo, el programa podría haber sido cargado a partir de la dirección 20 de la memoria. Entonces, la posición de memoria física donde residirá el valor SUMA no es la posición 6, sino la 26.

El mecanismo de traducción de direcciones del sistema **deberá sumar el valor base de la memoria** (en este caso, 20) **a todas las referencias a memoria generadas por el procesador** para mantener el funcionamiento deseado. **Sin** traducción de direcciones, la instrucción ST SUMA almacenará el resultado en la posición cuya dirección física es 6... ¡que pertenece a otro proceso!

## Asignación de memoria contigua

Uno de los esquemas de asignación de memoria más simples consiste en asignar una región de memoria **contigua** (un conjunto de posiciones de memoria sin interrupciones) a cada proceso.

Si un SO utiliza este esquema de asignación de memoria, establece **particiones** de la memoria, de un tamaño adecuado a los requerimientos de cada proceso. Cuando un proceso termina, su región de memoria se libera y puede ser asignada a un nuevo proceso.

## Fragmentación externa

El problema de este esquema es que, a medida que el sistema opere, las regiones que queden libres pueden ser tan pequeñas que un proceso nuevo no pueda obtener una región de tamaño suficiente, a pesar de que exista memoria libre en cantidad suficiente en el sistema. Este fenómeno se llama fragmentación externa.

Un remedio para la fragmentación externa es la **compactación** de la memoria, es decir, reubicar los procesos que estén ocupando memoria, de manera de que sus regiones sean contiguas entre sí. De esta forma los "huecos" en la memoria se unen y se crean regiones libres contiguas grandes.

El problema con esta solución es que la reubicación de los procesos es muy costosa en tiempo. Mientras el sistema esté compactando la memoria, los procesos que estén siendo reubicados no podrán realizar otra tarea, y el sistema perderá productividad.

Esta clase de cargas extra en tareas administrativas, que quitan capacidad al sistema para atender el trabajo genuino, se llama **sobrecarga** u **overhead**.

## Segmentación

Un esquema de asignación que reduce la fragmentación externa es el de **segmentación**. Con este esquema, el mapa de memoria del proceso se divide en trozos de diferentes tamaños, llamados **segmentos**, conteniendo cada uno un conjunto de instrucciones o de datos.

Durante la compilación de un programa fuente, el compilador distribuye los trozos de código y las estructuras de datos en distintos segmentos. Cada segmento tiene un tamaño o **límite**, calculado y especificado por el compilador, y grabado en la cabecera del archivo ejecutable resultante de la compilación.

Al cargar un programa en memoria, el SO destina cada segmento a una determinada dirección base física. La dirección base de cada segmento es utilizada por el mecanismo de traducción de direcciones. El dato de tamaño o límite de cada segmento es utilizado para la **protección**, asegurando que las referencias a memoria generadas por la CPU no rebasen los límites de cada segmento. De esta forma, un proceso no puede corromper el espacio de otros.

Este esquema de asignación de memoria reduce, aunque no elimina, la fragmentación externa, ya que los segmentos son más pequeños y reubicables dinámicamente.

## Paginación

El esquema de asignación de memoria conocido como **paginación** considera la memoria dividida en regiones del mismo tamaño (**marcos** de memoria), y el espacio lógico de los procesos dividido en regiones (**páginas**) de igual tamaño que los marcos.

Las páginas de los procesos se asignan individualmente a los marcos, una página por vez

Al contrario que en un sistema de particiones, en un sistema con paginación de memoria los procesos reciben más de una región de memoria o marco. Los marcos asignados a un proceso pueden no ser contiguos.

### Fragmentación interna

Bajo este esquema no hay fragmentación externa, porque, si existe espacio libre, siempre será suficiente para alojar al menos una página. Sin embargo, en general, el tamaño del espacio lógico del proceso no es exactamente divisible por el tamaño de la página; por lo tanto, puede haber algún espacio desaprovechado en las páginas asignadas. Esta condición se llama **fragmentación interna**.

#### Tabla de páginas

Para poder mantener la correspondencia entre marcos de memoria y páginas de los procesos, el SO mantiene una **tabla de páginas** por cada proceso.

- La tabla de páginas de cada proceso dice, para cada página del proceso, qué marco le ha sido asignado, además de otra información de control.
- La tabla de páginas puede contener referencias a marcos compartidos con otros procesos. Esto hace posible la creación de regiones de memoria compartida entre procesos.
- En particular, los marcos de memoria ocupados permanentemente por el kernel pueden aparecer en el mapa de memoria de todos los procesos.

#### Paginación por demanda

Debido a que los programas no utilizan sino una pequeña parte de su espacio lógico en cada momento (fenómeno llamado **localidad de referencias**), la asignación por paginación tiene una propiedad muy interesante: no es necesario que todas las páginas de un proceso estén en memoria física para que pueda ser ejecutado.

Esto permite la creación de sistemas con **paginación por demanda**, donde las páginas se cargan en memoria a medida que se necesitan. Un proceso puede empezar a ejecutarse apenas esté cargada la primera de sus páginas en memoria, sin necesidad de esperar a que todo su espacio lógico tenga memoria física asignada.

Cada proceso **demanda** al SO la carga de una página de su espacio lógico al espacio físico en el momento en que referencia algún objeto perteneciente a esa página. De esta manera la actividad de entrada/salida desde el disco a la memoria se reduce al mínimo necesario.

Utilizando 1) paginación por demanda, 2) agregando algunas características al mecanismo de **traducción de direcciones**, y 3) contando con un espacio de almacenamiento extra en disco para **intercambio de páginas** o **swapping**, se puede implementar un sistema de **memoria virtual**. La mayoría de los SO multipropósito para hardware con MMU utiliza esta técnica.

## Memoria virtual

Con memoria virtual, el espacio de direcciones lógicas y el espacio físico se independizan completamente. El espacio lógico puede tener un tamaño completamente diferente del espacio físico. La cantidad de páginas de un proceso ya no se ve limitada por la cantidad de marcos de la memoria física.

- Podemos ejecutar más procesos de los que cabrían en memoria física si debiéramos asignar todo el espacio lógico de una vez.
- Los procesos pueden tener un tamaño de espacio lógico más grande de lo que permite el tamaño de la memoria física.

En un sistema de memoria virtual, la tabla de páginas mantiene, además de los números de página y de marco asociados, datos de estado sobre la condición de cada página.

## ■ Bit de validez

Indica si la página del proceso tiene memoria física asignada.

#### Bit de modificación

Indica si la página ha sido modificada desde que se le asignó memoria física.

El bit de validez de cada página indica si la página tiene o no asignado un marco, y es crucial para el funcionamiento del sistema de memoria virtual. Cuando la CPU genera una referencia a una página no válida, la condición que se produce se llama un fallo de página (page fault) y se resuelve asignando un marco, luego de lo cual el proceso puede continuar.

Además de estos bits de validez y modificación, la tabla de páginas contiene datos sobre los permisos asociados con cada página.

El mecanismo de memoria virtual funciona de la siguiente manera:

- Cada dirección virtual tiene un cierto conjunto de bits que determinan el número de página. Los bits restantes determinan el desplazamiento dentro de la página.
- Cuando un proceso emite una referencia a una dirección virtual, la MMU extrae el número de página de la dirección y consulta la entrada correspondiente en la tabla de páginas.

- Si la información de control de la tabla de páginas dice que este acceso no es permitido, la MMU provoca una condición de error que interrumpe el proceso.
- Si el acceso es permitido, la MMU computa la dirección física reemplazando los bits de página por los bits de marco.
- Si el bit de validez está activo, la página ya está en memoria física.
- Si el bit de validez no está activo, ocurre un fallo de página, y se debe asignar un marco. Se elige un marco de una lista de marcos libres, se lo marca como utilizado y se completa la entrada en la tabla de páginas. Los contenidos de la página se traerán del disco.
- La MMU entrega la dirección física requerida al sistema de memoria.
- Si la operación era de escritura, se marca la página como modificada.

## Reemplazo de páginas

Cuando no existan más marcos libres en memoria para asignar, el SO elegirá una página **víctima** del mismo u otro proceso y la desalojará de la memoria. Aquí es donde se utiliza el bit de **modificación** de la tabla de páginas.

- Si la página víctima no está modificada, simplemente se marca como no válida y se reutiliza el marco que ocupaba.
- Si la página víctima está modificada, además de marcarla como no válida, sus contenidos deben guardarse en el espacio de intercambio o swap.

Posteriormente, en algún otro momento, el proceso dueño de esta página querrá accederla. La MMU verificará que la página no es válida y disparará una condición de **fallo de página**. La página será traída del espacio de intercambio, en el estado en que se encontraba al ser desalojada, y el proceso podrá proseguir su ejecución.

### **Ejemplo**

Supongamos un sistema donde existen dos procesos activos, con algunas páginas en memoria principal, y una zona de intercambio en disco.

- El proceso P1 tiene asignadas cuatro páginas (de las cuales sólo la página 2 está presente en memoria principal), y P2, dos páginas (ambas presentes).
   Hay tres marcos libres (M4, M6 y M7) y la zona de intercambio está vacía.
- P1 recibe la CPU y en algún momento ejecuta una instrucción que hace una referencia a una posición dentro de su página 3 (que no está en memoria).
- Ocurre un fallo de página que trae del almacenamiento la página 3 de P1 a un marco libre. La página 3 se marca como válida en la tabla de páginas de P1.
- Enseguida ingresa P3 al sistema y comienza haciendo una referencia a su página 2.

- Como antes, ocurre un fallo de página, se trae la página 2 de P3 del disco, y se copia en un marco libre. Se marca la página 2 como válida y P3 continúa su ejecución haciendo una referencia a una dirección que queda dentro de su página 3.
- Se resuelve como siempre el fallo de página para la página 3 y P3 hace una nueva referencia a memoria, ahora a la página 4.
- Pero ahora la memoria principal ya no tiene marcos libres. Es el momento de elegir una página víctima para desalojarla de la memoria. Si la página menos recientemente usada es la página 2 de P1, es una buena candidata. En caso de que se encuentre modificada desde que fue cargada en memoria, se la copia en la zona de intercambio para no perder esas modificaciones, y se declara libre el marco M2 que ocupaba.
- Se marca como no válida la página que acaba de salir de la memoria principal.
   La próxima referencia a esta página que haga P1 provocará un nuevo fallo de página.
- Se copia la página que solicitó P3 en el nuevo marco libre, se la marca como válida en la tabla de páginas de P3, y el sistema continúa su operación normalmente.

Notemos que en este ejemplo existen tres procesos cuyos tamaños de espacio lógico miden **4, 5 y 6 páginas**, dando un total de **15 páginas**. Sin embargo, el sistema de cómputo sólo tiene **ocho marcos**.

Sin paginación por demanda y memoria virtual, solamente podría entrar en el sistema uno de los tres procesos. Durante las operaciones de entrada/salida de ese proceso, la CPU quedaría desaprovechada. Además, si alguno de los procesos tuviera un espacio lógico de más de ocho páginas, no podría ser ejecutado.

Con la técnica de memoria virtual, los tres procesos pueden estar activos simultáneamente en el sistema, aumentando la utilización de CPU. Y, si alguno de esos procesos tuviera un espacio lógico de **más de 8 páginas**, el sistema seguiría funcionando del mismo modo.

## **Preguntas**

- 1. La cantidad de bits de página y la cantidad de bits de marco, ¿deben ser iguales? ¿Qué posibilidades hay, y qué consecuencias tiene cada una?
- 2. ¿Cuántos marcos tiene el espacio físico de un sistema de cómputo que utiliza memoria virtual, cuyas direcciones físicas codifican el número de marco en cuatro bits?
- 3. ¿Cuántas páginas tiene el espacio de direcciones lógicas de un proceso si las direcciones codifican el número de página en tres bits?
- 4. ¿Cuántos procesos como el anterior pueden estar activos en un sistema de cómputo como el anterior?

# Redes de computadoras

Un conjunto de computadoras conectadas para compartir información u otros recursos es una **red** de computadoras. En cualquier red se distinguen por lo menos tres elementos de hardware:

- Las computadoras conectadas se llaman hosts o nodos terminales.
- Los enlaces que conectan las computadoras. Los enlaces suelen llamarse punto a punto cuando conectan únicamente dos nodos, o compartidos cuando al mismo enlace se conectan más de dos nodos.
- Otros nodos intermedios, los routers, que sirven para encaminar el tráfico de información entre los nodos terminales.

Para utilizar la red, todos los nodos que están conectados a ella, ya sean terminales o intermedios, corren software de red como **protocolos** y **aplicaciones de red**. Los protocolos son, por un lado, convenciones que establecen con todo detalle cómo se realiza una comunicación, y por otro lado, los componentes de software que implementan esa forma de comunicación.

Las aplicaciones de red son aplicaciones **distribuidas**, es decir, se componen de al menos dos partes, preparadas para comunicarse unas con otras, y esas partes funcionan en nodos terminales de la red diferentes. Cada aplicación de red utiliza un protocolo, porque la interacción entre las partes debe estar perfectamente determinada para que los nodos se entiendan sin errores ni ambigüedades. Un protocolo puede ser utilizado por varias aplicaciones.

Hoy, la mayoría de las redes están interconectadas por una única red global llamada **Internet**. Para conectarse a Internet, todos los nodos, terminales e intermedios, ejecutan un protocolo básico llamado **IP (Internet Protocol)**, y se puede decir que, desde el punto de vista del software, constituyen una sola red.

Sin embargo, desde el punto de vista de la administración, dentro de Internet existen numerosas redes. Cada red es propiedad de una persona u organización que tiene el control sobre los nodos y enlaces de esa red, decide qué nodos pertenecen o no pertenecen a ella, y qué protocolos y aplicaciones utilizan.

Estas diferentes redes se pueden clasificar por su tamaño.

- Una red cuyos límites (o diámetro) son pequeños, se llama una red de área local o LAN (Local Area Network). Típicamente, una LAN está contenida en una oficina, piso o edificio.
- Una red que abarca el área de una ciudad (y por lo tanto, cuyos enlaces utilizan espacios públicos) suele llamarse red metropolitana o MAN (Metropolitan Area Network).
- Una red mayor, que cubre distancias entre ciudades, países o continentes, se llama una red de área extensa o WAN (Wide Area Network). Las redes de los proveedores de servicios de Internet (ISPs) suelen clasificarse como WANs.

# Modelo de Internet

Las redes pueden estudiarse y comprenderse mediante modelos jerárquicos compuestos por capas, donde cada pieza de hardware o de software pertenece a una capa o nivel.

Cada capa corresponde a un conjunto de problemas relacionados, y a las soluciones posibles. Para funcionar, cada capa se apoya en las soluciones provistas por la capa inmediatamente inferior.

## Aplicación

En la capa de Aplicación se encuentran los protocolos sobre los cuales se basan directamente las aplicaciones distribuidas.

#### Transporte

La capa de Transporte soluciona el problema de la entrega de datos entre **procesos** de nodos diferentes.

#### Red

La capa de Red soluciona el problema de la entrega de datos entre **nodos** de diferentes redes.

#### Enlace

La capa de Enlace soluciona el problema de la entrega de datos entre **nodos** de la misma red.

## Física

La capa Física define la forma como se codifican y transmiten las señales que representan la información.

## **Switches**

En las redes de área local, o LAN, encontramos enlaces compartidos. El cableado de una oficina, un aula o un edificio es un único medio de comunicación compartido por todos los nodos de la red. El cableado se concentra en un punto de conmutación llamado **switch** o, justamente, conmutador, que distribuye el tráfico entre los nodos conectados. Un switch tiene muchas **interfaces** donde se conectan cables punto a punto hacia los nodos de la LAN.

Es posible conectar switches entre sí para mejor distribución del tráfico, formando una **topología** de estrella o de árbol. Todo el conjunto de switches y enlaces de la LAN constituye un enlace compartido, ya que todos los nodos de la LAN pueden comunicarse a través de él.

Los switches y los nodos de las redes de área local ejecutan un protocolo de enlace definido por la norma **IEEE 802.3**. Este protocolo deriva de uno anterior, llamado **Ethernet**. Aunque el diseño original de Ethernet era diferente del de 802.3, y el hardware sobre el que funcionaba Ethernet era muy diferente del de los switches actuales, este nombre de Ethernet sigue usándose informalmente para las redes construidas con switches 802.3.

Un switch 802.3 conduce unas unidades de tráfico básicas, los **frames o tramas** 802.3, entre los nodos de la red de área local, conectados al enlace compartido formado por todos los switches y cableado de la LAN. La misión de este protocolo de enlace termina donde termina la red de área local. Los frames o tramas jamás salen fuera de la LAN. Por eso decimos que la función de **nivel de enlace** de una red es entregar el tráfico **entre nodos adyacentes**. Es decir, los que se encuentran sobre el mismo enlace.

#### Routers

Suele definirse a Internet como "red de redes". Las grandes redes, y en particular Internet, se componen interconectando redes a través de enlaces, a veces de gran longitud. Entre cada dos de estas redes siempre existe un **router**.

El router presta el servicio que no alcanza a prestar el nivel de enlace, que es el de enviar el tráfico fuera de la red de origen. El nivel al que pertenecen los routers se llama **nivel de red**.

Los routers son los elementos que toman las decisiones de **enrutamiento** o ruteo, al determinar por cuál de sus interfaces, que a veces son muchas, debe ser enviada la información que reciben. Esta tarea de enrutar la información se cumple mediante software de enrutamiento.

El hardware y el sistema operativo de los routers pueden estar altamente especializados en la tarea de ruteo, pero también es perfectamente posible construir un router a partir de una computadora corriente de escritorio y un sistema operativo multipropósito. Es decir que los routers no son sino computadoras, con un sistema operativo y un hardware similares a los que encontramos en muchas otras computadoras, pero dedicadas a la tarea del enrutamiento.

Dependiendo del ambiente donde deben trabajar y de la cantidad de tráfico que deben procesar, los routers pueden adoptar muchas formas físicas y tamaños.

- Los routers pueden ser pequeños y baratos, para uso doméstico.
- Algunos pueden dar servicio a muchos nodos terminales al incluir múltiples dispositivos de nivel de enlace, como un switch 802.3 de varias interfaces, y un punto de acceso para una red inalámbrica secundaria basada en tecnología de radio.

 Algunos, de muy altas prestaciones, usados por los proveedores de servicios de Internet, son modulares y pueden ser configurados a medida de las necesidades.
 Cada módulo contiene interfaces especializadas en alguna tecnología de enlace, lo que les permite conectar redes de tecnologías completamente diferentes.

### Interfaces

La interfaz es el punto de conexión entre un enlace y un nodo de la red. Es la pieza de hardware que convierte bits a señales capaces de viajar por la red, y viceversa. Cuando un nodo debe comunicar algo a otro, prepara su mensaje en una zona de la memoria, y entrega esos contenidos binarios a la interfaz a través de un bus de comunicación.

La interfaz contiene el hardware necesario para traducir ese **tren de bits** a señales eléctricas (cuando los enlaces son cableados), de radio (cuando el enlace es inalámbrico), o luminosas (cuando el enlace es de fibra óptica).

Las modernas interfaces de red pueden funcionar a **velocidades de transmisión** de muchos bits por segundo. Una LAN cableada actual funciona comúnmente en velocidades de 1 a 10 Gb/s o Gbps (gigabits por segundo). Una LAN inalámbrica suele funcionar a una velocidad de transmisión mucho menor (y, además, variable, dependiendo de condiciones físicas ambientales que tienden a limitar la velocidad de transmisión).

El tren de bits viaja en forma de señales físicas por el enlace hasta llegar a la interfaz del nodo destino dentro de la red de área local. La interfaz receptora decodifica las señales, recuperando los bits originales y comunicándolos al software que espera los datos. Ambas partes de la aplicación distribuida se han comunicado un mensaje.

## Medios y enlaces

El material que atraviesan las señales transmitidas sobre un enlace se llama el **medio** del enlace. Las tecnologías de construcción de los enlaces son muchas.

- Cuando las señales se codifican mediante impulsos eléctricos, como en las redes de cables de par trenzado o coaxial, el medio es un conductor, como el cobre.
- Para distancias mayores (como las transoceánicas) o para ambientes donde existe mucho ruido o interferencia electromagnética (como en fábricas), se utiliza fibra óptica.
- Cuando no es posible, o práctico, tender un cable, no queda más solución que utilizar emisiones de radio. Ejemplos de tecnologías de radio son los enlaces satelitales, los de microondas, y las LAN inalámbricas bajo norma 802.11 conocidas popularmente como WiFi. Estas tecnologías utilizan como medio el espacio.

Las principales compañías de conectividad del mundo tienden enlaces de fibra óptica transoceánicos. Como la instalación de estos cables es una maniobra muy compleja y tiene un costo altísimo, se aseguran de instalar capacidad de transmisión en abundancia. Por ejemplo, uno de estos enlaces tiene una capacidad de 3.2 Tbps, lo que permitiría transmitir el contenido completo de un disco rígido de 1 TB en menos de tres segundos. Esta capacidad es compartida entre varios proveedores de Internet que compran el servicio de transporte.

#### Interesante

#### Submarine Cable Map

En el pasado también se usaron los enlaces satelitales para resolver el problema de cubrir grandes distancias. Los satélites son repetidores de radio colocados en órbita. Reciben emisiones de una estación terrena y la comunican a otra distante, superando el problema de la curvatura terrestre, que no permitiría la propagación en línea recta de la emisión de radio.

Su principal inconveniente es la alta **latencia o retardo** en la llegada de la señal desde un punto a otro, debido a las grandes distancias que se deben enlazar. Los satélites **geoestacionarios** o de órbita alta (**GEO**) se instalan a una altura de alrededor de 35700 km. Al ubicarlos a esta altura se alcanza un equilibrio entre la fuerza de gravedad terrestre y la fuerza centrífuga del satélite, lo que garantiza que permanecerán inmóviles respecto de algún punto de la superficie terrestre, y así cubrirán siempre la misma región del planeta. Pero la órbita alta implica una gran distancia a recorrer para las señales, lo que introduce demoras de alrededor de un cuarto de segundo entre estaciones terrestres. Estas demoras son tolerables para algunas aplicaciones de tráfico de datos, pero perjudiciales para las comunicaciones interactivas.

Paulatinamente van siendo abandonados en favor de la fibra óptica para comunicación de datos a grandes distancias. Hoy se estima que sólo un 5 % del tráfico internacional es satelital, y el resto es conducido por fibras ópticas. Sin embargo, siguen siendo una buena solución para atravesar áreas continentales, o para distribuir tráfico hacia muchos puntos simultáneos de bajada, como en los medios de comunicación televisivos (aplicación llamada **broadcasting**).

### Velocidades de transmisión y de propagación

Cada interfaz funciona a una determinada **velocidad de transmisión**, que es la cantidad de bits por segundo que es capaz de escribir en el enlace, o leer del enlace. Las unidades utilizadas para expresar la velocidad de transmisión son las del sistema decimal. Así, una medida habitual es el Gbps o gigabit por segundo  $(10^9b/s)$ . La velocidad de transmisión suele ser llamada también **ancho de banda digital**.

Por otro lado, una vez que **cada bit** ha sido escrito en un enlace, ese bit aún debe viajar desde la interfaz de salida hasta la interfaz del otro extremo del enlace. Ese viaje, aunque se realiza a velocidades cercanas a la de la luz, **no es instantáneo**.

Dependiendo del medio, la **velocidad de propagación** de un bit puede ser de alrededor de un  $60\,\%$  a  $90\,\%$  de la velocidad de la luz, que es de unos  $300.000\,$  km/s, o  $3\times10^8m/s$ .

- Notemos que la velocidad de transmisión depende exclusivamente de las características tecnológicas de la interfaz. Son la construcción y la configuración de la interfaz las que definen la velocidad de transmisión a la cual funcionará un enlace, y no el medio con el que se implementa el enlace.
- Por el contrario, notemos también que la velocidad de propagación es una cuestión puramente física y no depende de la tecnología de las interfaces.

La velocidad de **transmisión** puede mejorarse si se mejoran las tecnologías de interfaz en los extremos del enlace. Pero un medio tiene una determinada velocidad de **propagación**, y ningún cambio en la tecnologia de las interfaces cambiará esa velocidad.

## Tiempo de transferencia de un mensaje

Conocer las velocidades de transmisión y de propagación nos permite definir un modelo para el **tiempo de transferencia** de un mensaje a través de un enlace.

Este modelo dependerá de otras dos variables: por un lado, como es lógico, del tamaño del mensaje que se quiere transmitir; y por otro lado, de la **distancia** que separa las interfaces.

Supongamos que:

- El mensaje es de *L* bits.
- lacksquare La velocidad de transmisión es  $V_{transm}.$
- La velocidad de propagación es  $V_{prop}$ .

Y que además, llamamos D a la distancia entre interfaces o longitud del enlace. Entonces:

- El tiempo de transmisión para los L bits será  $T_{transm} = L/V_{transm}$ .
- El **tiempo de propagación** para el enlace de D m será  $T_{prop} = D/V_{prop}$ .

Notemos una vez más que el tiempo de transmisión es dependiente de la velocidad de transmisión de las interfaces, y no de la longitud del enlace. Y además, que el tiempo de propagación es función de la longitud del enlace, y no de la velocidad de transmisión de las interfaces.

El **tiempo de transferencia** que demorarán en llegar los L bits a destino, será la suma de ambos tiempos:

$$T_{tot} = T_{transm} + T_{prop}$$

Es habitual ver en la bibliografía de Redes los diagramas de flujo de mensajes, que muestran qué ocurre en cada nodo a medida que transcurre el tiempo. En estos diagramas, el tiempo avanza hacia abajo, y los nodos emisor y receptor están representados por columnas.

En el emisor, a la izquierda, un trazo vertical de línea gruesa encima del nodo indica el tiempo de transmisión de un mensaje. Donde comienza el trazo, comienza la transmisión del primer bit del mensaje. Donde finaliza el trazo vertical y comienza una línea oblicua, finaliza la transmisión del último bit. Mientras más largo este trazo vertical, mayor el tiempo de transmisión y, por lo tanto, menor la velocidad de transmisión de la interfaz.

La línea oblicua, proyectada sobre la columna del emisor, indica el tiempo invertido en atravesar el enlace desde el emisor hasta el receptor. El ángulo formado por la oblicua con la vertical se relaciona con el tiempo de propagación. Mientras más tienda la oblicua a la horizontal, menor será el tiempo de propagación, lo que indica un enlace de menor longitud.

Comparemos ambos tiempos de transmisión y propagación. Podemos tener un **enlace**  $\mathbf{1}$  (línea azul) de baja velocidad de transmisión respecto del **enlace**  $\mathbf{2}$  (línea verde). Como las líneas de propagación tienen el mismo ángulo, inferimos que los enlaces son de la misma longitud.

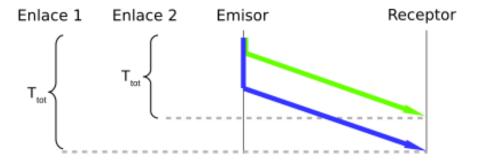


Figura 2: Comparando enlaces de la misma longitud

En este diagrama, el tiempo total mayor corresponde al enlace 1, que es el que tiene el mayor tiempo de transmisión.

Sin embargo, el tiempo de transmisión no es lo único que determina un mayor tiempo de transferencia. Si los enlaces fueran de diferente longitud, la situación podría invertirse. Un enlace de mayor velocidad de transmisión (línea azul) podría

seguir siendo el de mayor tiempo de transferencia si fuera de longitud suficientemente mayor que el otro.

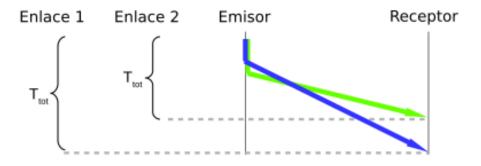


Figura 3: Comparando enlaces de longitudes diferentes

### Entidades de red

Llamamos **entidades** a las piezas de software o de hardware que funcionan como componentes de los nodos dentro de una red. Las entidades pueden ubicarse a cualquier nivel: pueden ser dos routers, dos interfaces de red, o las partes de una aplicación distribuida.

Las entidades de nodos diferentes que van a comunicarse estarán siempre al mismo nivel.

### Eventos de red

Llamamos **eventos** a cualquier suceso de interés que ocurre dentro de la red, especialmente si se trata de una interacción entre entidades. Por ejemplo, la llegada de un mensaje.

### **Protocolos**

Los **protocolos** son conjuntos de reglas que definen la interacción entre dos entidades de la red.

Para comunicarse, las entidades de cualquier nivel deben compartir un protocolo. Los protocolos especifican:

• Cuál es el **formato** de los mensajes que pueden intercambiar las entidades;

 Qué tipo de acciones o respuestas debe dar cada entidad al recibir cada mensaje.

Puede ser útil comparar los protocolos de red con protocolos sencillos de la vida cotidiana. Muchas interacciones entre las personas están gobernadas por protocolos, a veces poco evidentes. Por ejemplo, comprar un artículo cualquiera en un comercio sigue unas pautas bastante definidas.

Aunque los contenidos específicos de los mensajes pueden variar, es habitual que existan fases en la interacción entre las personas, como el inicio de sesión, la autentificación, la autorización, las peticiones o requerimientos (requests), las respuestas (responses), y el cierre de sesión.

Todas éstas son fases habituales en la comunicación entre los humanos, pero también en los protocolos de las redes.

#### Modelo cliente-servidor

Estas fases habituales aparecen en los protocolos que definen relaciones de **cliente y servidor** entre entidades. En el modelo cliente-servidor:

- El nodo cliente es el que inicia una interacción, con un request o requerimiento hacia el servidor.
- El nodo servidor contesta con una respuesta o **response**.
- El ciclo puede repetirse indefinidamente.

La mayoría de las aplicaciones de Internet siguen este **modelo cliente-servidor** de interacción. El protocolo **HTTP**, motor de la **WWW**, es un ejemplo claro.

#### Modelo peer-to-peer

El modelo cliente-servidor es asimétrico: los roles de cliente y de servidor están bien diferenciados. Un modelo alternativo, diferente, es el llamado **peer-to-peer**, donde no existe un nodo servidor propiamente dicho, sino que todos los nodos que comparten el protocolo son, a la vez, clientes y servidores, en igualdad de condiciones.

#### **Autómatas**

Los **autómatas** son una herramienta formal muy útil para describir detalladamente los protocolos. Un autómata es la especificación de los **estados** en los que puede encontrarse una entidad y los **eventos** que disparan los cambios de estado o **transiciones**. El autómata puede tomar la forma de un diagrama de burbujas y flechas.

- En un diagrama de autómata, las burbujas representan estados.
- Las flechas representan transiciones.
- Las flechas llevan rótulos que describen qué evento es necesario para disparar la transición, y qué acción debe ejecutar la entidad como respuesta al evento.
  - Cuando no se requiere un evento para entrar en un estado (por ejemplo, porque es el estado inicial del autómata), el evento es vacío (y se denota "-").
  - Un mensaje de respuesta que confirma la recepción correcta de un mensaje anterior se llama un reconocimiento o acknowledgement (ACK). Si el mensaje de respuesta indica la recepción incorrecta, se llama un acknowledgement negativo o NAK.

#### Autómata del cliente



Figura 4: Autómata del cliente

En el ejemplo, el cliente ingresa al estado de **Abriendo conexión** presentando sus credenciales. Si son aceptadas, envía su primera solicitud y pasa al estado **En servicio**. A cada respuesta que reciba, podrá enviar una nueva solicitud. Finalmente, emitirá un mensaje de cierre de conexión y terminará la interacción con el servidor.

### Autómata del servidor

Por su parte, el servidor presenta un autómata complementario al del cliente. La mayor parte del tiempo, el servidor estará en el estado **Esperando conexión** hasta que reciba unas credenciales de un cliente. Si las reconoce, pasa al estado **En servicio** 

donde acepta solicitudes y emite respuestas. Cuando el cliente decide poner fin a la interacción, vuelve al estado de esperar conexión de un nuevo cliente.

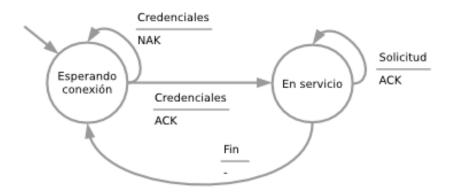


Figura 5: Autómata del servidor

### Protocolos de parada y espera

¿Cómo se relacionan, por un lado, las medidas de tiempo de transmisión y tiempo de propagación, y, por el otro, los autómatas de un protocolo cliente-servidor?

Muchos protocolos requieren que una entidad reciba la confirmación de un mensaje anterior antes de poder enviar el siguiente mensaje. Cuando esto ocurre, decimos que el protocolo es del tipo de **parada y espera** (*stop and wait*). Cuando el enlace entre dos entidades es de longitud muy grande, un protocolo de parada y espera puede tener una eficiencia muy reducida.

Si la aplicación que desea usar este protocolo de parada y espera es interactiva, y el enlace es muy largo, la experiencia de usuario será frustrante. El usuario deberá soportar las demoras correspondientes al tiempo de propagación de cada mensaje más el de su confirmación. Durante ese lapso, no se puede seguir transmitiendo datos porque aún no ha llegado la confirmación o **ACK** del mensaje anterior. Las demoras pueden hacer que la aplicación directamente no sea viable.

El punto crucial aquí es que este problema **no se resuelve aumentando el ancho de banda de los enlaces**, porque, como hemos dicho, el retardo de propagación no tiene nada que ver con la velocidad de transmisión de las interfaces.

Gran parte de la complejidad de Internet se debe a la necesidad de resolver este problema de los protocolos de parada y espera. En Internet, la solución está representada por el protocolo TCP/IP, que en lugar de obligar a esperar un tiempo de propagación por cada mensaje, es capaz de encadenar varios mensajes sin necesidad

de esperar confirmación por cada uno. El protocolo TCP pertenece al nivel de **transporte** de las redes.

#### Pregunta

Supongamos que se tiene un enlace de radio de 1Gbps entre una estación terrestre y un vehículo experimental **que circula por la superficie de Marte**. Supongamos además que la aplicación sea controlar interactivamente desde la Tierra este vehículo mediante un protocolo de parada y espera. Los mensajes de este protocolo son comandos de la forma **avanzar**, **detenerse**, **izquierda**, **derecha**, etc.

La distancia teórica mínima al planeta Marte es de unos  $54 \times 10^6 km$ . Esto se traduce en unos 3 minutos de retardo de propagación. Quiere decir que cada comando enviado desde la Tierra a Marte demorará, en el mejor caso, unos 6 minutos en ser confirmado. Esto ocasiona problemas para controlar el vehículo, porque una mala maniobra puede dejarlo en una situación peligrosa sobre el escarpado suelo marciano. Se necesita una velocidad de respuesta mucho mayor.

Elevar el ancho de banda digital del enlace, de 1Gbps a 10Gbps, ; sería una solución?

## Direcciones de red

Para poder dirigir los mensajes entre nodos, es necesario identificarlos de alguna forma, asignándoles **direcciones** o identificadores de red.

En Internet, las direcciones son asignadas a las interfaces, y no a los nodos. De esta manera, si un nodo tiene más de una interfaz, recibirá más de una dirección. El caso típico de un nodo con más de una interfaz son los routers, que tienen una interfaz perteneciente a cada una de las redes que conectan.

El protocolo IPv4 define las direcciones de red como números de 32 bits que se asignan a cada interfaz de los nodos. Estas direcciones de 32 bits suelen escribirse como cuatro valores decimales, entre 0 y 255, separados por puntos.

## **Ejemplo**

■ La dirección IPv4 110000001010100000000100000001 se puede escribir en notación decimal con punto como 192.168.1.1.

## Paquetes IP

Internet es una red del tipo de **conmutación por paquetes**, lo que significa que los flujos de datos que van de un nodo emisor a un receptor son fraccionados en **paquetes** o trozos de datos, de un cierto tamaño máximo, y que los nodos intermedios tratan a cada paquete individualmente para encaminarlos a su destino.

En una red conmutada por paquetes, los nodos intermedios, o routers, no necesitan conocer todo el camino que debe atravesar cada uno de los paquetes. En cambio, un

router sólo necesita saber a cuál de los **nodos intermedios adyacentes** encaminarlo, basándose en información transportada por el mismo paquete.

Cada nodo intermedio o router en el camino entre el emisor y el receptor tomará una nueva decisión de ruteo ante cada uno de los paquetes que llegan a él.

Al generar un paquete, para que pueda ser encaminado, el emisor completa los datos con un **encabezado** conteniendo la dirección IP del nodo emisor, o **dirección origen**, y la dirección IP del nodo destino, o **dirección destino**.

## Ruteo o encaminamiento

Cuando un paquete llega a un router, lo hace por algún enlace. La tarea del router es **reenviar** este paquete por otro de sus enlaces, de modo que se aproxime a su destino.

El router debe aplicar alguna regla lógica para decidir hacia qué otro enlace **reenviar** el paquete. Esta decisión de cuál será ese otro enlace es una acción de **ruteo** o **encaminamiento**.

#### Tabla de reenvío o de ruteo

La decisión de ruteo es tomada por los routers usando la información de destino que llevan consigo los paquetes, más información de ruteo contenida en una **tabla de reenvío** o tabla de ruteo, almacenada en la memoria del router.

La tabla de ruteo contiene reglas para la decisión de encaminamiento de los paquetes. Cada regla se llama una **ruta** e indica cuál será la interfaz de salida de los paquetes cuya dirección destino coincida con la dirección destino de la ruta.

En líneas generales, el algoritmo de ruteo es como sigue:

- Al recibir un paquete, el router examinará la dirección destino del paquete y la comparará con la dirección destino de cada ruta.
- Al encontrar una coincidencia de dirección destino entre el paquete y la ruta, utilizará la información en la columna de interfaz de salida de esa ruta, reenviando el paquete por esa interfaz.

Sin embargo, ésta es una simplificación. La verdadera forma de la tabla de ruteo es algo diferente. ¿ Por qué?

#### **Subredes**

Notemos que, ya que las direcciones IP se escriben usando 32 bits, existen más de cuatro mil millones de direcciones IPv4 posibles. Una tabla de ruteo completa, con

una ruta por cada dirección destino, tal como la hemos descrito, tendría enormes requerimientos de memoria, y el equipamiento de ruteo sería muy costoso.

Las tablas de ruteo verdaderas, entonces, no contienen una ruta por cada dirección destino, sino que las rutas corresponden a conjuntos o agrupaciones de direcciones, llamadas **subredes**.

Un paquete cuya dirección destino pertenezca a una subred utilizará la ruta de dicha subred. Cualquier otra dirección destino que pertenezca a la misma subred recibirá la misma decisión de ruteo.

Si las subredes son agrupaciones suficientemente grandes, la cantidad de reglas de ruteo o rutas disminuirá convenientemente.

## Prefijo de subred

¿Cómo agrupar estas direcciones para definir las subredes?

Todas las direcciones con el mismo **prefijo** de una cierta longitud formarán una subred.

## **Ejemplo**

- Las direcciones IP 130.240.10.17 y 130.240.11.15 pertenecen a una subred con prefijo común 130.240 de 16 bits. Todas las direcciones pertenecientes a esta subred se escriben como 130.240.XXX.XXX.
- Sin embargo, notemos que, si escribimos las direcciones IP anteriores en su forma binaria, encontraremos que en realidad existe un prefijo común aún más largo. En efecto,

130.240.10.17 = 10000010.11110000.00001010.00010001 130.240.11.15 = 10000010.11110000.00001011.00001111

Los primeros **23 bits** de ambas direcciones son iguales, luego comparten un prefijo común de longitud 23. Es imposible escribirlo en notación decimal a menos que adoptemos la convención de completar con ceros la parte no común:

130.240.10.0 = 10000010.11110000.00001010.00000000

Esta convención no es otra cosa que lo que llamamos la dirección de la subred.

### Dirección de subred y máscara de subred

Cuando en una tabla de ruteo se especifique una ruta para todas las direcciones con un mismo prefijo, la dirección destino de la ruta será una **dirección de subred**.

Una dirección de subred se calcula utilizando una **máscara de subred**, que es una sucesión de 32 dígitos binarios. Los primeros n dígitos de la máscara son **unos**, y los restantes **ceros**.

Estos primeros n dígitos "unos" definen cuál será el prefijo compartido por todas las direcciones IP que pertenecen a la subred. La cantidad de dígitos "uno" dicen cuál es la longitud del prefijo compartido. Los restantes bits de esas direcciones pueden tomar cualquier valor.

## **Ejemplo**

- Una máscara de 24 bits de longitud puede expresarse como 11111111 11111111 11111111 00000000, que en la misma notación decimal de las direcciones IP suele escribirse 255.255.25.0.
- Una máscara de 26 bits de longitud puede expresarse como 11111111
   1111111 11111111 11000000, o 255.255.255.192.

### Cálculo de la dirección de subred

Para calcular la dirección de subred a la cual pertenece una dirección IP, superponemos la dirección y su máscara de modo de encolumnar todos los dígitos y efectuamos una operación AND bit a bit. El operador AND es el que devuelve 1 solamente si ambos operandos son 1, y en otro caso devuelve 0.

El efecto de este AND es **copiar** en las primeras n columnas del resultado los bits tal cual figuran en la dirección IP, y **completar con ceros** hasta el final del resultado. Este resultado es la dirección de subred a la cual pertenece la dirección IP original.

#### **Ejemplo**

- ¿Cuál es la dirección de subred de la dirección IP **170.210.80.129** con máscara 255.255.255.0?
  - Aplicando la máscara de 24 bits de longitud, la operación AND devuelve la dirección de subred **170.210.80.0**.
- ¿Cuál es la dirección de subred de la dirección IP 170.210.80.129 con máscara 255.255.255.128?
  - Si escribimos esta máscara en forma binaria, vemos que contiene **25 unos**. La operación AND que copia los primeros 25 bits de la dirección IP y deja los restantes en 0 da la dirección de subred **170.210.80.128**.

#### Notación alternativa

Una máscara de subred con n bits suele expresarse también como "/n". Así, la dirección IP 192.168.1.1 con máscara 255.255.255.0 puede escribirse más sencillamente como 192.168.1.1/24.

Sabiendo calcular direcciones de subred, ya podemos rediseñar la tabla de ruteo. Habrá que especificar **direcciones de subred** en lugar de direcciones de hosts, y para cada ruta en la tabla, agregar cuál es la **máscara** que define el prefijo de la ruta.

#### Nota

Para simplificar los ejemplos siguientes, utilizaremos direcciones y máscaras de cinco bits. Sin embargo, el mecanismo para el algoritmo de reenvío será básicamente el mismo que con las direcciones reales IPv4 de 32 bits.

## **Ejemplo**

Sea una tabla de ruteo con la siguiente información:

Dirección de subred	Máscara	Interfaz de salida
00000	11100	0
00100	11100	1
00010	11110	2

Esta tabla de ruteo dice que:

- La subred 00000 con máscara 11100 se alcanza mediante la interfaz de salida
   0. Es decir, que si los primeros tres bits de la dirección destino de un paquete son 000, el paquete debe ser reenviado por la interfaz 0.
- La subred 00100 con máscara 11100 se alcanza mediante la interfaz de salida 1. Es decir, que si los primeros tres bits de la dirección destino de un paquete son 001, el paquete debe ser reenviado por la interfaz 1.
- La subred 00010 con máscara 11110 se alcanza mediante la interfaz de salida 1. Es decir, que si los primeros **cuatro** bits de la dirección destino de un paquete son 0001, el paquete debe ser reenviado por la interfaz 2.

#### Pregunta

■ En el ejemplo anterior, ¿puede darse un caso donde quepa la duda de si aplicar la primera o la segunda regla?

## Ruta por defecto o ruta default

Aun con la estrategia de ruteo por prefijos, los routers no pueden conocer **todas** las rutas a todos los destinos. Siempre se apoyan en que alguno de sus routers vecinos que esté más próximo al destino tenga más información que ellos.

Cuando un router no sabe cómo encaminar un paquete, lo envía por una interfaz predefinida, en la esperanza de que un router situado sobre ese enlace, que reciba el paquete, tenga mejor información.

Para definir una ruta default agregamos una regla a la tabla de ruteo con dirección de subred = 00000 y máscara de red = 00000. Como la máscara tiene cero

unos, cualquier dirección IP destino da una coincidencia. Por eso, la regla default se consulta en último lugar, y como último recurso. De lo contrario, la interfaz de la ruta default absorbería todo el tráfico y nunca se reenviaría tráfico a otros enlaces.

En Internet, tiene sentido que la interfaz de la ruta default en cada router sea la que "mira" al centro de la Internet, en la dirección donde hay más nodos. Allí es más probable que existan routers con una configuración mejor.

## Rutas más específicas y máscaras más largas

El caso de la ruta default nos permite ver que la ruta más genérica, la menos específica, es la que tiene la máscara más corta. Representa a cualquier subred, o al conjunto de todas las subredes.

Lo inverso también es cierto: si una máscara es más larga, la ruta es más específica. Una máscara más larga representa una subred de **menor** tamaño.

Una máscara larga puede servir para indicar una excepción a una regla más general. Por eso, las máscaras más largas **tienen preferencia** en el proceso de ruteo de un paquete.

Cada vez que un router se encuentre con más de una ruta posible, elegirá aquella cuya máscara de subred sea más larga (es decir, la ruta más específica).

# Algoritmo de reenvío

Finalmente podemos presentar el algoritmo de reenvío tal cual lo ejecutan los routers de Internet.

- Para cada regla en la tabla de ruteo, en orden descendente por longitud de prefijo
  - Subred destino del paquete = Dirección destino del paquete AND Máscara de la ruta
  - Si subred destino del paquete = subred de la ruta, reenviar el paquete por la interfaz de salida de esa ruta
- Si se agotó la tabla pero hay una ruta default
  - Reenviar el paquete por la ruta default
- Si se agotó la tabla sin éxito
  - Devolver error de red inalcanzable

Como las reglas se consultan en orden de prefijos más largos a prefijos más cortos, las rutas más específicas se encuentran primero, y tienen preferencia sobre las menos específicas.

## **Ejemplo**

Volvamos a la tabla de ruteo de un ejemplo anterior, sólo que agregándole una ruta default por la interfaz 2:

Regla	Dirección de subred	Máscara	Interfaz de salida
1	00000	11100	0
2	00100	11100	1
3	00010	11110	2
4	00000	00000	2

¿Qué camino tomarán los paquetes con la siguiente dirección destino?

- lacksquare 00001 ightarrow Interfaz 0, por la regla 1
- 00011 → Interfaz 2, por la regla 2, ya que, a pesar de que la dirección destino coincide también con la regla 1, la regla 2 es más específica.
- lacksquare 01001 ightarrow Interfaz 2, por la regla default, ya que las anteriores no han resultado en coincidencias.

# Servicio de Nombres de Dominio (DNS)

Como hemos visto, el funcionamiento de Internet se basa en la existencia de **direcciones**, que permiten enviar y encaminar el tráfico entre los diferentes puntos de la red. Sin embargo, las direcciones IP de 32 bits, o su equivalente de cuatro decimales con puntos, son incómodas de manejar para los humanos. El **servicio de nombres de dominio**, o Domain Name Service (**DNS**) es un servicio agregado a la Internet para comodidad de los usuarios.

El servicio DNS permite a los usuarios referirse a los nodos de Internet mediante nombres simbólicos en lugar de direcciones, y entra en acción cada vez que se menciona el **nombre** de un nodo para hacer contacto con él. Un nodo que necesita enviar un mensaje cualquiera a otro nodo necesita conocer su dirección IP. Si únicamente conoce su nombre, pedirá una **traducción de nombre** a algún **servidor DNS**.

Técnicamente, Internet podría funcionar perfectamente (y, de hecho, lo hizo durante algún tiempo) sin la existencia del servicio DNS, pero la costumbre lo ha convertido en una parte indispensable de la red.

## Jerarquía de nombres de dominio

Estos nombres simbólicos tienen una cierta estructura jerárquica, es decir, organizada por niveles. Un nombre consta de varias partes, separadas por puntos. En cada

nombre, las partes más a la derecha designan conjuntos mayores de nodos, y las partes más a la izquierda, conjuntos más pequeños, contenidos en aquellos conjuntos mayores.

#### **Ejemplo**

- El nombre pedco.uncoma.edu.ar designa al nodo pedco, que pertenece al conjunto uncoma, contenido en el conjunto edu contenido en el conjunto ar.
- El nombre pedco.uncoma.edu.ar equivale, gracias al servicio DNS, a la dirección IP 170.210.81.41.

Estos conjuntos de nombres se llaman **dominios**. Los dominios que aparecen más a la derecha son los más generales. Inicialmente fueron siete de propósito general (**org, mil, gov, edu, com, net, int**), más los pertenecientes a los países (**ar** para Argentina, **cl** para Chile, **uy** para Uruguay...), pero luego se agregaron otros. Por ser los más generales, están al tope de la jerarquía, y se llaman dominios de nivel superior o **TLD** (**Top-Level Domains**).

Los dominios de nivel superior contienen otros espacios de nombres, llamados a su vez dominios, y éstos, otros llamados subdominios. En el ejemplo anterior, el TLD es ar, el dominio es edu.ar (educación, Argentina), el subdominio es uncoma.edu.ar (Universidad del Comahue, educación, Argentina) y finalmente pedco.uncoma.edu.ar es el nombre de un nodo perteneciente a la Universidad del Comahue, educación, Argentina.

## Resolución de nombres

Los servidores DNS se clasifican por el tipo de función que cumplen. Cada uno interviene de una manera especial en el mecanismo de traducción de nombres a direcciones. Este mecanismo de traducción se llama **resolución** de nombres.

- Cada nodo de Internet lleva una configuración que le dice cuál es la dirección de su servidor DNS local. El servidor local es quien responde efectivamente una consulta DNS. Normalmente, el servidor local se encuentra "cerca" del cliente en términos de redes. Posiblemente, en la misma red local, o en la del proveedor de acceso a Internet.
- Al ser consultado por un nombre, un servidor local usará la estrategia de analizar ese nombre de derecha a izquierda. Utilizará los componentes del nombre en ese orden, es decir, yendo de lo general a lo particular. En primer lugar utilizará el TLD o nombre de nivel superior para averiguar información sobre ese conjunto de nombres.

Los servidores locales no conocen todas las posibles traducciones de nombre a dirección IP, por lo cual necesitan el servicio de los **servidores raíz**. Estos son alrededor de una veintena de servidores distribuidos en diferentes lugares del

planeta, y todos tienen la misma información, replicada: las direcciones de los servidores de los TLD.

Así, un servidor local obtendrá, de un servidor raíz, el dato de dónde ubicar al servidor del TLD **ar**.

- Conociendo la dirección IP del servidor del TLD, el servidor local lo interrogará entonces acerca del siguiente componente del nombre.
  - Los servidores de los TLD tampoco conocen todas las posibles traducciones, sino que conocen las direcciones de los servidores DNS de los dominios por debajo de ellos. Así, el servidor del TLD **ar** puede decirle al servidor local dónde ubicar al servidor del dominio **edu.ar**.
  - Otra información que este servidor del dominio TLD ar podría darle al servidor local, si la pidiera, serían las direcciones de los servidores de los dominios com.ar, org.ar, etc.
- Ahora el servidor local puede consultar al servidor del dominio edu.ar, que es quien puede informarle la dirección del servidor del subdominio uncoma.edu.ar.
- Finalmente, el servidor local consulta al servidor del subdominio uncoma.edu.ar por la traducción del nombre de nodo www.uncoma.edu.ar. Este servidor tiene en sus tablas la información que dice cuál es la dirección IP asignada a ese nombre. Ahora el servidor local puede devolver esa información al cliente que originalmente hizo la consulta.

Todo este complejo mecanismo debería tener lugar cada vez que un cliente de la red consulta por un nombre. Sin embargo, como este mecanismo es costoso en tiempo y en ancho de banda de las redes, se adopta un esquema de **cache** o reserva de información. Como es muy probable que esa información vuelva a ser solicitada, los pares (nombre, dirección) que han sido resueltos quedan guardados en una memoria temporaria o **cache** del servidor local. De esta manera las próximas consultas podrán responderse sin necesidad de volver a generar tráfico hacia el resto de la Internet.

### Administración de redes

Existen herramientas de software que permiten diagnosticar las condiciones en que se realiza el ruteo, o encaminamiento, de los paquetes IP. El administrador de redes las utiliza para investigar el origen de los problemas en la red.

## Comando ping

El comando **ping** emite paquetes hacia un nodo destino. Si los paquetes logran atravesar la Internet, el nodo destino emitirá una respuesta. El comando ping muestra

los paquetes de respuesta que llegan o se pierden, y el tiempo que demora cada respuesta en llegar.

Cuando los usuarios tienen problemas con alguna aplicación de red, el comando ping es útil como herramienta de diagnóstico porque permite saber si la red es capaz de hacer llegar paquetes de un nodo a otro. Si el diagnóstico de ping es positivo, el administrador de red no se preocupa en comprobar cuestiones asociadas con los niveles inferiores a la capa de red: la comunicación a nivel físico, de enlace y de red entre ambos nodos es operativa. Si existe alguna condición de error, se deberá a problemas relacionados con las aplicaciones, que habrá que investigar.

#### Comando traceroute

El comando **traceroute** permite investigar cuál es la cadena particular de routers que debe atravesar un paquete para llegar a un destino dado. Además, da información sobre la demora en atravesar cada enlace, lo que puede dar una idea de si existe una condición de **congestión** en el camino de los paquetes, y en qué lugar de Internet.

Una condición de congestión es aquella que aparece cuando los nodos intentan utilizar un enlace más allá de su capacidad. Si un enlace es capaz de transmitir una cantidad de bits por segundo, y las demandas de los nodos de la red superan esa capacidad, el router comienza a acumular o encolar paquetes hasta que no tiene más espacio en su memoria para almacenarlos. A partir de este momento, si llegan nuevos paquetes, simplemente los descarta. El programa traceroute hace evidentes las pérdidas de paquetes, y dice en cuál de los enlaces ocurren.

El programa traceroute también permite detectar anomalías de ruteo como los lazos o ciclos de ruteo, que se producen cuando los paquetes toman caminos circulares de los cuales no pueden salir.